

실제 데이터를 이용한 선형회귀와 정규분포 잡음

1 선형회귀 모형

선형회귀 모형은 다음과 같이 표현할 수 있다.

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

여기서 y_i 는 관측값, x_i 는 설명변수, $\beta_0 + \beta_1 x_i$ 는 회귀모형이 예측하는 평균적인 값이다. ε_i 는 모형이 설명하지 못하는 오차 또는 잡음을 의미한다.

선형회귀에서는 보통 이 잡음이 평균 0인 정규분포를 따른다고 가정한다.

$$\varepsilon_i \sim N(0, \sigma^2)$$

따라서 x_i 가 주어졌을 때 y_i 는 다음과 같이 표현된다.

$$y_i | x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$$

즉, 실제 관측값은 회귀직선 주변에서 정규분포 형태로 흩어진다고 볼 수 있다.

2 파이썬 코드

아래 코드는 scikit-learn에 내장된 당뇨병 데이터를 이용하여 BMI와 질병 진행도 사이의 선형회귀 모형을 학습한다.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import load_diabetes
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from scipy.stats import norm

# 1. Load real dataset
diabetes = load_diabetes()
X_all = pd.DataFrame(diabetes.data, columns=diabetes.
    feature_names)
y = diabetes.target
```

```

# 2. Use BMI only for simple visualization
X = X_all[["bmi"]]

# 3. Split train and test data
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42
)

# 4. Fit linear regression model
model = LinearRegression()
model.fit(X_train, y_train)

# 5. Prediction and residuals
y_pred = model.predict(X_test)
residuals = y_test - y_pred

print("linear regression equation:")
print(f"diabetes progression ~= {model.intercept_:.2f} "
      f"+ {model.coef_[0]:.2f} * bmi")

print("\nResidual Summary:")
print(pd.Series(residuals).describe())

# 6. Visualize regression line and actual data
x_line = np.linspace(X["bmi"].min(), X["bmi"].max(), 200).
    reshape(-1, 1)
y_line = model.predict(pd.DataFrame(x_line, columns=["bmi"]))

plt.figure(figsize=(8, 5))
plt.scatter(X_test["bmi"], y_test, alpha=0.75, label="Actual
    data")
plt.plot(x_line, y_line, linewidth=2.5, label="Regression
    mean line")

# Plot residuals as dashed lines for a subset of
    observations
sample_idx = np.arange(min(12, len(X_test)))

for i in sample_idx:
    x_i = X_test.iloc[i, 0]
    plt.vlines(x_i, y_pred[i], y_test[i],
        linestyle="dashed", linewidth=1)

plt.title("Real Data: Linear Regression on Diabetes Dataset")
plt.xlabel("BMI feature, standardized")
plt.ylabel("Disease progression")
plt.legend()

```

```

plt.grid(True, alpha=0.25)
plt.tight_layout()
plt.show()

# 7. Residual histogram and normal distribution curve
mu = np.mean(residuals)
sigma = np.std(residuals, ddof=1)

plt.figure(figsize=(8, 5))
plt.hist(residuals, bins=18, density=True,
         alpha=0.65, label="Residuals")

x_norm = np.linspace(residuals.min(), residuals.max(), 300)
plt.plot(x_norm, norm.pdf(x_norm, mu, sigma),
         linewidth=2.5,
         label="Normal curve fitted to residuals")

plt.axvline(0, linestyle="dashed",
           linewidth=1.5, label="Zero error")

plt.title("Residuals as Noise: Are They Roughly Normal?")
plt.xlabel("Residual = actual - predicted")
plt.ylabel("Density")
plt.legend()
plt.grid(True, alpha=0.25)
plt.tight_layout()
plt.show()

```

3 코드 설명

먼저 `load_diabetes()` 함수를 이용하여 실제 당뇨병 데이터를 불러온다. 이 데이터에는 여러 설명변수가 포함되어 있지만, 그래프로 쉽게 이해하기 위해 여기서는 BMI 변수 하나만 사용한다.

선형회귀 모형은 BMI를 이용하여 질병 진행도를 예측한다. 학습된 회귀식은 다음과 같은 형태를 가진다.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

여기서 $\hat{y}$ 는 예측값이고, x 는 BMI이다.

실제값과 예측값의 차이를 잔차라고 한다.

$$e_i = y_i - \hat{y}_i$$

이 잔차는 회귀모형이 설명하지 못한 부분이며, 통계적으로는 잡음 ε_i 의 관측된 값으로 볼 수 있다.

4 그래프 해석

첫 번째 그래프에서 점들은 실제 관측값을 나타내고, 직선은 선형회귀 모형이 예측한 평균적인 관계를 나타낸다. 점들이 직선 위에 정확히 놓이지 않는 이유는 BMI 만으로 질병 진행도를 완벽히 설명할 수 없기 때문이다.

점선으로 표시된 부분은 실제값과 예측값의 차이, 즉 잔차이다.

$$\text{잔차} = \text{실제값} - \text{예측값}$$

두 번째 그래프는 잔차들의 분포를 보여준다. 잔차들이 0을 중심으로 대체로 종 모양으로 퍼져 있다면, 잔차를 정규분포 잡음으로 가정하는 것이 어느 정도 타당하다고 볼 수 있다.

즉, 선형회귀 모형은 다음과 같이 해석할 수 있다.

$$\text{관측값} = \text{회귀직선이 설명하는 평균적 패턴} + \text{정규분포 잡음}$$

수식으로는 다음과 같다.

$$y = X\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 I)$$

5 정리

선형회귀에서 정규분포는 x 나 y 자체가 반드시 정규분포를 따른다는 뜻이 아니다. 정규분포 가정은 모형이 설명하지 못한 오차항 ε 에 대한 가정이다.

따라서 선형회귀는 다음과 같은 관점에서 이해할 수 있다.

$$\text{선형회귀} = \text{선형적 평균 구조} + \text{정규분포 잡음}$$