1. 파이썬
2. 개요
3. 모집단과 표본
4. 시각화를 이용한 자료 요약

참고용 사이트 여기 클릭.

파이썬 설치하기

- 파이썬은 기본 파이썬 인터프리터 이외에도 다양한 패키지와 개발 도구를 함께 제공하는 배포판으로 설치하는 것이 좋음.

참고용 사이트 여기 클릭.

파이썬 설치하기

- 파이썬은 기본 파이썬 인터프리터 이외에도 다양한 패키지와 개발 도구를 함께 제공하는 배포판으로 설치하는 것이 좋음.
- 현재 가장 널리 사용되는 파이썬 배포판은 '아나콘다(Anaconda)'임. 아나콘다 배포판은 다음 웹사이트에서 자신이 사용하는 운영체제에 맞는 것을 선택하여 내려받는다.

참고용 사이트 여기 클릭.

데이터 분석용 파이썬 패키지 소개

아나콘다 배포판을 설치하면 NumPy, SciPy, SymPy, Matplotlib, Seaborn 등은 자동으로 설치됨.

- NumPy : 파이썬에서 수치 해석, 특히 선형 대수(linear algebra) 계산 기능을 제공. 자료형이 고정된 다차원 배열 클래스(n-dimensional array)와 벡터화 연산(vectorized operation)을 지원하며 수학 연산을 위한 가장 기본적이고 중요한 패키지

참고용 사이트 여기 클릭.

데이터 분석용 파이썬 패키지 소개

아나콘다 배포판을 설치하면 NumPy, SciPy, SymPy, Matplotlib, Seaborn 등은 자동으로 설치됨.

- NumPy : 파이썬에서 수치 해석, 특히 선형 대수(linear algebra) 계산 기능을 제공. 자료형이 고정된 다차원 배열 클래스(n-dimensional array)와 벡터화 연산(vectorized operation)을 지원하며 수학 연산을 위한 가장 기본적이고 중요한 패키지
- SciPy : 고급 수학 함수, 수치적 미적분, 미분 방정식 계산, 최적화, 신호 처리 등에 사용하는 다양한 과학 기술 계산 기능을 제공

참고용 사이트 여기 클릭.

데이터 분석용 파이썬 패키지 소개

아나콘다 배포판을 설치하면 NumPy, SciPy, SymPy, Matplotlib, Seaborn 등은 자동으로 설치됨.

- NumPy : 파이썬에서 수치 해석, 특히 선형 대수(linear algebra) 계산 기능을 제공. 자료형이 고정된 다차원 배열 클래스(n-dimensional array)와 벡터화 연산(vectorized operation)을 지원하며 수학 연산을 위한 가장 기본적이고 중요한 패키지
- SciPy : 고급 수학 함수, 수치적 미적분, 미분 방정식 계산, 최적화, 신호 처리 등에 사용하는 다양한 과학 기술 계산 기능을 제공
- SymPy : 숫자를 더하거나 빼는 수치 연산이 아니라 인수 분해, 미분, 적분 등 심볼릭 연산 기능을 제공

참고용 사이트 여기 클릭.

데이터 분석용 파이썬 패키지 소개

아나콘다 배포판을 설치하면 NumPy, SciPy, SymPy, Matplotlib, Seaborn 등은 자동으로 설치됨.

- NumPy : 파이썬에서 수치 해석, 특히 선형 대수(linear algebra) 계산 기능을 제공. 자료형이 고정된 다차원 배열 클래스(n-dimensional array)와 벡터화 연산(vectorized operation)을 지원하며 수학 연산을 위한 가장 기본적이고 중요한 패키지
- SciPy : 고급 수학 함수, 수치적 미적분, 미분 방정식 계산, 최적화, 신호 처리 등에 사용하는 다양한 과학 기술 계산 기능을 제공
- SymPy : 숫자를 더하거나 빼는 수치 연산이 아니라 인수 분해, 미분, 적분 등 심볼릭 연산 기능을 제공
- Pandas : 테이블 형태의 데이터를 다루는 데이터프레임(DataFrame) 자료형을 제공. 자료의 탐색이나 정리에 아주 유용하여 데이터 분석에 빠질 수 없는 필수 패키지

참고용 사이트 여기 클릭.

데이터 분석용 파이썬 패키지 소개

아나콘다 배포판을 설치하면 NumPy, SciPy, SymPy, Matplotlib, Seaborn 등은 자동으로 설치됨.

- NumPy : 파이썬에서 수치 해석, 특히 선형 대수(linear algebra) 계산 기능을 제공. 자료형이 고정된 다차원 배열 클래스(n-dimensional array)와 벡터화 연산(vectorized operation)을 지원하며 수학 연산을 위한 가장 기본적이고 중요한 패키지
- SciPy : 고급 수학 함수, 수치적 미적분, 미분 방정식 계산, 최적화, 신호 처리 등에 사용하는 다양한 과학 기술 계산 기능을 제공
- SymPy : 숫자를 더하거나 빼는 수치 연산이 아니라 인수 분해, 미분, 적분 등 심볼릭 연산 기능을 제공
- Pandas : 테이블 형태의 데이터를 다루는 데이터프레임(DataFrame) 자료형을 제공. 자료의 탐색이나 정리에 아주 유용하여 데이터 분석에 빠질 수 없는 필수 패키지
- Matplotlib : 파이썬에서 각종 그래프나 챠트 등을 그리는 시각화 기능을 제공

참고용 사이트 여기 클릭.

데이터 분석용 파이썬 패키지 소개

아나콘다 배포판을 설치하면 NumPy, SciPy, SymPy, Matplotlib, Seaborn 등은 자동으로 설치됨.

- NumPy : 파이썬에서 수치 해석, 특히 선형 대수(linear algebra) 계산 기능을 제공. 자료형이 고정된 다차원 배열 클래스(n-dimensional array)와 벡터화 연산(vectorized operation)을 지원하며 수학 연산을 위한 가장 기본적이고 중요한 패키지
- SciPy : 고급 수학 함수, 수치적 미적분, 미분 방정식 계산, 최적화, 신호 처리 등에 사용하는 다양한 과학 기술 계산 기능을 제공
- SymPy : 숫자를 더하거나 빼는 수치 연산이 아니라 인수 분해, 미분, 적분 등 심볼릭 연산 기능을 제공
- Pandas : 테이블 형태의 데이터를 다루는 데이터프레임(DataFrame) 자료형을 제공. 자료의 탐색이나 정리에 아주 유용하여 데이터 분석에 빠질 수 없는 필수 패키지
- Matplotlib : 파이썬에서 각종 그래프나 챠트 등을 그리는 시각화 기능을 제공
- Seaborn : Matplotlib 패키지에서 지원하지 않는 고급 통계 차트를 그리는 통계용 시각화 기능을 제공

개요

- 통계학(statistics): 어떤 결론을 도출해내기 위해 자료를 수집하고, 정리·요약하는 방법을 연구하는 학문.

개요

- 통계학(statistics): 어떤 결론을 도출해내기 위해 자료를 수집하고, 정리·요약하는 방법을 연구하는 학문.
- 통계학 분류:

개요

- 통계학(statistics): 어떤 결론을 도출해내기 위해 자료를 수집하고, 정리·요약하는 방법을 연구하는 학문.
- 통계학 분류:
  - 기술통계학(descriptive statistics): 주어진 자료로부터 어떤 추측을 하지 않고 단지 수집된 자료의 정리 및 요약 방법만을 다룸 - 도수분포표와 시각화(graph)를 사용하여 수집된 자료를 시각화하고 대푯값과 산포도를 수치 자료의 요약에 기술함.
    예) 실업률, 교통사고 건수, 농업 생산량의 통계, 어느 물품의 불량품의 수, 혈 액형 등 여러 분야에 관한 수많은 자료의 분석이나 시각화를 다루는 것.

개요

- 통계학(statistics): 어떤 결론을 도출해내기 위해 자료를 수집하고, 정리·요약하는 방법을 연구하는 학문.
- 통계학 분류:
  - 기술통계학(descriptive statistics): 주어진 자료로부터 어떤 추측을 하지 않고 단지 수집된 자료의 정리 및 요약 방법만을 다룸 - 도수분포표와 시각화(graph)를 사용하여 수집된 자료를 시각화하고 대푯값과 산포도를 수치 자료의 요약에 기술함.
    예) 실업률, 교통사고 건수, 농업 생산량의 통계, 어느 물품의 불량품의 수, 혈 액형 등 여러 분야에 관한 수많은 자료의 분석이나 시각화를 다루는 것.
  - 추측통계학(inductive statistics): 미래의 현상을 예측하고 추론(inference)하기 위하여 수학적 방법 및 기법을 발전시키고, 이용하는 데 관련된 과학적인 학문 분야. 특히, 확률론의 개념을 이용하여 관련된 이론을 발전시키고 있음.

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.
- 모수(parameter): 모집단의 특성을 나타내는 양적인 측도.

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.
- 모수(parameter): 모집단의 특성을 나타내는 양적인 측도.
- 통계량(statistic): 표본의 특성을 나타내는 양적인 측도.

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.
- 모수(parameter): 모집단의 특성을 나타내는 양적인 측도.
- 통계량(statistic): 표본의 특성을 나타내는 양적인 측도.

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.
- 모수(parameter): 모집단의 특성을 나타내는 양적인 측도.
- 통계량(statistic): 표본의 특성을 나타내는 양적인 측도.

예제

- 하루 100,000개의 반도체를 생산하는 공장에서 품질 관리를 위해 매일 반도체의 수명을 검사하였다. 이 경우 검사한 반도체는 다시 시장에 팔 수 없기 때문에 생산된 반도체를 모두 검사할 수 없으므로 1,000개만 뽑아서 검사하였다면,

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.
- 모수(parameter): 모집단의 특성을 나타내는 양적인 측도.
- 통계량(statistic): 표본의 특성을 나타내는 양적인 측도.

예제

- 하루 100,000개의 반도체를 생산하는 공장에서 품질 관리를 위해 매일 반도체의 수명을 검사하였다. 이 경우 검사한 반도체는 다시 시장에 팔 수 없기 때문에 생산된 반도체를 모두 검사할 수 없으므로 1,000개만 뽑아서 검사하였다면,
- 이 때의 모집단은 하루에 생산된 100,000개의 반도체의 수명이며,

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.
- 모수(parameter): 모집단의 특성을 나타내는 양적인 측도.
- 통계량(statistic): 표본의 특성을 나타내는 양적인 측도.

예제

- 하루 100,000개의 반도체를 생산하는 공장에서 품질 관리를 위해 매일 반도체의 수명을 검사하였다. 이 경우 검사한 반도체는 다시 시장에 팔 수 없기 때문에 생산된 반도체를 모두 검사할 수 없으므로 1,000개만 뽑아서 검사하였다면,
- 이 때의 모집단은 하루에 생산된 100,000개의 반도체의 수명이며,
- 추출된 1,000개의 반도체의 수명은 표본이 됨.

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.
- 모수(parameter): 모집단의 특성을 나타내는 양적인 측도.
- 통계량(statistic): 표본의 특성을 나타내는 양적인 측도.

예제

- 하루 100,000개의 반도체를 생산하는 공장에서 품질 관리를 위해 매일 반도체의 수명을 검사하였다. 이 경우 검사한 반도체는 다시 시장에 팔 수 없기 때문에 생산된 반도체를 모두 검사할 수 없으므로 1,000개만 뽑아서 검사하였다면,
- 이 때의 모집단은 하루에 생산된 100,000개의 반도체의 수명이며,
- 추출된 1,000개의 반도체의 수명은 표본이 됨.
- 모든 반도체의 불량률이 하나의 모수이고,

모집단과 표본

- 모집단(population): 연구 대상이 되는 집단의 모든 구성 원소들의 집합으로 볼 수 있으며, 관심 있는 연구 대상의 특성에 대한 모든 관측치(observation)들의 집합(set).
- 표본(sample): 모집단의 부분 집합.
- 모수(parameter): 모집단의 특성을 나타내는 양적인 측도.
- 통계량(statistic): 표본의 특성을 나타내는 양적인 측도.

예제

- 하루 100,000개의 반도체를 생산하는 공장에서 품질 관리를 위해 매일 반도체의 수명을 검사하였다. 이 경우 검사한 반도체는 다시 시장에 팔 수 없기 때문에 생산된 반도체를 모두 검사할 수 없으므로 1,000개만 뽑아서 검사하였다면,
- 이 때의 모집단은 하루에 생산된 100,000개의 반도체의 수명이며,
- 추출된 1,000개의 반도체의 수명은 표본이 됨.
- 모든 반도체의 불량률이 하나의 모수이고,
- 모든 반도체 중에서 100,000개를 뽑아 조사를 했을 경우 10,000개에 있어서의 불량률은 하나의 통계량이 됨.

모집단과 표본 - 계속

- 표본조사의 가장 큰 목적은 모수가 모집단의 특성을 이해하는 데 커다란 도움을 주기 때문에 표본을 통해서 이러한 모수의 값을 추정(estimate)하려는 것이다. 즉, 표본 을 추출할 때는 표본 자체에 관심이 있는 것이 아니라 모집단의 여러 가지 특성에 관심이 있는 것이다. 따라서, 표본을 추출할 때는 모집단의 특성을 잘 대표할 수 있도록 주의하여야 함.

모집단과 표본 - 계속

- 표본조사의 가장 큰 목적은 모수가 모집단의 특성을 이해하는 데 커다란 도움을 주기 때문에 표본을 통해서 이러한 모수의 값을 추정(estimate)하려는 것이다. 즉, 표본 을 추출할 때는 표본 자체에 관심이 있는 것이 아니라 모집단의 여러 가지 특성에 관심이 있는 것이다. 따라서, 표본을 추출할 때는 모집단의 특성을 잘 대표할 수 있도록 주의하여야 함.
- 변수(variable): 연구나 조사 대상의 특성치. 예) 혈액형, 어느 지점을 통과하는 자동차의 수, 1일 주식 거래량, 물가, 통근시간

모집단과 표본 - 계속

- 표본조사의 가장 큰 목적은 모수가 모집단의 특성을 이해하는 데 커다란 도움을 주기 때문에 표본을 통해서 이러한 모수의 값을 추정(estimate)하려는 것이다. 즉, 표본 을 추출할 때는 표본 자체에 관심이 있는 것이 아니라 모집단의 여러 가지 특성에 관심이 있는 것이다. 따라서, 표본을 추출할 때는 모집단의 특성을 잘 대표할 수 있도록 주의하여야 함.
- 변수(variable): 연구나 조사 대상의 특성치. 예) 혈액형, 어느 지점을 통과하는 자동차의 수, 1일 주식 거래량, 물가, 통근시간
- 변수의 분류:

모집단과 표본 - 계속

- 표본조사의 가장 큰 목적은 모수가 모집단의 특성을 이해하는 데 커다란 도움을 주기 때문에 표본을 통해서 이러한 모수의 값을 추정(estimate)하려는 것이다. 즉, 표본 을 추출할 때는 표본 자체에 관심이 있는 것이 아니라 모집단의 여러 가지 특성에 관심이 있는 것이다. 따라서, 표본을 추출할 때는 모집단의 특성을 잘 대표할 수 있도록 주의하여야 함.
- 변수(variable): 연구나 조사 대상의 특성치. 예) 혈액형, 어느 지점을 통과하는 자동차의 수, 1일 주식 거래량, 물가, 통근시간
- 변수의 분류:
  - 질적 변수: 양을 나타내는 숫자가 아닌 범주나 문자로써 나타낼 수 있는 변수. 질적 변 수도 숫자로 바꾸어 사용하면 편리할 때가 많음. 즉, 남자 1, 여자 0이라는 값을 대응시켜 주면 양적 변수로 바뀜. 예) 성별, 선호도(좋다, 싫다), 지역(서울, 부산, 대구, 광주 등) 등.

모집단과 표본 - 계속

- 표본조사의 가장 큰 목적은 모수가 모집단의 특성을 이해하는 데 커다란 도움을 주기 때문에 표본을 통해서 이러한 모수의 값을 추정(estimate)하려는 것이다. 즉, 표본 을 추출할 때는 표본 자체에 관심이 있는 것이 아니라 모집단의 여러 가지 특성에 관심이 있는 것이다. 따라서, 표본을 추출할 때는 모집단의 특성을 잘 대표할 수 있도록 주의하여야 함.
- 변수(variable): 연구나 조사 대상의 특성치. 예) 혈액형, 어느 지점을 통과하는 자동차의 수, 1일 주식 거래량, 물가, 통근시간
- 변수의 분류:
  - 질적 변수: 양을 나타내는 숫자가 아닌 범주나 문자로써 나타낼 수 있는 변수. 질적 변 수도 숫자로 바꾸어 사용하면 편리할 때가 많음. 즉, 남자 1, 여자 0이라는 값을 대응시켜 주면 양적 변수로 바뀜. 예) 성별, 선호도(좋다, 싫다), 지역(서울, 부산, 대구, 광주 등) 등.
  - 양적 변수: 수량, 즉 숫자의 크기로 나타낼 수 있는 변수. 예) 변수가 어떤 실수 구간 내에 임의의 모든 수치를 나타낼 경우 연속변수라 함: 무게, 높이, 시간 등. 모든 변수가 주어진 구간 내의 특정한 수치만을 나타내고 있을 때 이산 변수라 함: 사람의 수, 불량품의 개수, 한 시간 동안 걸려오는 전화 통화 수 등.

- 자료의 시각적 표현 방법들 중 가장 일반적인 것은 점도표, 막대그래프, 히스토그램, 그리고 줄기잎그림임.

도수분포표

- 자료의 시각적 표현 방법들 중 가장 일반적인 것은 점도표, 막대그래프, 히스토그램, 그리고 줄기잎그림임.
- 모든 시각화 표현에서 그래프가 나타내는 것이 무엇인가를 확실하게 해주는 변수를 정확히 표기하는 것이 중요함.

도수분포표

- 자료의 시각적 표현 방법들 중 가장 일반적인 것은 점도표, 막대그래프, 히스토그램, 그리고 줄기잎그림임.
- 모든 시각화 표현에서 그래프가 나타내는 것이 무엇인가를 확실하게 해주는 변수를 정확히 표기하는 것이 중요함.

도수분포표

- 데이터가 명목형이나 순서형인 경우에 하나의 변수에 대해서 도수분포표 (frequency table)를 작성할 수 있음. 이 때 각 범주에 해당하는 관측치의 개수를 세어 범주의 도 수(빈도)로 놓음.

- 자료의 시각적 표현 방법들 중 가장 일반적인 것은 점도표, 막대그래프, 히스토그램, 그리고 줄기잎그림임.
- 모든 시각화 표현에서 그래프가 나타내는 것이 무엇인가를 확실하게 해주는 변수를 정확히 표기하는 것이 중요함.

도수분포표

- 데이터가 명목형이나 순서형인 경우에 하나의 변수에 대해서 도수분포표 (frequency table)를 작성할 수 있음. 이 때 각 범주에 해당하는 관측치의 개수를 세어 범주의 도 수(빈도)로 놓음.
- 도수분포표에는 흔히 상대도수나 누적상대도수가 같이 쓰임. 상대도수는 각 구간의 도수를 자료의 총수로 나눈 값이고, 누적상대도수는 이의 누계임. 장점으로 각 범주의 도수와 상대적인 비율을 쉽게 비교할 수 있음.

예제 2.1

어느 대학에서 통계학 수업을 수강하는 55명의 학생들을 대상으로 혈액형을 조사한 결과는 다음 과 같다. 이 자료를 도수분포표로 작성하라.
B B B B B A AB O O B B B B B O A AB B B B A AB A B O B A A A B O A O AB A A O A A A A AB A A AB A O AB B A O A B O A

예제 2.1

어느 대학에서 통계학 수업을 수강하는 55명의 학생들을 대상으로 혈액형을 조사한 결과는 다음 과 같다. 이 자료를 도수분포표로 작성하라.
B B B B B A AB O O B B B B B O A AB B B B A AB A B O B A A A B O A O AB A A O A A A A AB A A AB A O AB B A O A B O A

풀이

Table : <표 2.1>혈액형에 대한 도수분포표

범주	도수	상대도수(%)
A	20	36
AB	7	13
B	18	33
O	10	18

막대그래프, 원그래프

범주 또는 그룹들의 크기를 비교하는 일반적인 시각적 표현이며 다음과 같이 나열 할 수 있음.

- 원그래프 : 상대적인 빈도 또는 상대적인 비율을 원모양 파이의 분할 부분으로 나 타낸 그림

장점

막대그래프, 원그래프

범주 또는 그룹들의 크기를 비교하는 일반적인 시각적 표현이며 다음과 같이 나열 할 수 있음.

- 원그래프 : 상대적인 빈도 또는 상대적인 비율을 원모양 파이의 분할 부분으로 나 타낸 그림
- 막대그래프 : 각 범주에 대응하는 도수 또는 상대도수 등을 같은 폭의 수직막대로 나타낸 그림

장점

막대그래프, 원그래프

범주 또는 그룹들의 크기를 비교하는 일반적인 시각적 표현이며 다음과 같이 나열 할 수 있음.

- 원그래프 : 상대적인 빈도 또는 상대적인 비율을 원모양 파이의 분할 부분으로 나 타낸 그림
- 막대그래프 : 각 범주에 대응하는 도수 또는 상대도수 등을 같은 폭의 수직막대로 나타낸 그림
- 파레토 그림(Pareto chart) : 각 범주의 도수가 감소하도록 범주를 재배열한 막대그 래프

장점

막대그래프, 원그래프

범주 또는 그룹들의 크기를 비교하는 일반적인 시각적 표현이며 다음과 같이 나열 할 수 있음.

- 원그래프 : 상대적인 빈도 또는 상대적인 비율을 원모양 파이의 분할 부분으로 나 타낸 그림
- 막대그래프 : 각 범주에 대응하는 도수 또는 상대도수 등을 같은 폭의 수직막대로 나타낸 그림
- 파레토 그림(Pareto chart) : 각 범주의 도수가 감소하도록 범주를 재배열한 막대그 래프

장점

- 각 범주에 대한 도수분포표에 비하여 각 범주의 도수 또는 상대도수를 시각적으로 쉽게 비교 할 수 있음

예제 2.2

다음 자료는 어느 신도시의 스마트폰의 종류(A, B, C) 표본 조사 결과이다. 문자 A, B, C는 세 가지 범주를 나타낸다.
A B B A C B C C C A C B C A C C B C C A A B C C B C B A C A
도수분포표와 막대그래프, 원그래프로 시각화하시오.

필요한 파이썬 툴

- Series 클래스: 넘파이에서 제공하는 1차원 배열과 비슷하지만 각 데이터의 의미를 표시하는 인덱스(index)를 붙일 수 있음. 데이터 자체는 값(value)이라고 함. 배포된 파이썬편 pdf 파일 p.112 참고

예제 2.2

다음 자료는 어느 신도시의 스마트폰의 종류(A, B, C) 표본 조사 결과이다. 문자 A, B, C는 세 가지 범주를 나타낸다.
A B B A C B C C C A C B C A C C B C C A A B C C B C B A C A
도수분포표와 막대그래프, 원그래프로 시각화하시오.

필요한 파이썬 툴

- Series 클래스: 넘파이에서 제공하는 1차원 배열과 비슷하지만 각 데이터의 의미를 표시하는 인덱스(index)를 붙일 수 있음. 데이터 자체는 값(value)이라고 함. 배포된 파이썬편 pdf 파일 p.112 참고
- value_counts() : 시리즈의 값이 정수, 문자열, 카테고리 값인 경우에는 value_counts 메서드로 각각의 값이 나온 횟수를 셀 수 있음. 배포된 파이썬편 pdf 파일 p.133 참고

예제 2.2

다음 자료는 어느 신도시의 스마트폰의 종류(A, B, C) 표본 조사 결과이다. 문자 A, B, C는 세 가지 범주를 나타낸다.
A B B A C B C C C A C B C A C C B C C A A B C C B C B A C A
도수분포표와 막대그래프, 원그래프로 시각화하시오.

필요한 파이썬 툴

- Series 클래스: 넘파이에서 제공하는 1차원 배열과 비슷하지만 각 데이터의 의미를 표시하는 인덱스(index)를 붙일 수 있음. 데이터 자체는 값(value)이라고 함. 배포된 파이썬편 pdf 파일 p.112 참고
- value_counts() : 시리즈의 값이 정수, 문자열, 카테고리 값인 경우에는 value_counts 메서드로 각각의 값이 나온 횟수를 셀 수 있음. 배포된 파이썬편 pdf 파일 p.133 참고
- countplot() : 각 카테고리 값별로 데이터가 얼마나 있는지 표시할 수 있으며 countplot 명령은 데이터프레임에만 사용 가능. 배포된 파이썬편 pdf 파일 p.202 참고

풀이

- (막대그래프를 위한 파이썬 코드)

```
In [1]: import pandas as pd

In [2]: smartphone = ['A', 'B', 'B', 'A', 'C', 'B', 'C', 'C', 'C', 'A', 'C',  'B', 'C','A', 'C', 'C',  'B', 'C', 'C', 'A', 'A',  'B', 'C', 'C',  'B', 'C',
'B', 'A', 'C', 'A']

In [3]: pd.Series(smartphone).value_counts()
Out[3]:
C    14
A     8
B     8
dtype: int64

In [4]: import seaborn as sns

In [5]: sns.countplot(smartphone)
Out[5]: <matplotlib.axes._subplots.AxesSubplot at 0x22d75d43430>
```

풀이 - 계속

- (막대그래프)

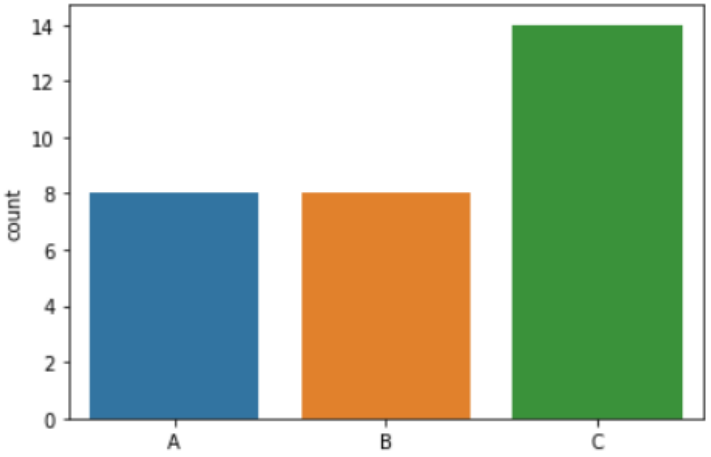

풀이 - 계속

- (원 그래프를 위한 파이썬 코드)

풀이 - 계속

- (원 그래프를 위한 파이썬 코드)
- pie() : 카테고리 별 값의 상대적인 비교를 해야 할 때는 pie 명령으로 파이 차트 (pie chart)를 그릴 수 있음. 배포된 파이썬편 pdf 파일 p.190 참고

```
In [1]: import pandas as pd
   ...: import matplotlib.pyplot as plt
   ...: import seaborn as sns

In [2]: smartphone = ['A', 'B', 'B', 'A', 'C', 'B', 'C', 'C', 'C', 'A', 'C', 'B', 'C', 'A', 'C', 'C', 'B', 'C', 'C', 'A', 'A', 'B', 'C', 'C', 'B', 'C',
'B', 'A', 'C', 'A']

In [3]: count = pd.Series(smartphone).value_counts()

In [4]: plt.pie(x=count, labels=count.index, autopct='%.1f%%', shadow=True)
Out[4]:
([<matplotlib.patches.Wedge at 0x19e4592f160>,
  <matplotlib.patches.Wedge at 0x19e4592f850>,
  <matplotlib.patches.Wedge at 0x19e45947160>],
 [Text(0.11498130276606913, 1.0939740856227893, 'C'),
  Text(-0.8899186574910393, -0.6465638275138399, 'A'),
  Text(0.7360437843500347, -0.8174592023579401, 'B')],
 [Text(0.0627170742360377, 0.5967131376124304, '46.7%'),
  Text(-0.48541017681329407, -0.3526711786439127, '26.7%'),
  Text(0.4014784278272916, -0.4458868376497855, '26.7%')])

Figures now render in the Plots pane by default. To make them also appear inline in the Console, uncheck "Mute Inline Plotting" under the Plots pane
options menu.
```

풀이 - 계속

- 원그래프(Pie Chart)

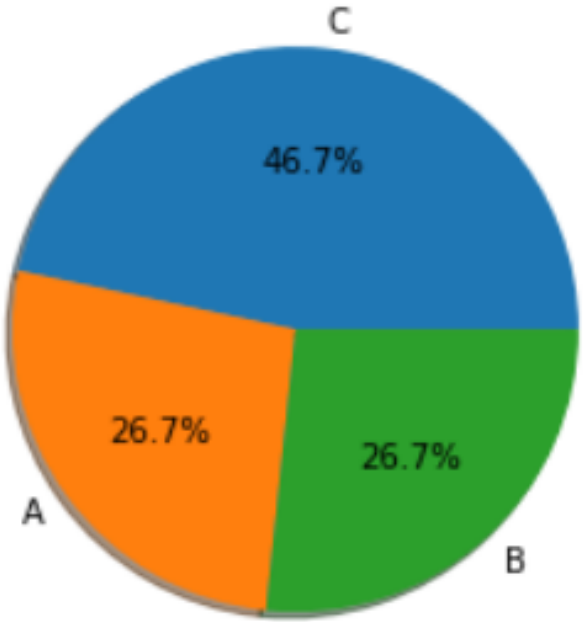

히스토그램

- 계급구간과 막대의 높이가 주어짐으로써 그릴 수 있는데, 막대의 높이는 상대도수를 계급구간의 폭으로 나눔으로써 구할 수 있음. 이렇게 구한 히스토그램의 전체 면적은 1이 됨.

장점과 단점

히스토그램

- 계급구간과 막대의 높이가 주어짐으로써 그릴 수 있는데, 막대의 높이는 상대도수를 계급구간의 폭으로 나눔으로써 구할 수 있음. 이렇게 구한 히스토그램의 전체 면적은 1이 됨.
- 모든 계급구간의 폭이 같으면 도수 또는 상대도수를 막대의 높이로 사용하여 그린 그림과 히스토그램은 같은 모양이 됨. 따라서 도수나 상대도수를 막대의 높이로 사용하여 히스토그램의 모양을 얻기도 함.

장점과 단점

히스토그램

- 계급구간과 막대의 높이가 주어짐으로써 그릴 수 있는데, 막대의 높이는 상대도수를 계급구간의 폭으로 나눔으로써 구할 수 있음. 이렇게 구한 히스토그램의 전체 면적은 1이 됨.
- 모든 계급구간의 폭이 같으면 도수 또는 상대도수를 막대의 높이로 사용하여 그린 그림과 히스토그램은 같은 모양이 됨. 따라서 도수나 상대도수를 막대의 높이로 사용하여 히스토그램의 모양을 얻기도 함.

장점과 단점

- 장점: 도수분포표에 비하여 보다 더 시각적으로 중심의 위치와 자료가 어떠한 모양으로 흩어져 있는가에 대하여 쉽게 파악할 수 있음.

히스토그램

- 계급구간과 막대의 높이가 주어짐으로써 그릴 수 있는데, 막대의 높이는 상대도수를 계급구간의 폭으로 나눔으로써 구할 수 있음. 이렇게 구한 히스토그램의 전체 면적은 1이 됨.
- 모든 계급구간의 폭이 같으면 도수 또는 상대도수를 막대의 높이로 사용하여 그린 그림과 히스토그램은 같은 모양이 됨. 따라서 도수나 상대도수를 막대의 높이로 사용하여 히스토그램의 모양을 얻기도 함.

장점과 단점

- 장점: 도수분포표에 비하여 보다 더 시각적으로 중심의 위치와 자료가 어떠한 모양으로 흩어져 있는가에 대하여 쉽게 파악할 수 있음.
- 단점: 각 계급 안에 놓이는 자료의 정확한 측정값을 알 수 없음.

예제 2.3

조그만 도시에 2,000가구들이 살고, 그들의 자녀의 분포는 다음과 같다. 300가구는 자녀가 없 고, 400가구는 한 명, 700가구는 두 명, 300가구는 세 명, 100가구는 네 명, 100가구는 다섯 명, 그리고 100가구는 여섯 명이 있다고 가정하자. 이 자료들은 히스토그램으로 나타내어라.

예제 2.3

조그만 도시에 2,000가구들이 살고, 그들의 자녀의 분포는 다음과 같다. 300가구는 자녀가 없 고, 400가구는 한 명, 700가구는 두 명, 300가구는 세 명, 100가구는 네 명, 100가구는 다섯 명, 그리고 100가구는 여섯 명이 있다고 가정하자. 이 자료들은 히스토그램으로 나타내어라.

풀이

Table : <표 2.3> 자녀 수에 대한 도수분포표

자녀 수	도수	상대도수
0	300	300/2000=.15
1	400	400/2000=.20
2	700	700/2000=.35
3	300	300/2000=.15
4	100	100/2000=.05
5	100	100/2000=.05
6	100	100/2000=.05

풀이 - 계속

- (히스토그램)

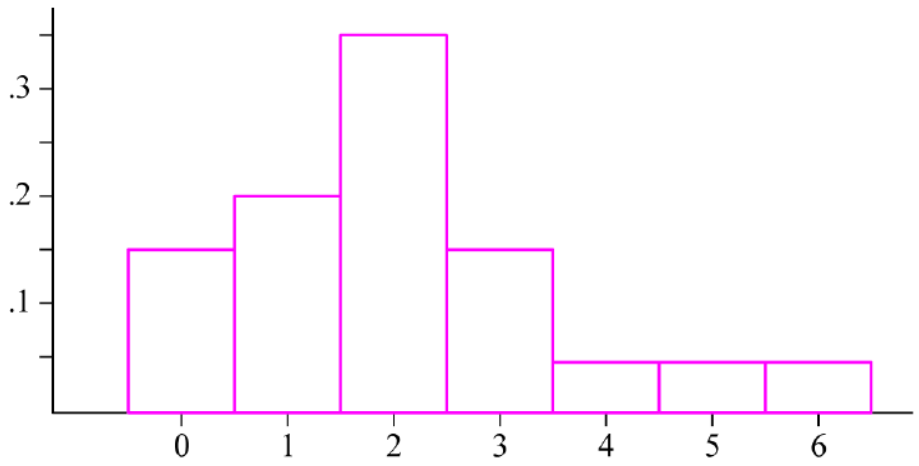

[그림 2.2] 자녀 수에 대한 히스토그램

집단화 자료의 도수분포표

- 양적자료를 적당한 크기로 집단화하여 좀 더 쉽게 이해하도록 적당한 간격으로 집단화하여 만든 도수분포표

용어 설명

집단화 자료의 도수분포표

- 양적자료를 적당한 크기로 집단화하여 좀 더 쉽게 이해하도록 적당한 간격으로 집단화하여 만든 도수분포표
- 장점: 누적상대도수 즉, 분포함수 $F(x) = 0.5$가 되는 대략적인 중심의 위치를 알 수 있음. 대략 적인 자료의 흩어진 정도를 파악할 수 있음.

용어 설명

집단화 자료의 도수분포표

- 양적자료를 적당한 크기로 집단화하여 좀 더 쉽게 이해하도록 적당한 간격으로 집단화하여 만든 도수분포표
- 장점: 누적상대도수 즉, 분포함수 $F(x) = 0.5$가 되는 대략적인 중심의 위치를 알 수 있음. 대략 적인 자료의 흩어진 정도를 파악할 수 있음.
- 원자료의 정확한 관찰값을 알 수 없음.

용어 설명

집단화 자료의 도수분포표

- 양적자료를 적당한 크기로 집단화하여 좀 더 쉽게 이해하도록 적당한 간격으로 집단화하여 만든 도수분포표
- 장점: 누적상대도수 즉, 분포함수 $F(x) = 0.5$가 되는 대략적인 중심의 위치를 알 수 있음. 대략 적인 자료의 흩어진 정도를 파악할 수 있음.
- 원자료의 정확한 관찰값을 알 수 없음.

용어 설명

- 계급(class) : 적당한 간격으로 집단화하여 나타낸 범주들

집단화 자료의 도수분포표

- 양적자료를 적당한 크기로 집단화하여 좀 더 쉽게 이해하도록 적당한 간격으로 집단화하여 만든 도수분포표
- 장점: 누적상대도수 즉, 분포함수 $F(x) = 0.5$가 되는 대략적인 중심의 위치를 알 수 있음. 대략 적인 자료의 흩어진 정도를 파악할 수 있음.
- 원자료의 정확한 관찰값을 알 수 없음.

용어 설명

- 계급(class) : 적당한 간격으로 집단화하여 나타낸 범주들
- 계급간격(class width) : 이웃하는 두 계급의 위쪽 경계에서 아래쪽 경계를 뺀 값

집단화 자료의 도수분포표

- 양적자료를 적당한 크기로 집단화하여 좀 더 쉽게 이해하도록 적당한 간격으로 집단화하여 만든 도수분포표
- 장점: 누적상대도수 즉, 분포함수 $F(x) = 0.5$가 되는 대략적인 중심의 위치를 알 수 있음. 대략 적인 자료의 흩어진 정도를 파악할 수 있음.
- 원자료의 정확한 관찰값을 알 수 없음.

용어 설명

- 계급(class) : 적당한 간격으로 집단화하여 나타낸 범주들
- 계급간격(class width) : 이웃하는 두 계급의 위쪽 경계에서 아래쪽 경계를 뺀 값
- 계급값(class mark) : 각 계급의 중앙에 위치한 값, $\frac{\text{위쪽 경계} + \text{아래쪽 경계}}{2}$

도수분포표의 작성

1. 표본자료의 최대값과 최소값을 찾아 (범위) = (최대값) - (최소값)을 구함

도수분포표의 작성

1. 표본자료의 최대값과 최소값을 찾아 (범위) = (최대값) - (최소값)을 구함
2. 자료의 크기에 따라 5 20정도의 계급의 개수를 정하고, 계급의 폭은

$$(\text{범위})/(\text{계급의 개수})$$

를 계산하여 자료값의 최소 단위까지 끊어 올려 정한다.

도수분포표의 작성

1. 표본자료의 최대값과 최소값을 찾아 (범위) = (최대값) - (최소값)을 구함
2. 자료의 크기에 따라 5 20정도의 계급의 개수를 정하고, 계급의 폭은

$$(\text{범위})/(\text{계급의 개수})$$

   를 계산하여 자료값의 최소 단위까지 끊어 올려 정한다.
3. 첫 번째 계급의 시작점은

$$(\text{최소값}) - \frac{1}{2}(\text{자료값의 최소 단위})$$

   로 정하여, 2에서 구한 계급의 폭에 따라 그 다음 계급을 정함

도수분포표의 작성

1. 표본자료의 최대값과 최소값을 찾아 (범위) = (최대값) - (최소값)을 구함
2. 자료의 크기에 따라 5 20정도의 계급의 개수를 정하고, 계급의 폭은

   (범위)/(계급의 개수)

   를 계산하여 자료값의 최소 단위까지 끊어 올려 정한다.
3. 첫 번째 계급의 시작점은

   (최소값) - $\frac{1}{2}$(자료값의 최소 단위)

   로 정하여, 2에서 구한 계급의 폭에 따라 그 다음 계급을 정함
4. 각 계급의 상대도수(또는 도수)를 구함

줄기-잎 그림

도수분포표나 히스토그램이 갖고 있는 성질을 그대로 보존하면서 각 계급 안에 들어 있는 개개의 측정값을 제공하는 그림.

줄기-잎 그림 작성 방법

1. 줄기와 잎을 구분한다. 변동이 작은 부분을 줄기, 변동이 많은 부분을 잎으로 지정 함

줄기-잎 그림

도수분포표나 히스토그램이 갖고 있는 성질을 그대로 보존하면서 각 계급 안에 들어 있는 개개의 측정값을 제공하는 그림.

줄기-잎 그림 작성 방법

1. 줄기와 잎을 구분한다. 변동이 작은 부분을 줄기, 변동이 많은 부분을 잎으로 지정 함
2. 줄기 부분을 작은 수부터 순차적으로 나열하고, 잎 부분을 원자료의 관찰 순서대로 나열함

줄기-잎 그림

도수분포표나 히스토그램이 갖고 있는 성질을 그대로 보존하면서 각 계급 안에 들어 있는 개개의 측정값을 제공하는 그림.

줄기-잎 그림 작성 방법

1. 줄기와 잎을 구분한다. 변동이 작은 부분을 줄기, 변동이 많은 부분을 잎으로 지정 함
2. 줄기 부분을 작은 수부터 순차적으로 나열하고, 잎 부분을 원자료의 관찰 순서대로 나열함
3. 잎 부분의 관찰값을 순서대로 나열함

예제 2.5

농구선수의 13년 경력 동안 3점 슛의 퍼센트를 나타낸 집합인 17, 17, 18, 13, 28, 38, 31, 27, 35, 50, 43, 37, 24를 보자. 1, 2, 3, 4, 5를 10, 20, 30, 40, 50로 대체해보자. 그 결과 는 이 자료들의 줄기 도표로 나타내어라.

예제 2.5

농구선수의 13년 경력 동안 3점 슛의 퍼센트를 나타낸 집합인 17, 17, 18, 13, 28, 38, 31, 27, 35, 50, 43, 37, 24를 보자. 1, 2, 3, 4, 5를 10, 20, 30, 40, 50로 대체해보자. 그 결과 는 이 자료들의 줄기 도표로 나타내어라.

풀이

- (줄기-잎 그림)

```
1 | 3 7 7 8
2 | 4 7 8
3 | 1 5 7 8
4 | 3
5 | 0

Key:
 Stem multiplier: 10
 X | Y  =>  10*X+Y
```

풀이 - 계속

- (파이썬 코드) 관심있는 학생은 분석해 보시기 바람. 출처: Rosetta Code

```
from collections import namedtuple
from pprint import pprint as pp
from math import floor

Stem = namedtuple('Stem', 'data, leafdigits')

data0 = Stem((17,17,18,13, 28 , 38 , 31 , 27, 35, 50 ,43 , 37 , 24),  1.0)

def stemplot(stem):
    d = []
    interval = int(10**int(stem.leafdigits))
    for data in sorted(stem.data):
        data = int(floor(data))
        stm, lf = divmod(data,interval)
        d.append( (int(stm), int(lf)) )
    stems, leafs = list(zip(*d))
    stemwidth = max(len(str(x)) for x in stems)
    leafwidth = max(len(str(x)) for x in leafs)
    laststem, out = min(stems) - 1, []
    for s,l in d:
        while laststem < s:
            laststem += 1
            out.append('\n%*i |' % ( stemwidth, laststem))
        out.append(' %0*i' % (leafwidth, l))
    out.append('\n\nKey:\n Stem multiplier: %i\n X | Y  =>  %i*X+Y\n'
               % (interval, interval))
    return ''.join(out)

if __name__ == '__main__':
    print( stemplot(data0) )
```