1 2.2 수치를 통한 자료 요약

2.2.1 평균값과 중앙값

평균값

- 집합의 모든 항목들의 합계를 항목들의 수로 나눈 값

모평균(population mean)

표본평균(sample mean)

2.2.1 평균값과 중앙값

평균값

- 집합의 모든 항목들의 합계를 항목들의 수로 나눈 값
- 전체 모집합의 평균값은 자주 그리스 문자 μ (mu)로 표기되고, 표본의 평균값은 $\bar{x}$로 자주 표기됨

모평균(population mean)

표본평균(sample mean)

2.2.1 평균값과 중앙값

평균값

- 집합의 모든 항목들의 합계를 항목들의 수로 나눈 값
- 전체 모집합의 평균값은 자주 그리스 문자 μ (mu)로 표기되고, 표본의 평균값은 $\bar{x}$로 자주 표기됨

모평균(population mean)

- $$\text{모집단의 평균: } \mu = \frac{1}{N}\sum_{i=1}^{N} x_i$$

표본평균(sample mean)

2.2.1 평균값과 중앙값

평균값

- 집합의 모든 항목들의 합계를 항목들의 수로 나눈 값
- 전체 모집합의 평균값은 자주 그리스 문자 μ (mu)로 표기되고, 표본의 평균값은 $\bar{x}$로 자주 표기됨

모평균(population mean)

- $$\text{모집단의 평균: } \mu = \frac{1}{N}\sum_{i=1}^{N} x_i$$

표본평균(sample mean)

- $$\text{표본의 평균: } \mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

2.2.1 평균값과 중앙값 - 계속

표본평균의 특성 - 장점

- 계산하기 쉽다.

표본평균의 특성 - 단점

예제 2.7

2.2.1 평균값과 중앙값 - 계속

표본평균의 특성 - 장점

- 계산하기 쉽다.
- 모든 측정값을 반영한 정보를 제공한다.

표본평균의 특성 - 단점

예제 2.7

2.2.1 평균값과 중앙값 - 계속

표본평균의 특성 - 장점

- 계산하기 쉽다.
- 모든 측정값을 반영한 정보를 제공한다.
- 각 자료와 평균과의 편차의 제곱을 모두 더한 잔차제곱합(residual sum of squares, RSS)이 다른 유형의 위치척도에 비하여 작다.

표본평균의 특성 - 단점

예제 2.7

2.2.1 평균값과 중앙값 - 계속

표본평균의 특성 - 장점

- 계산하기 쉽다.
- 모든 측정값을 반영한 정보를 제공한다.
- 각 자료와 평균과의 편차의 제곱을 모두 더한 잔차제곱합(residual sum of squares, RSS)이 다른 유형의 위치척도에 비하여 작다.

표본평균의 특성 - 단점

- 이상점에 큰 영향을 받는다.

예제 2.7

2.2.1 평균값과 중앙값 - 계속

표본평균의 특성 - 장점

- 계산하기 쉽다.
- 모든 측정값을 반영한 정보를 제공한다.
- 각 자료와 평균과의 편차의 제곱을 모두 더한 잔차제곱합(residual sum of squares, RSS)이 다른 유형의 위치척도에 비하여 작다.

표본평균의 특성 - 단점

- 이상점에 큰 영향을 받는다.

예제 2.7

- 13개의 야구장에서 필드의 중심까지의 홈런 거리의 집합을 살펴보자. $\{387, 400, 400, 410, 410, 410, 414, 415, 420, 420, 421, 457, 461\}$ 평균값은 얼마인가?

2.2.1 평균값과 중앙값 - 계속

표본평균의 특성 - 장점

- 계산하기 쉽다.
- 모든 측정값을 반영한 정보를 제공한다.
- 각 자료와 평균과의 편차의 제곱을 모두 더한 잔차제곱합(residual sum of squares, RSS)이 다른 유형의 위치척도에 비하여 작다.

표본평균의 특성 - 단점

- 이상점에 큰 영향을 받는다.

예제 2.7

- 13개의 야구장에서 필드의 중심까지의 홈런 거리의 집합을 살펴보자. $\{387, 400, 400, 410, 410, 410, 414, 415, 420, 420, 421, 457, 461\}$ 평균값은 얼마인가?
- (풀이) 평균값은

$$\frac{387 + 400 + 400 + 410 + 410 + \cdots + 457 + 461}{13} = 417.3 \ feet$$

2.2.1 평균값과 중앙값 - 계속

중앙값

- 표본평균이 갖는 이상점에 대한 영향을 제거할 수 있는 중심위치의 척도

중앙값의 장점과 단점

2.2.1 평균값과 중앙값 - 계속

중앙값

- 표본평균이 갖는 이상점에 대한 영향을 제거할 수 있는 중심위치의 척도
- 자료의 측정값을 크기 순서로 나열하여 가장 가운데 순위에 놓이는 값. 즉,

$$M_e = \begin{cases} x_{[\frac{n+1}{2}]}, & n\text{이 홀수인 경우} \\ \frac{x_{[\frac{n}{2}]}+x_{[\frac{n}{2}]+1}}{2}, & n\text{이 짝수인 경우} \end{cases}$$

단, $x_{(i)}$는 순서통계량이다.

중앙값의 장점과 단점

2.2.1 평균값과 중앙값 - 계속

중앙값

- 표본평균이 갖는 이상점에 대한 영향을 제거할 수 있는 중심위치의 척도
- 자료의 측정값을 크기 순서로 나열하여 가장 가운데 순위에 놓이는 값. 즉,

$$M_e = \begin{cases} x_{[\frac{n+1}{2}]}, & n\text{이 홀수인 경우} \\ \frac{x_{[\frac{n}{2}]}+x_{[\frac{n}{2}]+1}}{2}, & n\text{이 짝수인 경우} \end{cases}$$

단, $x_{(i)}$는 순서통계량이다.

중앙값의 장점과 단점

- (장점) 어느 한 쪽으로 치우친 분포를 갖는 자료에 대하여 평균보다 좋은 중심의 위치를 나타냄

2.2.1 평균값과 중앙값 - 계속

중앙값

- 표본평균이 갖는 이상점에 대한 영향을 제거할 수 있는 중심위치의 척도
- 자료의 측정값을 크기 순서로 나열하여 가장 가운데 순위에 놓이는 값. 즉,

$$M_e = \begin{cases} x_{[\frac{n+1}{2}]}, & n\text{이 홀수인 경우} \\ \frac{x_{[\frac{n}{2}]}+x_{[\frac{n}{2}]+1}}{2}, & n\text{이 짝수인 경우} \end{cases}$$

단, $x_{(i)}$는 순서통계량이다.

중앙값의 장점과 단점

- (장점) 어느 한 쪽으로 치우친 분포를 갖는 자료에 대하여 평균보다 좋은 중심의 위치를 나타냄
- (단점)전체 자료를 크기 순으로 나열하여 중앙에 놓이는 자료를 찾아야 한다는 점에서 자료의 수가 많은 경우에 부적절함

2.2.1 평균값과 중앙값 - 계속

중앙값

- 표본평균이 갖는 이상점에 대한 영향을 제거할 수 있는 중심위치의 척도
- 자료의 측정값을 크기 순서로 나열하여 가장 가운데 순위에 놓이는 값. 즉,

$$M_e = \begin{cases} x_{[\frac{n+1}{2}]}, & n\text{이 홀수인 경우} \\ \frac{x_{[\frac{n}{2}]}+x_{[\frac{n}{2}]+1}}{2}, & n\text{이 짝수인 경우} \end{cases}$$

단, $x_{(i)}$는 순서통계량이다.

중앙값의 장점과 단점

- (장점) 어느 한 쪽으로 치우친 분포를 갖는 자료에 대하여 평균보다 좋은 중심의 위치를 나타냄
- (단점)전체 자료를 크기 순으로 나열하여 중앙에 놓이는 자료를 찾아야 한다는 점에서 자료의 수가 많은 경우에 부적절함
- 수리적으로 다루기 매우 힘들다는 이유로 추측통계학에서 별로 사용하지 않음

2.2.1 평균값과 중앙값 - 계속

예제 2.8

한달 동안 다섯 명의 의사가 불필요한 수술을 제안한 수의 집합이

(1) $\{2, 2, 8, 20, 33\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

풀이

(1)과 (2) 모두 중앙값은 8이고 평균값은 아래와 같이 바뀜.

2.2.1 평균값과 중앙값 - 계속

예제 2.8

한달 동안 다섯 명의 의사가 불필요한 수술을 제안한 수의 집합이

(1) $\{2, 2, 8, 20, 33\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

(2) $\{2, 2, 8, 20, 58\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

풀이

(1)과 (2) 모두 중앙값은 8이고 평균값은 아래와 같이 바뀜.

2.2.1 평균값과 중앙값 - 계속

예제 2.8

한달 동안 다섯 명의 의사가 불필요한 수술을 제안한 수의 집합이

(1) $\{2, 2, 8, 20, 33\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

(2) $\{2, 2, 8, 20, 58\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

풀이

(1)과 (2) 모두 중앙값은 8이고 평균값은 아래와 같이 바뀜.

(1) 평균값은 $\frac{2+2+8+20+33}{5} = 13$ 임.

2.2.1 평균값과 중앙값 - 계속

예제 2.8

한달 동안 다섯 명의 의사가 불필요한 수술을 제안한 수의 집합이

(1) $\{2, 2, 8, 20, 33\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

(2) $\{2, 2, 8, 20, 58\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

풀이

(1)과 (2) 모두 중앙값은 8이고 평균값은 아래와 같이 바뀜.

(1) 평균값은 $\frac{2+2+8+20+33}{5} = 13$ 임.

(2) 평균값은 $\frac{2+2+8+20+58}{5} = 18$ 임.

2.2.1 평균값과 중앙값 - 계속

예제 2.8

한달 동안 다섯 명의 의사가 불필요한 수술을 제안한 수의 집합이

(1) $\{2, 2, 8, 20, 33\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

(2) $\{2, 2, 8, 20, 58\}$으로 주어졌다고 가정해보자. 중앙값과 평균을 구하여라.

풀이

(1)과 (2) 모두 중앙값은 8이고 평균값은 아래와 같이 바뀜.

(1) 평균값은 $\frac{2+2+8+20+33}{5} = 13$ 임.

(2) 평균값은 $\frac{2+2+8+20+58}{5} = 18$ 임.

- 수리적으로 다루기 매우 힘들다는 이유로 추측통계학에서 별로 사용하지 않음

2.2.1 평균값과 중앙값 - 계속

예제 2.8 - 계속

```
In [1]: import numpy as np

In [2]: x=np.array([2,2,8,20,33])

In [3]: np.sum(x) #합
Out[3]: 65

In [4]: x.sum() #합
Out[4]: 65

In [5]: x.min() #최소값
Out[5]: 2

In [6]: x.max() #최대값
Out[6]: 33

In [7]: x.argmin() # 최솟값의 위치(인덱스)
Out[7]: 0

In [8]: x.argmax() # 최댓값의 위치(인덱스)
Out[8]: 4

In [9]: x.mean() #평균
Out[9]: 13.0

In [10]: np.median(x) #중앙값
Out[10]: 8.0
```

2.2.2 범위, 백분위수, 사분위수 범위

범위

- 가장 간단하고 쉽게 변이성을 계산하는 척도

예제 2.9

2.2.2 범위, 백분위수, 사분위수 범위

범위

- 가장 간단하고 쉽게 변이성을 계산하는 척도
- 가장 큰 값과 가장 작은 값의 차이

예제 2.9

2.2.2 범위, 백분위수, 사분위수 범위

범위

- 가장 간단하고 쉽게 변이성을 계산하는 척도
- 가장 큰 값과 가장 작은 값의 차이
- 범위의 한 용도로는 아주 적은 항목들을 가진 표본에서 분포로 계산할 때 유용함

예제 2.9

2.2.2 범위, 백분위수, 사분위수 범위

범위

- 가장 간단하고 쉽게 변이성을 계산하는 척도
- 가장 큰 값과 가장 작은 값의 차이
- 범위의 한 용도로는 아주 적은 항목들을 가진 표본에서 분포로 계산할 때 유용함

예제 2.9

- 집단 A : 최대값 = 95, 최소값 = 20
  집단 B : 최대값 = 81, 최소값 = 55
  이라 가정하자. 각 집단의 범위를 구하고 설명하여라.

2.2.2 범위, 백분위수, 사분위수 범위

범위

- 가장 간단하고 쉽게 변이성을 계산하는 척도
- 가장 큰 값과 가장 작은 값의 차이
- 범위의 한 용도로는 아주 적은 항목들을 가진 표본에서 분포로 계산할 때 유용함

예제 2.9

- 집단 A : 최대값 = 95, 최소값 = 20
  집단 B : 최대값 = 81, 최소값 = 55
  이라 가정하자. 각 집단의 범위를 구하고 설명하여라.
- (풀이) $R_A = 95 - 20 = 75$ 이고 $R_B = 81 - 55 = 26$으로 집단 B에 비하여 집단 A가 폭넓게 분포되어 있음을 알 수 있음

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

백분위수(percentile)

- 자료 안에서 어떤 특정한 값의 상대적인 위치에 관심이 있는 경우에 백분위수나 z-점수(z-score)와 같은 상대적 위치의 측도가 필요함

제 $100 \times p$ 백분위수를 구하는 방법

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

백분위수(percentile)

- 자료 안에서 어떤 특정한 값의 상대적인 위치에 관심이 있는 경우에 백분위수나 z-점수(z-score)와 같은 상대적 위치의 측도가 필요함

제 $100 \times p$ 백분위수를 구하는 방법

1. 관측값을 큰 순으로 배열한다.

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

백분위수(percentile)

- 자료 안에서 어떤 특정한 값의 상대적인 위치에 관심이 있는 경우에 백분위수나 z-점수(z-score)와 같은 상대적 위치의 측도가 필요함

제 $100 \times p$ 백분위수를 구하는 방법

1. 관측값을 큰 순으로 배열한다.
2. 관측값의 개수(n)에 p를 곱한다.

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

백분위수(percentile)

- 자료 안에서 어떤 특정한 값의 상대적인 위치에 관심이 있는 경우에 백분위수나 z-점수(z-score)와 같은 상대적 위치의 측도가 필요함

제 $100 \times p$ 백분위수를 구하는 방법

1. 관측값을 큰 순으로 배열한다.
2. 관측값의 개수(n)에 p를 곱한다.
   a. 만약 $n \times p$가 정수이면, $n \times p$ 번째 관측값과 $(n \times p) + 1$ 번째 관측값의 평균을 제 $100 \times p$ 백분위수로 한다.

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

백분위수(percentile)

- 자료 안에서 어떤 특정한 값의 상대적인 위치에 관심이 있는 경우에 백분위수나 z-점수(z-score)와 같은 상대적 위치의 측도가 필요함

제 $100 \times p$ 백분위수를 구하는 방법

1. 관측값을 큰 순으로 배열한다.
2. 관측값의 개수(n)에 p를 곱한다.
   a. 만약 $n \times p$가 정수이면, $n \times p$ 번째 관측값과 $(n \times p) + 1$ 번째 관측값의 평균을 제 $100 \times p$ 백분위수로 한다.
   b. 만약 $n \times p$가 정수가 아니면, $n \times p$의 정수부분에서 1을 더한 값 m을 구한 후, m번째 큰 관측값을 제 $100 \times p$ 백분위수로 한다.

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.9

서울의 한 전철역에서 수원의 한 전철역까지 소요되는 시간을 기록한 자료가 다음과 같다.(단위: 분)

42 40 38 37 43 39 78 38 45 44 40 38 41 35 31 44

제 50 백분위수인 중앙값과 제 30 백분위수를 구하여라.

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.9

서울의 한 전철역에서 수원의 한 전철역까지 소요되는 시간을 기록한 자료가 다음과 같다.(단위: 분)

42 40 38 37 43 39 78 38 45 44 40 38 41 35 31 44

제 50 백분위수인 중앙값과 제 30 백분위수를 구하여라.

풀이

위의 자료를 크기 순서로 재배열하면 다음과 같다.

31 35 37 38 38 38 39 40 40 41 42 43 44 44 45 78

- 관측값의 개수가 16이고 $16 \times 0.5 = 8$이므로 제 50 백분위수는 8번째 값과 9번째 값의 평균이 40이므로 제 50 백분위수인 중앙값은 40이다.

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.9

서울의 한 전철역에서 수원의 한 전철역까지 소요되는 시간을 기록한 자료가 다음과 같다.(단위: 분)

42 40 38 37 43 39 78 38 45 44 40 38 41 35 31 44

제 50 백분위수인 중앙값과 제 30 백분위수를 구하여라.

풀이

위의 자료를 크기 순서로 재배열하면 다음과 같다.

31 35 37 38 38 38 39 40 40 41 42 43 44 44 45 78

- 관측값의 개수가 16이고 $16 \times 0.5 = 8$이므로 제 50 백분위수는 8번째 값과 9번째 값의 평균이 40이므로 제 50 백분위수인 중앙값은 40이다.
- 제 30 백분위수의 경우는 $16 \times 0.3 = 4.8$이므로 제 30 백분위수의 값은 5번째 값인 38이다.

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.9 - 계속

```
In [1]: import numpy as np

In [2]: x=np.array([42, 40, 38, 37, 43, 39, 78, 38, 45, 44, 40, 38, 41, 35, 31, 44])

In [3]: p = np.percentile(x, 50) # return 50th percentile, e.g median.

In [4]: print(p)
40.0

In [5]: p = np.percentile(x, 30)

In [6]: print(p)
38.0
```

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

사분위수 범위

- 사분위수(quartile): 자료를 크기 순으로 나열했을 때 전체 자료가 4등분되는 위치의 관측값

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

사분위수 범위

- 사분위수(quartile): 자료를 크기 순으로 나열했을 때 전체 자료가 4등분되는 위치의 관측값
- 제일 작은 사분위수를 제1사분위수(Q_1), 두 번째로 작은 사분위수를 제2사분위수(Q_2), 다음 사분위수를 제3사분위수(Q_3)라 하며, 제2사분위수는 중앙값이 됨

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

사분위수 범위

- 사분위수(quartile): 자료를 크기 순으로 나열했을 때 전체 자료가 4등분되는 위치의 관측값
- 제일 작은 사분위수를 제1사분위수(Q_1), 두 번째로 작은 사분위수를 제2사분위수(Q_2), 다음 사분위수를 제3사분위수(Q_3)라 하며, 제2사분위수는 중앙값이 됨
- 사분위수 범위를 찾는 것은 범위에서 극값들의 영향을 받지 않기 위한 하나의 방법이다. 그것은 중간 50% 값들의 범위이다. 즉 $IQR = Q_3 - Q_1$으로 계산함

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

사분위수 범위

- 사분위수(quartile): 자료를 크기 순으로 나열했을 때 전체 자료가 4등분되는 위치의 관측값
- 제일 작은 사분위수를 제1사분위수(Q_1), 두 번째로 작은 사분위수를 제2사분위수(Q_2), 다음 사분위수를 제3사분위수(Q_3)라 하며, 제2사분위수는 중앙값이 됨
- 사분위수 범위를 찾는 것은 범위에서 극값들의 영향을 받지 않기 위한 하나의 방법이다. 그것은 중간 50% 값들의 범위이다. 즉 $IQR = Q_3 - Q_1$으로 계산함
- 이상치를 구하는 데 사용되는 수적 규칙으로, 만약 관측치가 $Q_1 - IQR \times 1.5$보다 작거나 $Q_3 + IQR \times 1.5$보다 클 때 이상치라 부름

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.10

한 작은 마을의 농장 크기가 다음과 같은 성질을 가지고 있다고 가정해보자. 가장 작은 값은 16.6에이커이고, 값의 25%는 41.1에이커, 75%는 101.9에이커, 90%는 124.0에이커, 가장 큰 값은 201.7에이커이다.

(1) 범위는 무엇인가?

풀이

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.10

한 작은 마을의 농장 크기가 다음과 같은 성질을 가지고 있다고 가정해보자. 가장 작은 값은 16.6에이커이고, 값의 25%는 41.1에이커, 75%는 101.9에이커, 90%는 124.0에이커, 가장 큰 값은 201.7에이커이다.

(1) 범위는 무엇인가?

(2) 사분위수 범위는 얼마인가?

풀이

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.10

한 작은 마을의 농장 크기가 다음과 같은 성질을 가지고 있다고 가정해보자. 가장 작은 값은 16.6에이커이고, 값의 25%는 41.1에이커, 75%는 101.9에이커, 90%는 124.0에이커, 가장 큰 값은 201.7에이커이다.

(1) 범위는 무엇인가?

(2) 사분위수 범위는 얼마인가?

(3) 수적 규칙이 이상치로 쓰였을 때, 가장 작은 또는 가장 큰 값을 이상치라 불러야 하는가?

풀이

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.10

한 작은 마을의 농장 크기가 다음과 같은 성질을 가지고 있다고 가정해보자. 가장 작은 값은 16.6에이커이고, 값의 25%는 41.1에이커, 75%는 101.9에이커, 90%는 124.0에이커, 가장 큰 값은 201.7에이커이다.

(1) 범위는 무엇인가?

(2) 사분위수 범위는 얼마인가?

(3) 수적 규칙이 이상치로 쓰였을 때, 가장 작은 또는 가장 큰 값을 이상치라 불러야 하는가?

풀이

(1) 범위는 $201.7 - 16.6 = 185.1$ 에이커

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.10

한 작은 마을의 농장 크기가 다음과 같은 성질을 가지고 있다고 가정해보자. 가장 작은 값은 16.6에이커이고, 값의 25%는 41.1에이커, 75%는 101.9에이커, 90%는 124.0에이커, 가장 큰 값은 201.7에이커이다.

(1) 범위는 무엇인가?

(2) 사분위수 범위는 얼마인가?

(3) 수적 규칙이 이상치로 쓰였을 때, 가장 작은 또는 가장 큰 값을 이상치라 불러야 하는가?

풀이

(1) 범위는 $201.7 - 16.6 = 185.1$ 에이커

(2) 사분위수 범위는 $Q_3 - Q_1 = 101.9 - 41.1 = 60.8$ 에이커이다.

2.2.2 범위, 백분위수, 사분위수 범위 - 계속

예제 2.10

한 작은 마을의 농장 크기가 다음과 같은 성질을 가지고 있다고 가정해보자. 가장 작은 값은 16.6에이커이고, 값의 25%는 41.1에이커, 75%는 101.9에이커, 90%는 124.0에이커, 가장 큰 값은 201.7에이커이다.

(1) 범위는 무엇인가?

(2) 사분위수 범위는 얼마인가?

(3) 수적 규칙이 이상치로 쓰였을 때, 가장 작은 또는 가장 큰 값을 이상치라 불러야 하는가?

풀이

(1) 범위는 $201.7 - 16.6 = 185.1$ 에이커

(2) 사분위수 범위는 $Q_3 - Q_1 = 101.9 - 41.1 = 60.8$ 에이커이다.

(3) $1.5 \times IQR = 1.5 \times 60.8 = 91.2$ 이므로 가장 큰 값인 201.7은 $Q_3 + 1.5 \times IQR = 101.9 + 91.2 = 193.1$ 보다 크기 때문에, 이는 이상치라고 할 수 있음

2.2.3 상자 그림

상자 그림

- 상자그림(box plot): 표본 사분위수 범위를 이용하고 이런 단점은 보완하면서 자료의 흩어진 모양을 쉽게 알 수 있도록 자료를 요약한 그림

상자 그림을 그리는 순서

2.2.3 상자 그림

상자 그림

- 상자그림(box plot): 표본 사분위수 범위를 이용하고 이런 단점은 보완하면서 자료의 흩어진 모양을 쉽게 알 수 있도록 자료를 요약한 그림
- 상자그림을 작성하는 자세한 과정은 다음과 같다. [그림 2.8]은 이해를 돕기 위하여 구성요소를 표시한 상자그림이다.

상자 그림을 그리는 순서

2.2.3 상자 그림

상자 그림

- 상자그림(box plot): 표본 사분위수 범위를 이용하고 이런 단점은 보완하면서 자료의 흩어진 모양을 쉽게 알 수 있도록 자료를 요약한 그림
- 상자그림을 작성하는 자세한 과정은 다음과 같다. [그림 2.8]은 이해를 돕기 위하여 구성요소를 표시한 상자그림이다.

상자 그림을 그리는 순서

1. 자료를 크기 순으로 나열하여 사분위수(Q_1, Q_2, Q_3)를 결정한다.

2.2.3 상자 그림

상자 그림

- 상자그림(box plot): 표본 사분위수 범위를 이용하고 이런 단점은 보완하면서 자료의 흩어진 모양을 쉽게 알 수 있도록 자료를 요약한 그림
- 상자그림을 작성하는 자세한 과정은 다음과 같다. [그림 2.8]은 이해를 돕기 위하여 구성요소를 표시한 상자그림이다.

상자 그림을 그리는 순서

1. 자료를 크기 순으로 나열하여 사분위수(Q_1, Q_2, Q_3)를 결정한다.
2. Q_1 과 Q_3을 네모난 상자로 연결하고, 중앙값(Q_2)의 위치에 수직선을 긋는다.

2.2.3 상자 그림

상자 그림

- 상자그림(box plot): 표본 사분위수 범위를 이용하고 이런 단점은 보완하면서 자료의 흩어진 모양을 쉽게 알 수 있도록 자료를 요약한 그림
- 상자그림을 작성하는 자세한 과정은 다음과 같다. [그림 2.8]은 이해를 돕기 위하여 구성요소를 표시한 상자그림이다.

상자 그림을 그리는 순서

1. 자료를 크기 순으로 나열하여 사분위수(Q_1, Q_2, Q_3)를 결정한다.
2. Q_1 과 Q_3을 네모난 상자로 연결하고, 중앙값(Q_2)의 위치에 수직선을 긋는다.
3. 사분위수 범위 $IQR = Q_3 - Q_1$을 계산한다.

2.2.3 상자 그림

상자 그림

- 상자그림(box plot): 표본 사분위수 범위를 이용하고 이런 단점은 보완하면서 자료의 흩어진 모양을 쉽게 알 수 있도록 자료를 요약한 그림
- 상자그림을 작성하는 자세한 과정은 다음과 같다. [그림 2.8]은 이해를 돕기 위하여 구성요소를 표시한 상자그림이다.

상자 그림을 그리는 순서

1. 자료를 크기 순으로 나열하여 사분위수(Q_1, Q_2, Q_3)를 결정한다.
2. Q_1 과 Q_3을 네모난 상자로 연결하고, 중앙값(Q_2)의 위치에 수직선을 긋는다.
3. 사분위수 범위 $IQR = Q_3 - Q_1$을 계산한다.
4. 상자 양끝에서 $1.5 \times IQR$ 크기의 범위를 경계로 하여, 이 범위에 포함되는 최소값과 최대값을 Q_1 과 Q_3으로부터 각각 선으로 연결한다.

2.2.3 상자 그림

상자 그림

- 상자그림(box plot): 표본 사분위수 범위를 이용하고 이런 단점은 보완하면서 자료의 흩어진 모양을 쉽게 알 수 있도록 자료를 요약한 그림
- 상자그림을 작성하는 자세한 과정은 다음과 같다. [그림 2.8]은 이해를 돕기 위하여 구성요소를 표시한 상자그림이다.

상자 그림을 그리는 순서

1. 자료를 크기 순으로 나열하여 사분위수(Q_1, Q_2, Q_3)를 결정한다.
2. Q_1 과 Q_3을 네모난 상자로 연결하고, 중앙값(Q_2)의 위치에 수직선을 긋는다.
3. 사분위수 범위 $IQR = Q_3 - Q_1$을 계산한다.
4. 상자 양끝에서 $1.5 \times IQR$ 크기의 범위를 경계로 하여, 이 범위에 포함되는 최소값과 최대값을 Q_1 과 Q_3으로부터 각각 선으로 연결한다.
5. 양 경계를 벗어나는 자료값들을 *로 표시하고, 이 점들을 이상점이라고 한다.

2.2.3 상자 그림 - 계속

상자 그림 - 계속

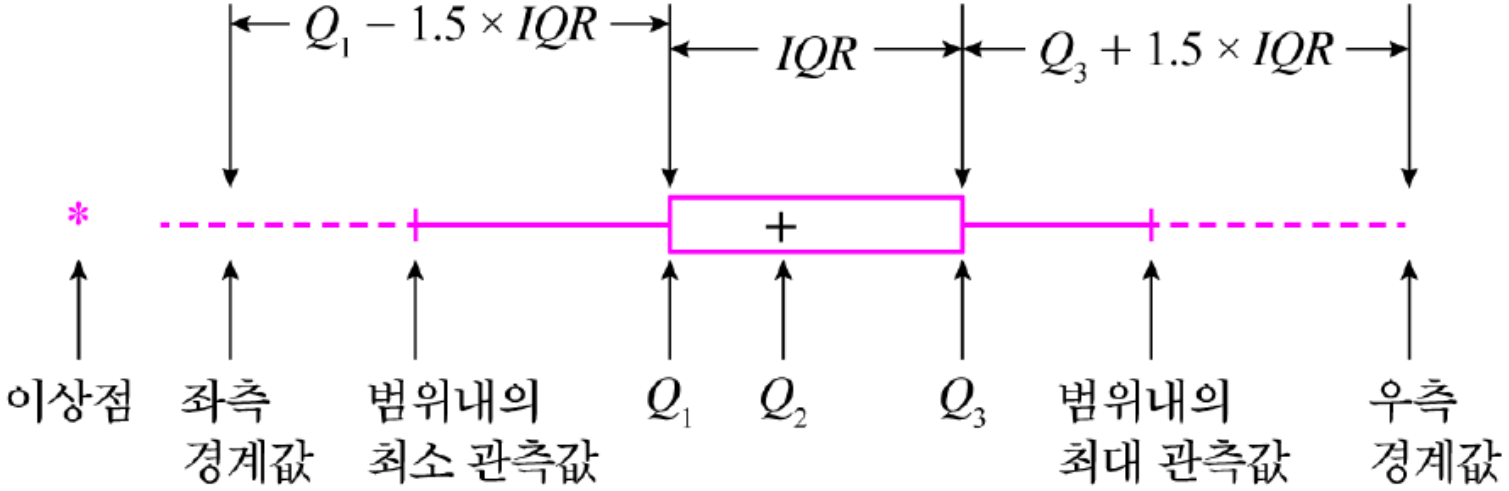

[그림 2.8] 상자그림

2.2.3 상자 그림 - 계속

예제 2.11

다음 자료는 표본 12 가구의 수입액(단위: 천 달러)을 나타낸다.

35 29 44 72 34 64 41 50 54 104 39 58

상자그림으로 시각화하시오.

풀이

- 책의 설명처럼 상자 그림을 그리는 순서에 따라 그릴 수 있음

2.2.3 상자 그림 - 계속

예제 2.11

다음 자료는 표본 12 가구의 수입액(단위: 천 달러)을 나타낸다.

35 29 44 72 34 64 41 50 54 104 39 58

상자그림으로 시각화하시오.

풀이

- 책의 설명처럼 상자 그림을 그리는 순서에 따라 그릴 수 있음
- (파이썬 코드)

```
In [1]: import seaborn as sns

In [2]: import numpy as np

In [3]: x=np.array([35, 29, 44, 72, 34, 64, 41, 50, 54, 104, 39, 58])

In [4]: ax = sns.boxplot(x)
```

2.2.3 상자 그림 - 계속

풀이 - 계속

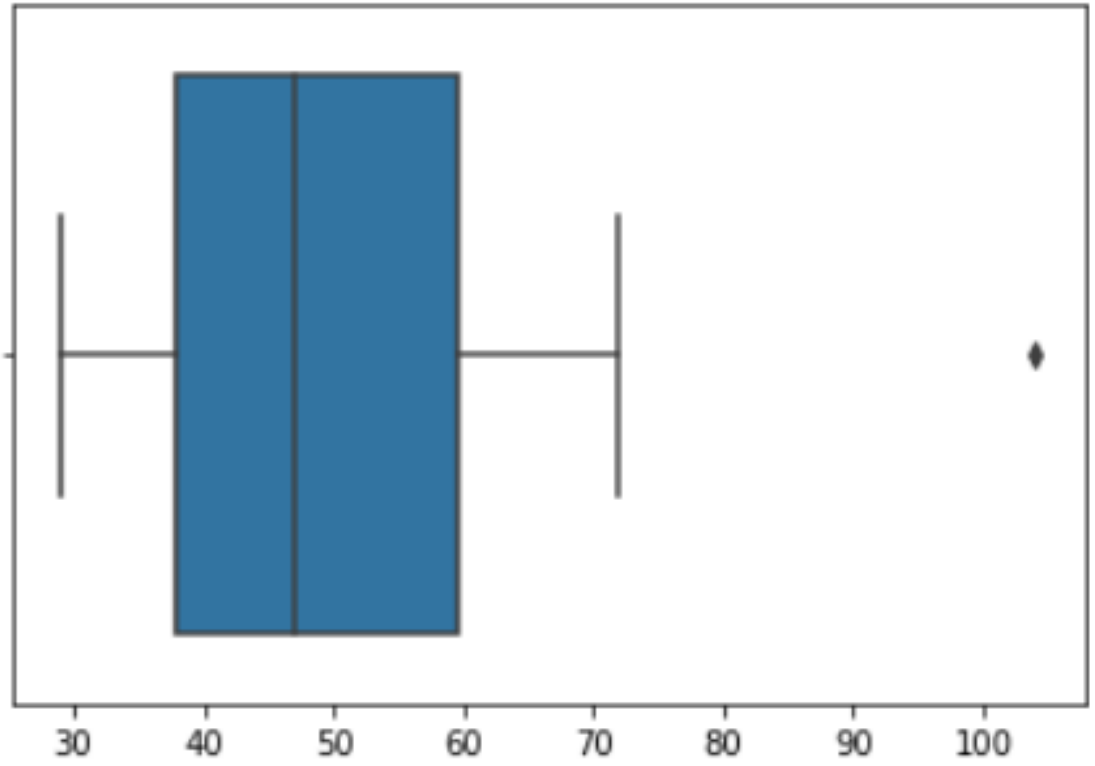

2.2.4 분산과 표준편차

분산과 표준편차

- 분산: 자료의 평균값으로부터 자료들의 퍼짐정도를 나타내는 대표적인 측도로 편차의 제곱들의 평균임

2.2.4 분산과 표준편차

분산과 표준편차

- 분산: 자료의 평균값으로부터 자료들의 퍼짐정도를 나타내는 대표적인 측도로 편차의 제곱들의 평균임
- 모집단에서 분산은 σ^2 로 표기

$$\sigma^2 = \frac{\sum(x_i - \mu)^2}{n}$$

2.2.4 분산과 표준편차

분산과 표준편차

- 분산: 자료의 평균값으로부터 자료들의 퍼짐정도를 나타내는 대표적인 측도로 편차의 제곱들의 평균임
- 모집단에서 분산은 σ^2 로 표기

$$\sigma^2 = \frac{\sum(x_i - \mu)^2}{n}$$

- s^2로 표기되는 표본분산은 다음과 같이 계산

$$s^2 = \frac{\sum(x_i - \overline{x})^2}{n-1}$$

2.2.4 분산과 표준편차

분산과 표준편차

- 분산: 자료의 평균값으로부터 자료들의 퍼짐정도를 나타내는 대표적인 측도로 편차의 제곱들의 평균임
- 모집단에서 분산은 σ^2 로 표기

$$\sigma^2 = \frac{\sum(x_i - \mu)^2}{n}$$

- s^2로 표기되는 표본분산은 다음과 같이 계산

$$s^2 = \frac{\sum(x_i - \overline{x})^2}{n-1}$$

- 특정 모집단의 변의성을 대표하는 값을 구하려고 한다. 따라서 평방편차의 제곱근 σ를 고려해야 한다. 이 값은 표준편차라고 함

2.2.4 분산과 표준편차

분산과 표준편차

- 분산: 자료의 평균값으로부터 자료들의 퍼짐정도를 나타내는 대표적인 측도로 편차의 제곱들의 평균임
- 모집단에서 분산은 σ^2 로 표기

$$\sigma^2 = \frac{\sum(x_i - \mu)^2}{n}$$

- s^2로 표기되는 표본분산은 다음과 같이 계산

$$s^2 = \frac{\sum(x_i - \overline{x})^2}{n-1}$$

- 특정 모집단의 변의성을 대표하는 값을 구하려고 한다. 따라서 평방편차의 제곱근 σ를 고려해야 한다. 이 값은 표준편차라고 함
- 표본의 표준편차는 s로 표기

2.2.4 분산과 표준편차

분산과 표준편차

- 분산: 자료의 평균값으로부터 자료들의 퍼짐정도를 나타내는 대표적인 측도로 편차의 제곱들의 평균임
- 모집단에서 분산은 σ^2 로 표기

$$\sigma^2 = \frac{\sum(x_i - \mu)^2}{n}$$

- s^2로 표기되는 표본분산은 다음과 같이 계산

$$s^2 = \frac{\sum(x_i - \overline{x})^2}{n-1}$$

- 특정 모집단의 변의성을 대표하는 값을 구하려고 한다. 따라서 평방편차의 제곱근 σ를 고려해야 한다. 이 값은 표준편차라고 함
- 표본의 표준편차는 s로 표기
- 분산이 제곱 단위로 측정되는 반면, 표준편차는 자료와 같은 단위로 측정

2.2.4 분산과 표준편차 - 계속

예제 2.12

다음 자료는 어느 농장에서 지난 8주 동안 특정품목의 수이다.

$$7\ 10\ 8\ 3\ 15\ 12\ 6\ 11$$

(1) 평균을 구하시오.

2.2.4 분산과 표준편차 - 계속

예제 2.12

다음 자료는 어느 농장에서 지난 8주 동안 특정품목의 수이다.

7 10 8 3 15 12 6 11

(1) 평균을 구하시오.

(2) 편차를 구하여 편차의 합을 구하시오.

2.2.4 분산과 표준편차 - 계속

예제 2.12

다음 자료는 어느 농장에서 지난 8주 동안 특정품목의 수이다.

7 10 8 3 15 12 6 11

(1) 평균을 구하시오.

(2) 편차를 구하여 편차의 합을 구하시오.

(3) 범위, 분산, 표준편차를 구하시오.

2.2.4 분산과 표준편차 - 계속

풀이 - 계속

- 책의 설명처럼 풀이할 수도 있음.

2.2.4 분산과 표준편차 - 계속

풀이 - 계속

- 책의 설명처럼 풀이할 수도 있음.
- (파이썬 활용)

```
In [1]: import numpy as np

In [2]: x=np.array([7, 10, 8, 3, 15, 12, 6, 11])

In [3]: x.var()
Out[3]: 12.5

In [4]: np.var(x)
Out[4]: 12.5

In [5]: x.std()
Out[5]: 3.5355339059327378

In [6]: np.std(x)
Out[6]: 3.5355339059327378
```