

1 4.3 카테고리분포와 다항분포

카테고리분포

카테고리 확률변수

- 카테고리 확률변수(Categorical random variable)는 1부터 k 까지 k 개 정숫값 중 하나가 나온다. 이 정숫값을 범주값, 카테고리(category) 혹은 클래스(class)라고 함.

카테고리분포

카테고리 확률변수

- 카테고리 확률변수(Categorical random variable)는 1부터 k 까지 k 개 정숫값 중 하나가 나온다. 이 정숫값을 범주값, 카테고리(category) 혹은 클래스(class)라고 함.
- 예) 주사위를 던져 나오는 눈금 수는 $k=6$ 인 카테고리분포

카테고리분포

카테고리 확률변수

- 카테고리 확률변수(Categorical random variable)는 1부터 k 까지 k 개 정숫값 중 하나가 나온다. 이 정숫값을 범주값, 카테고리(category) 혹은 클래스(class)라고 함.
- 예) 주사위를 던져 나오는 눈금 수는 $k=6$ 인 카테고리분포
- 주의할 점은 원래 카테고리는 스칼라값이지만 카테고리 확률변수는 다음과 같이 1과 0으로만 이루어진 다차원 벡터를 출력한다. (벡터는 원래 세로 열로 표시해야 하지만 여기에서는 편의상 가로 행으로 표시하였다.)

$$x = 1 \rightarrow x = (1, 0, 0, 0, 0, 0)$$

$$x = 2 \rightarrow x = (0, 1, 0, 0, 0, 0)$$

$$x = 3 \rightarrow x = (0, 0, 1, 0, 0, 0)$$

$$x = 4 \rightarrow x = (0, 0, 0, 1, 0, 0)$$

$$x = 5 \rightarrow x = (0, 0, 0, 0, 1, 0)$$

$$x = 6 \rightarrow x = (0, 0, 0, 0, 0, 1)$$

카테고리분포

카테고리 확률변수

- 카테고리 확률변수(Categorical random variable)는 1부터 k까지 k개 정숫값 중 하나가 나온다. 이 정숫값을 범주값, 카테고리(category) 혹은 클래스(class)라고 함.
- 예) 주사위를 던져 나오는 눈금 수는 $k=6$ 인 카테고리분포
- 주의할 점은 원래 카테고리는 스칼라값이지만 카테고리 확률변수는 다음과 같이 1과 0으로만 이루어진 다차원 벡터를 출력한다. (벡터는 원래 세로 열로 표시해야 하지만 여기에서는 편의상 가로 행으로 표시하였다.)

$$x = 1 \rightarrow x = (1, 0, 0, 0, 0, 0)$$

$$x = 2 \rightarrow x = (0, 1, 0, 0, 0, 0)$$

$$x = 3 \rightarrow x = (0, 0, 1, 0, 0, 0)$$

$$x = 4 \rightarrow x = (0, 0, 0, 1, 0, 0)$$

$$x = 5 \rightarrow x = (0, 0, 0, 0, 1, 0)$$

$$x = 6 \rightarrow x = (0, 0, 0, 0, 0, 1)$$

- 숫자를 이렇게 변형하는 것을 원핫인코딩(One-Hot-Encoding)이라고 한다.

카테고리분포

카테고리 확률변수 - 계속

- 확률변수의 값도 다음처럼 벡터로 표시한다.

$$x = (x_1, \dots, x_k), \text{ 여기서 } x_i = \begin{cases} 0 \\ 1 \end{cases} \quad \text{이고} \quad \sum_{i=1}^k x_i = 1$$

카테고리분포

카테고리 확률변수 - 계속

- 확률변수의 값도 다음처럼 벡터로 표시한다.

$$x = (x_1, \dots, x_k), \text{ 여기서 } x_i = \begin{cases} 0 \\ 1 \end{cases} \quad \text{이고} \quad \sum_{i=1}^k x_i = 1$$

- 첫 번째 제한 조건은 x_i 값으로 0 또는 1 만 가능하다는 것이고, 두 번째 제한 조건은 여러 x_i 중 단 하나만 1일 수 있다는 것이다.

카테고리분포

카테고리 확률변수 - 계속

- 확률변수의 값도 다음처럼 벡터로 표시한다.

$$x = (x_1, \dots, x_k), \text{ 여기서 } x_i = \begin{cases} 0 \\ 1 \end{cases} \text{ 이고 } \sum_{i=1}^k x_i = 1$$

- 첫 번째 제한 조건은 x_i 값으로 0 또는 1 만 가능하다는 것이고, 두 번째 제한 조건은 여러 x_i 중 단 하나만 1일 수 있다는 것이다.
- 원숫값 x_i 는 베르누이 확률변수로 볼 수 있기 때문에 각각 1이 나올 확률을 나타내는 모수 μ_i 를 가진다. 따라서 전체 카테고리분포 의 모수는 다음과 같이 벡터로 나타낸다.

$$\mu = (\mu_1, \dots, \mu_k), \text{ 여기서 } 0 \leq \mu_i \leq 1 \text{ 이고 } \sum_{i=1}^k \mu_i = 1$$

카테고리분포

카테고리 확률변수 - 계속

- 확률변수의 값도 다음처럼 벡터로 표시한다.

$$x = (x_1, \dots, x_k), \text{ 여기서 } x_i = \begin{cases} 0 \\ 1 \end{cases} \text{ 이고 } \sum_{i=1}^k x_i = 1$$

- 첫 번째 제한 조건은 x_i 값으로 0 또는 1 만 가능하다는 것이고, 두 번째 제한 조건은 여러 x_i 중 단 하나만 1일 수 있다는 것이다.
- 원숫값 x_i 는 베르누이 확률변수로 볼 수 있기 때문에 각각 1이 나올 확률을 나타내는 모수 μ_i 를 가진다. 따라서 전체 카테고리분포 의 모수는 다음과 같이 벡터로 나타낸다.

$$\mu = (\mu_1, \dots, \mu_k), \text{ 여기서 } 0 \leq \mu_i \leq 1 \text{ 이고 } \sum_{i=1}^k \mu_i = 1$$

- 첫 번째 제한 조건은 모수 μ_i 가 0과 1 사이의 값만 가질 수 있다는 점을 가리킨다. 두 번째 제한 조건은 μ_i 의 합이 1이 된다는 것이다.

카테고리분포

카테고리 확률분포

- 카테고리 확률변수의 확률분포인 카테고리 확률분포는 $\text{Cat}(x_1, x_2, \dots, x_k; \mu_1, \dots, \mu_k)$ 로 표기하거나 출력 벡터 $x = (x_1, \dots, x_k)$, 모수 벡터 $\mu = (\mu_1, \dots, \mu_k)$ 를 사용하여 $\text{Cat}(x; \mu)$ 로 간단히 표기할 수 있다.

카테고리분포

카테고리 확률분포

- 카테고리 확률변수의 확률분포인 카테고리 확률분포는 $\text{Cat}(x_1, x_2, \dots, x_k; \mu_1, \dots, \mu_k)$ 로 표기하거나 출력 벡터 $x = (x_1, \dots, x_k)$, 모수 벡터 $\mu = (\mu_1, \dots, \mu_k)$ 를 사용하여 $\text{Cat}(x; \mu)$ 로 간단히 표기할 수 있다.
- 확률질량함수는 다음처럼 표기한다.

$$\text{Cat}(x; \mu) = \begin{cases} \mu_1, & \text{if } x = (1, 0, 0, \dots, 0) \\ \mu_2, & \text{if } x = (0, 1, 0, \dots, 0) \\ \mu_3, & \text{if } x = (0, 0, 1, \dots, 0) \\ \vdots & \vdots \\ \mu_k, & \text{if } x = (0, 0, 0, \dots, 1) \end{cases}$$

카테고리분포

카테고리 확률분포

- 카테고리 확률변수의 확률분포인 카테고리 확률분포는 $\text{Cat}(x_1, x_2, \dots, x_k; \mu_1, \dots, \mu_k)$ 로 표기하거나 출력 벡터 $x = (x_1, \dots, x_k)$, 모수 벡터 $\mu = (\mu_1, \dots, \mu_k)$ 를 사용하여 $\text{Cat}(x; \mu)$ 로 간단히 표기할 수 있다.
- 확률질량함수는 다음처럼 표기한다.

$$\text{Cat}(x; \mu) = \begin{cases} \mu_1, & \text{if } x = (1, 0, 0, \dots, 0) \\ \mu_2, & \text{if } x = (0, 1, 0, \dots, 0) \\ \mu_3, & \text{if } x = (0, 0, 1, \dots, 0) \\ \vdots & \vdots \\ \mu_k, & \text{if } x = (0, 0, 0, \dots, 1) \end{cases}$$

- 위 식은 다음과 같이 쓸 수 있다. 이 간략한 표현은 원핫인코딩을 사용한 덕분이다.

$$\text{Cat}(x; \mu) = \mu_1^{x_1} \mu_2^{x_2} \cdots \mu_k^{x_k} = \prod_{i=1}^k \mu_i^{x_i}$$

카테고리분포

카테고리분포의 모멘트

- 카테고리분포는 표본값이 벡터이므로 기댓값과 분산도 벡터이다. 기댓값과 분산을 구하는 공식은 다음과 같다.

카테고리분포

카테고리분포의 모멘트

- 카테고리분포는 표본값이 벡터이므로 기댓값과 분산도 벡터이다. 기댓값과 분산을 구하는 공식은 다음과 같다.
- 기댓값

$$E(x_i) = \mu_i$$

카테고리분포

카테고리분포의 모멘트

- 카테고리분포는 표본값이 벡터이므로 기댓값과 분산도 벡터이다. 기댓값과 분산을 구하는 공식은 다음과 같다.

- 기댓값

$$E(x_i) = \mu_i$$

- 분산

$$V(x_i) = \mu_i(1 - \mu_i)$$

사이파이를 이용한 카테고리분포의 시뮬레이션

- 사이파이는 카테고리분포를 위한 별도의 클래스를 제공하지 않는다. 하지만 뒤에서 설명할 다항분포를 위한 `multinomial` 클래스에서 시행 횟수를 1로 설정하면 카테고리분포가 되므로 이 명령을 사용할 수 있다. 다음은 모수가 $\mu = (0.1, 0.1, 0.1, 0.1, 0.3, 0.3)$ 인 카테고리분포를 시뮬레이션한 것이다.

사이파이를 이용한 카테고리분포의 시뮬레이션

- 사이파이는 카테고리분포를 위한 별도의 클래스를 제공하지 않는다. 하지만 뒤에서 설명할 다항분포를 위한 `multinomial` 클래스에서 시행 횟수를 1로 설정하면 카테고리분포가 되므로 이 명령을 사용할 수 있다. 다음은 모수가 $\mu = (0.1, 0.1, 0.1, 0.1, 0.3, 0.3)$ 인 카테고리분포를 시뮬레이션한 것이다.
- `pandas.get_dummies(data, prefix=None, prefix_sep='_', dummy_na=False, columns=None, sparse=False, drop_first=False, dtype=None)`
- 범주형 변수를 더미/지표 변수로 변환

사이파이를 이용한 카테고리분포의 시뮬레이션

- 사이파이는 카테고리분포를 위한 별도의 클래스를 제공하지 않는다. 하지만 뒤에서 설명할 다항분포를 위한 `multinomial` 클래스에서 시행 횟수를 1로 설정하면 카테고리분포가 되므로 이 명령을 사용할 수 있다. 다음은 모수가 $\mu = (0.1, 0.1, 0.1, 0.1, 0.3, 0.3)$ 인 카테고리분포를 시뮬레이션한 것이다.
- `pandas.get_dummies(data, prefix=None, prefix_sep='_', dummy_na=False, columns=None, sparse=False, drop_first=False, dtype=None)`
- 범주형 변수를 더미/지표 변수로 변환
- (파이썬 코드)

```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd

mu = [0.1, 0.1, 0.1, 0.1, 0.3, 0.3]
rv = sp.stats.multinomial(1, mu)

xx = np.arange(1, 7)
xx_oh = pd.get_dummies(xx)

plt.bar(xx, rv.pmf(xx_oh.values)) #카테고리분포의 출력은 벡터값으로 pmf() 메서드의 인수로도 원핫인코딩 벡터를 넣어야 함.
plt.ylabel("P(x)")
plt.xlabel("sample value")
plt.title("pmf of categorical distribution")
plt.show()
```

카테고리분포

사이파이를 이용한 카테고리분포의 시뮬레이션 - 계속


- `rvs()` 메서드로 생성한 값도 원핫인코딩 벡터다.

```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt

mu = [0.1, 0.1, 0.1, 0.1, 0.3, 0.3]
rv = sp.stats.multinomial(1, mu)

np.random.seed(1)
X = rv.rvs(100)
X[:5] #처음 5개를 확인함

#100개의 표본값을 생성하는 시뮬레이션 결과는 다음과 같음
y = X.sum(axis=0) / float(len(X))
plt.bar(np.arange(1, 7), y)
plt.title("simulation result of categorical distribution")
plt.xlabel("sample value")
plt.ylabel("ratio")
plt.show()
```



함수(stack(), reset_index(), pivot())의 예

```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
mu, N, M=0.5, 5, 10
rv = sp.stats.binom(N, mu)
x = rv.rvs(M, random_state=0)
x
Out[20]: array([3, 3, 3, 3, 2, 3, 2, 4, 4, 2])
y = np.bincount(x, minlength=N+1) / float(len(x))
y
Out[21]: array([0. , 0. , 0.3, 0.5, 0.2, 0. ])
```

함수(stack(), reset_index(), pivot())의 예 - 계속

```

xx = np.arange(11+1)
df = pd.DataFrame({'Theory': rv.omf(xx), 'Simulation': y})
df

Out[22]:
   Theory  Simulation
0  0.03125         0.0
1  0.15625         0.0
2  0.31250         0.3
3  0.31250         0.5
4  0.15625         0.2
5  0.03125         0.0

df = pd.DataFrame({'Theory': rv.omf(xx), 'Simulation': y}).stack()

df
Out[24]:
0  Theory      0.03125
   Simulation  0.00000
1  Theory      0.15625
   Simulation  0.00000
2  Theory      0.31250
   Simulation  0.30000
3  Theory      0.31250
   Simulation  0.50000
4  Theory      0.15625
   Simulation  0.20000
5  Theory      0.03125
   Simulation  0.00000
dtype: float64

```

함수(stack(), reset_index(), pivot())의 예 - 계속

```
df = df.reset_index()
df

Out[28]:
   level_0  level_1      0
0         0    Theory  0.03125
1         0  Simulation  0.00000
2         1    Theory  0.15625
3         1  Simulation  0.00000
4         2    Theory  0.31250
5         2  Simulation  0.30000
6         3    Theory  0.31250
7         3  Simulation  0.50000
8         4    Theory  0.15625
9         4  Simulation  0.20000
10        5    Theory  0.03125
11        5  Simulation  0.00000

df.columns = ['sample value', 'type', 'ratio']

df.pivot('sample value', 'type', 'ratio')

Out[29]:
type      Simulation  Theory
sample value
0              0.0  0.03125
1              0.0  0.15625
2              0.3  0.31250
3              0.5  0.31250
4              0.2  0.15625
5              0.0  0.03125
```

카테고리분포

사이파이를 이용한 카테고리분포의 시뮬레이션 - 계속

- 이론적인 확률분포와 시뮬레이션 결과를 비교하면 다음과 같다.


```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns

mu = [0.1, 0.1, 0.1, 0.1, 0.3, 0.3]
rv = sp.stats.multinomial(1, mu)

xx = np.arange(1, 7)
xx_oh = pd.get_dummies(xx)

df = pd.DataFrame({"Theory": rv.pmf(xx_oh.values), "Simulation": y},
index=np.arange(1, 7)).stack()
df = df.reset_index()
df.columns = ["sample value", "type", "ratio"]
df.pivot(["sample value", "type", "ratio"])

sns.barplot(x="sample value", y="ratio", hue="type", data=df)
plt.title("simulation dist. and theoretic dist. of catogorical dist.")
plt.show()
```



카테고리분포


응용 - 다중 분류문제

- 다음은 사이킷런 패키지에서 제공하는 붓꽃 데이터의 품종값을 시각화한 것이다. 0, 1, 2 세 가지의 범주값을 가지는 붓꽃 데이터의 품종값은 카테고리 $k = 3$ 인 카테고리분포를 이룬다. 꽃잎 폭이라고 하는 특징에 따라 카테고리분포의 모양이 달라지는 것을 볼 수 있다.

```
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
from sklearn.datasets import load_iris
iris = load_iris()
df = pd.DataFrame(iris.data, columns=iris.feature_names)
df["varieties"] = pd.Series(iris.target, dtype="category")
df1 = df[df["petal width (cm)"] > 1.5]
df2 = df[df["petal width (cm)"] <= 1.5]
fig, ax = plt.subplots(1, 2)
sns.countplot(x="varieties", data=df1, ax=ax[0]).set_title("petal width > 1.5cm")
sns.countplot(x="varieties", data=df2, ax=ax[1]).set_title("petal width <= 1.5cm")
plt.tight_layout()
plt.show()
```

카테고리분포

응용 - 다중 분류문제 - 계속



다항분포

다항분포 확률변수

- 베르누이 확률변수의 데이터가 복수이면 이 데이터의 합이 이항 분포를 이루는 것처럼 카테고리 확률변수의 데이터가 여럿 있으면 이 데이터의 합은 다항분포(Multinomial distribution)가 된다.

다항분포

다항분포 확률변수

- 베르누이 확률변수의 데이터가 복수이면 이 데이터의 합이 이항 분포를 이루는 것처럼 카테고리 확률변수의 데이터가 여럿 있으면 이 데이터의 합은 **다항분포**(Multinomial distribution)가 된다.
- 예) 동전을 N 번 던져 앞면이 나오는 횟수의 분포가 이항 분포이고 주사위를 N 번 던져 각 면이 나오는 횟수 집합의 분포가 다항분포다.

다항분포

다항분포 확률변수

- 베르누이 확률변수의 데이터가 복수이면 이 데이터의 합이 이항 분포를 이루는 것처럼 카테고리 확률변수의 데이터가 여럿 있으면 이 데이터의 합은 **다항분포**(Multinomial distribution)가 된다.
- 예) 동전을 N 번 던져 앞면이 나오는 횟수의 분포가 이항 분포이고 주사위를 N 번 던져 각 면이 나오는 횟수 집합의 분포가 다항분포다.
- 다항분포는 카테고리가 K 개인 카테고리 확률변수의 표본 데이터를 N 개 얻었을 때, 각각의 카테고리 $k(k = 1, \dots, K)$ 가 각각 x_k 번 나올 확률분포 즉, 표본값이 벡터 $x = (x_1, \dots, x_K)$ 가 되는 확률분포를 말한다.

다항분포

다항분포 확률변수

- 베르누이 확률변수의 데이터가 복수이면 이 데이터의 합이 이항 분포를 이루는 것처럼 카테고리 확률변수의 데이터가 여럿 있으면 이 데이터의 합은 **다항분포**(Multinomial distribution)가 된다.
- 예) 동전을 N 번 던져 앞면이 나오는 횟수의 분포가 이항 분포이고 주사위를 N 번 던져 각 면이 나오는 횟수 집합의 분포가 다항분포다.
- 다항분포는 카테고리가 K 개인 카테고리 확률변수의 표본 데이터를 N 개 얻었을 때, 각각의 카테고리 $k(k = 1, \dots, K)$ 가 각각 x_k 번 나올 확률분포 즉, 표본값이 벡터 $x = (x_1, \dots, x_K)$ 가 되는 확률분포를 말한다.
- 예) $x = (1, 2, 1, 2, 3, 1)$ 은 6개의 숫자가 나올 수 있는 주사위를 10번 던져서 1인 면이 1번, 2인 면이 2번, 3인 면이 1번, 4인 면이 2번, 5인 면이 3번, 6인 면이 1번 나왔다는 뜻이다.

다항분포

다항분포 확률변수

- 베르누이 확률변수의 데이터가 복수이면 이 데이터의 합이 이항 분포를 이루는 것처럼 카테고리 확률변수의 데이터가 여럿 있으면 이 데이터의 합은 **다항분포**(Multinomial distribution)가 된다.
- 예) 동전을 N 번 던져 앞면이 나오는 횟수의 분포가 이항 분포이고 주사위를 N 번 던져 각 면이 나오는 횟수 집합의 분포가 다항분포다.
- 다항분포는 카테고리가 K 개인 카테고리 확률변수의 표본 데이터를 N 개 얻었을 때, 각각의 카테고리 $k(k = 1, \dots, K)$ 가 각각 x_k 번 나올 확률분포 즉, 표본값이 벡터 $x = (x_1, \dots, x_K)$ 가 되는 확률분포를 말한다.
- 예) $x = (1, 2, 1, 2, 3, 1)$ 은 6개의 숫자가 나올 수 있는 주사위를 10번 던져서 1인 면이 1번, 2인 면이 2번, 3인 면이 1번, 4인 면이 2번, 5인 면이 3번, 6인 면이 1번 나왔다는 뜻이다.
- 다항분포의 확률질량함수는 $Mu(x; N, \mu)$ 와 같이 표기하며 다음과 같은 수식을 따른다.

$$Mu(x; N, \mu) = \binom{N}{x} \prod_{k=1}^K \mu_k^{x_k} = \binom{N}{x_1, \dots, x_K} \prod_{k=1}^K \mu_k^{x_k}, \quad \binom{N}{x_1, \dots, x_K} = \frac{N!}{x_1! \cdots x_K!}$$

다항분포

다항분포의 모멘트

- 다항분포의 기댓값과 분산은 다음과 같다

다항분포

다항분포의 모멘트

- 다항분포의 기댓값과 분산은 다음과 같다
- 기댓값

$$E(x_k) = N\mu_k$$

다항분포

다항분포의 모멘트

- 다항분포의 기댓값과 분산은 다음과 같다
- 기댓값

$$E(x_k) = N\mu_k$$

- 분산

$$V(x_k) = N\mu_k(1 - \mu_k)$$

다항분포

사이파이를 이용한 다항분포의 시뮬레이션

- 사이파이는 다항분포를 위한 multinomial 클래스를 지원한다. 인수로는 시행 횟수 N 과 모수 벡터 $\mu = (0.1, 0.1, 0.1, 0.1, 0.3, 0.3)$ 를 받는다. 이 시뮬레이션은 5와 6이 다른 수보다 잘 나오게 만든 조작된 주사위를 30번 던졌을 때 나올 수 있는 여러 경우를 살펴본 것이다.

다항분포

사이파이를 이용한 다항분포의 시뮬레이션

- 사이파이는 다항분포를 위한 multinomial 클래스를 지원한다. 인수로는 시행 횟수 N 과 모수 벡터 $\mu = (0.1, 0.1, 0.1, 0.1, 0.3, 0.3)$ 를 받는다. 이 시뮬레이션은 5와 6이 다른 수보다 잘 나오게 만든 조작된 주사위를 30번 던졌을 때 나올 수 있는 여러 경우를 살펴본 것이다.
- 다음은 이 시뮬레이션 결과를 시본 패키지의 스웜 플롯(swarm plot) 명령과 바이올린 플롯(violin plot) 명령을 사용하여 시각화한 것이다. 스웜 플롯은 각 카테고리에 해당하는 실숫값 데이터 집합을 하나하나 점으로 나타낸 것이고 바이올린 플롯은 이 데이터의 분포를 커널밀도(kernel density)라는 부드러운 곡선으로 표현한 것이다.

사이파이를 이용한 다항분포의 시뮬레이션 - 계속


```

import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns

N = 30
mu = [0.1, 0.1, 0.1, 0.1, 0.3, 0.3]
rv = sp.stats.multinomial(N, mu)
np.random.seed(0)
X = rv.rvs(100)
X[:10]

df = pd.DataFrame(X).stack().reset_index()
df.columns = ["trial", "class", "sample value"]
sns.violinplot(x="class", y="sample value", data=df, inner="quartile")
sns.swarmplot(x="class", y="sample value", data=df, color=".3")
plt.title("simulation result of multinomial dist.")
plt.show()

```



다항분포

사이파일을 이용한 다항분포의 시뮬레이션 - 계속

- 맷플롯립 패키지의 박스 플(box plot) 명령으로 더 단순하게 시각화할 수도 있다. boxplot 명령은 박스-휘스커 플롯(box-whisker Plot) 혹은 간단히 **박스 플롯(boxplot)**이라 부르는 차트를 그려준다. 박스 플롯은 상자(box)와 상자 바깥의 선(whisker)으로 이루어진다.

다항분포

사이파이를 이용한 다항분포의 시뮬레이션 - 계속

- 맷플롯립 패키지의 박스 플(box plot) 명령으로 더 단순하게 시각화할 수도 있다. boxplot 명령은 박스-휘스커 플롯(box-whisker Plot) 혹은 간단히 **박스 플롯(boxplot)**이라 부르는 차트를 그려준다. 박스 플롯은 상자(box)와 상자 바깥의 선(whisker)으로 이루어진다.
- 다항분포의 표본 하나는 같은 모수를 가진 카테고리분포의 표본 여럿을 합쳐놓은 것이므로 다항분포의 표본이 이루는 분포의 모양은 카테고리분포와 비슷해진다.

사이파이를 이용한 다항분포의 시뮬레이션 - 계속

```

import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
N = 30
mu = [0.1, 0.1, 0.1, 0.1, 0.3, 0.3]
rv = sp.stats.multinomial(N, mu)
np.random.seed(0)
X = rv.rvs(100)
X[:10]

plt.boxplot(X)
plt.title("simulation result of multinomial dist.")
plt.xlabel("class")
plt.ylabel("sample value")
plt.show()

```

