

1 4.4 정규분포와 중심극한정리

정규분포

정규분포

- 정규분포(normal distribution) 혹은 가우스 정규분포(Gaussian normal distribution)라는 분포는 자연 현상에서 나타나는 숫자를 확률 모형으로 모형화할 때 많이 사용

정규분포

정규분포

- 정규분포(normal distribution) 혹은 가우스 정규분포(Gaussian normal distribution)라는 분포는 자연 현상에서 나타나는 숫자를 확률 모형으로 모형화할 때 많이 사용
- 정규분포는 평균 μ 와 분산 σ^2 이라는 두 모수만으로 정의되며 확률밀도함수(pdf: probability density function)는 다음과 같은 수식으로 표현된다.

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

정규분포

정규분포

- 정규분포(normal distribution) 혹은 가우스 정규분포(Gaussian normal distribution)라는 분포는 자연 현상에서 나타나는 숫자를 확률 모형으로 모형화할 때 많이 사용
- 정규분포는 평균 μ 와 분산 σ^2 이라는 두 모수만으로 정의되며 확률밀도함수(pdf: probability density function)는 다음과 같은 수식으로 표현된다.

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 분산의 역수를 정밀도(precision) β 라고 부르기도 한다.

$$\beta = \frac{1}{\sigma^2}$$

정규분포

정규분포

- 정규분포(normal distribution) 혹은 가우스 정규분포(Gaussian normal distribution)라는 분포는 자연 현상에서 나타나는 숫자를 확률 모형으로 모형화할 때 많이 사용
- 정규분포는 평균 μ 와 분산 σ^2 이라는 두 모수만으로 정의되며 확률밀도함수(pdf: probability density function)는 다음과 같은 수식으로 표현된다.

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 분산의 역수를 정밀도(precision) β 라고 부르기도 한다.

$$\beta = \frac{1}{\sigma^2}$$

- 정규분포 중에서도 평균이 0이고 분산이 1 ($\mu = 0, \sigma^2 = 1$)인 정규분포를 표준정규분포(standard normal distribution) 라고 한다.

정규분포

정규분포

- 정규분포(normal distribution) 혹은 가우스 정규분포(Gaussian normal distribution)라는 분포는 자연 현상에서 나타나는 숫자를 확률 모형으로 모형화할 때 많이 사용
- 정규분포는 평균 μ 와 분산 σ^2 이라는 두 모수만으로 정의되며 확률밀도함수(pdf: probability density function)는 다음과 같은 수식으로 표현된다.

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 분산의 역수를 정밀도(precision) β 라고 부르기도 한다.

$$\beta = \frac{1}{\sigma^2}$$

- 정규분포 중에서도 평균이 0이고 분산이 1 ($\mu = 0, \sigma^2 = 1$)인 정규분포를 표준정규분포(standard normal distribution) 라고 한다.
- 정규분포의 확률밀도함수는 다음과 같은 성질을 가진다.

정규분포

정규분포

- 정규분포(normal distribution) 혹은 가우스 정규분포(Gaussian normal distribution)라는 분포는 자연 현상에서 나타나는 숫자를 확률 모형으로 모형화할 때 많이 사용
- 정규분포는 평균 μ 와 분산 σ^2 이라는 두 모수만으로 정의되며 확률밀도함수(pdf: probability density function)는 다음과 같은 수식으로 표현된다.

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 분산의 역수를 정밀도(precision) β 라고 부르기도 한다.

$$\beta = \frac{1}{\sigma^2}$$

- 정규분포 중에서도 평균이 0이고 분산이 1 ($\mu = 0, \sigma^2 = 1$)인 정규분포를 표준정규분포(standard normal distribution) 라고 한다.
- 정규분포의 확률밀도함수는 다음과 같은 성질을 가진다.
 - $x = \mu$ 일 때 확률밀도가 최대가 된다.

정규분포

정규분포

- 정규분포(normal distribution) 혹은 가우스 정규분포(Gaussian normal distribution)라는 분포는 자연 현상에서 나타나는 숫자를 확률 모형으로 모형화할 때 많이 사용
- 정규분포는 평균 μ 와 분산 σ^2 이라는 두 모수만으로 정의되며 확률밀도함수(pdf: probability density function)는 다음과 같은 수식으로 표현된다.

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 분산의 역수를 정밀도(precision) β 라고 부르기도 한다.

$$\beta = \frac{1}{\sigma^2}$$

- 정규분포 중에서도 평균이 0이고 분산이 1 ($\mu = 0, \sigma^2 = 1$)인 정규분포를 표준정규분포(standard normal distribution) 라고 한다.
- 정규분포의 확률밀도함수는 다음과 같은 성질을 가진다.
 - $x = \mu$ 일 때 확률밀도가 최대가 된다.
 - $x = \infty$ 로 다가가거나 $x = -\infty$ 로 다가갈수록 확률밀도가 작아진다.

정규분포


정규분포 확률밀도함수

- `matplotlib.pyplot.arrow(x, y, dx, dy, **kwargs)`
- `matplotlib.pyplot.text(x, y, s, fontdict=None, **kwargs)`

```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt

mu = 0
std = 1
rv = sp.stats.norm(mu, std)

xx = np.linspace(-5, 5, 100)
plt.plot(xx, rv.pdf(xx))
plt.arrow(0, 0.05, 2, 0, lw=3, color='r',
          head_width=0.02, head_length=0.2, length_includes_head=True)
plt.arrow(0, 0.05, -2, 0, lw=3, color='r',
          head_width=0.02, head_length=0.2, length_includes_head=True)
plt.text(-0.95, 0.03, "4 times of std")
plt.ylabel("p(x)")
plt.title("pdf of normal dist.")
plt.show()
```



정규분포

정규분포 확률밀도함수

- `seaborn.distplot(a=None, bins=None, hist=True, kde=True, rug=False, fit=None, hist_kws=None, kde_kws=None, rug_kws=None, fit_kws=None, color=None, vertical=False, norm_hist=False, axlabel=None, label=None, ax=None, x=None)`
 - rug : 지지 축에 rugplot을 그릴 지 여부
 - kde : 가우스 커널 밀도 추정치를 플로팅할지 여부


```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

mu = 0
std = 1
rv = sp.stats.norm(mu, std)

np.random.seed(0)
x = rv.rvs(20)

# distplot() 명령의 fit 인수를 사용하여
# 가장 유사한 정규분포의 확률밀도함수를 그림

sns.distplot(x, rug=True, kde=False, fit=sp.stats.norm)
plt.title("result of random sample generation")
plt.xlabel("sample value")
plt.ylabel("$p(x)$")
plt.show()
```




정규분포

예제: 붓꽃 데이터

- 붓꽃 데이터는 통계학자 피셔(R.A. Fisher)의 붓꽃의 분류 연구에 기반한 데이터다. `load_iris()` 명령으로 로드한다. 데이터는 다음과 같이 구성되어 있다.
 - 타겟 데이터 : `setosa`, `versicolor`, `virginica`의 세가지 붓꽃 종(species)
 - 특징 데이터 : 꽃받침 길이(Sepal Length), 꽃받침 폭(Sepal Width), 꽃잎 길이(Petal Length), 꽃잎 폭(Petal Width)
- 다음은 붓꽃 중 특정한 종(`setosa`)의 꽃잎의 길이에 대한 히스토그램이다. 정규분포와 비슷한 모양을 보인다.

```
import scipy as sp
import scipy.stats
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_iris

setosa_sepal_length = load_iris().data[:50, 2]
sns.distplot(setosa_sepal_length, rug=True)
plt.tight_layout()
plt.show()
```



정규분포

예제: 주식 수익률

- No module named 'pandas_datareader' 에러 메시지가 나오면 Anaconda Powershell Prompt에서 다음 두 pip 명령을 사용하여 설치하시기 바랍니다.
(1. pip install pip --upgrade 2. pip install pandas-datareader)

정규분포

예제: 주식 수익률

- No module named 'pandas_datareader' 에러 메시지가 나오면 Anaconda Powershell Prompt에서 다음 두 pip 명령을 사용하여 설치하시기 바랍니다.
(1. pip install pip -upgrade 2. pip install pandas-datareader)
- 다음은 과거 약 10년간의 미국 나스닥(Nasdaq) 주가지수를 그린 것이다.

```
import pandas as pd
import matplotlib.pyplot as plt
import pandas_datareader.data as web

symbol = "NASDAQCOM"
data = pd.DataFrame()
data[symbol] = web.DataReader(
    symbol, data_source="fred", start="2009-01-01", end="2018-12-31")[symbol]
data = data.dropna()
data.plot(legend=False)
plt.xlabel("day")
plt.title("Nasdaq index")
plt.show()
```



예제: 주식 수익률 - 계속

- 10년간의 평균 일간수익률을 계산하면 약 0.06%가 나온다. 표준편차는 약 1.17%다. 주식의 수익률을 표시할 때는 표준편차라는 말 대신 변동(volatility)이라는 용어를 사용한다.

예제: 주식 수익률 - 계속

- 10년간의 평균 일간수익률을 계산하면 약 0.06%가 나온다. 표준편차는 약 1.17%다. 주식의 수익률을 표시할 때는 표준편차라는 말 대신 변동(volatility)이라는 용어를 사용한다.
- `DataFrame.dropna(axis=0, how='any', thresh=None, subset=None, inplace=False)`

```
In [1]: import pandas as pd
...: import matplotlib.pyplot as plt
...: import pandas_datareader.data as web
...:
...: symbol = "NASDAQCOM"
...: data = pd.DataFrame()
...: data[symbol] = web.DataReader(
...:     symbol, data_source="fred", start="2009-01-01", end="2018-12-31")[symbol]
...: data = data.dropna()
...:
...: daily_returns = data.pct_change().dropna()
...: mean = daily_returns.mean().values[0]
...: std = daily_returns.std().values[0]
...: print("평균 일간수익률: {:.2f}%".format(mean * 100))
...: print("평균 일간변동성: {:.2f}%".format(std * 100))
```

평균 일간수익률: 0.06%
 평균 일간변동성: 1.17%

예제: 주식 수익률 - 계속

- 일간수익률의 분포를 히스토그램으로 나타냈다. 이 그림에서 다음과 같은 사실을 알 수 있다.

예제: 주식 수익률 - 계속

- 일간수익률의 분포를 히스토그램으로 나타냈다. 이 그림에서 다음과 같은 사실을 알 수 있다.
 1. 주식의 일간수익률은 단봉분포이고 대칭적인 정규분포와 비슷한 모양을 가진다.

예제: 주식 수익률 - 계속

- 일간수익률의 분포를 히스토그램으로 나타냈다. 이 그림에서 다음과 같은 사실을 알 수 있다.
 1. 주식의 일간수익률은 단봉분포이고 대칭적인 정규분포와 비슷한 모양을 가진다.
 2. 주식 일간수익률은 0에 가까운 기댓값을 가진다.

예제: 주식 수익률 - 계속

- 일간수익률의 분포를 히스토그램으로 나타냈다. 이 그림에서 다음과 같은 사실을 알 수 있다.
 1. 주식의 일간수익률은 단봉분포이고 대칭적인 정규분포와 비슷한 모양을 가진다.
 2. 주식 일간수익률은 0에 가까운 기댓값을 가진다.
 3. 일간수익률의 값이 0에 가깝더라도 양수라면 오랜 시간후에 엄청나게 높은 수익률을 보인다.


예제: 주식 수익률 - 계속

- 일간수익률의 분포를 히스토그램으로 나타냈다. 이 그림에서 다음과 같은 사실을 알 수 있다.
 1. 주식의 일간수익률은 단봉분포이고 대칭적인 정규분포와 비슷한 모양을 가진다.
 2. 주식 일간수익률은 0에 가까운 기댓값을 가진다.
 3. 일간수익률의 값이 0에 가깝더라도 양수라면 오랜 시간후에 엄청나게 높은 수익률을 보인다.
- (파이썬 코드)

```
import pandas as pd
import matplotlib.pyplot as plt
import pandas_datareader.data as web
import seaborn as sns

symbol = "NASDAQCOM"
data = pd.DataFrame()
data[symbol] = web.DataReader(
    symbol, data_source="fred", start="2009-01-01", end="2018-12-31")[symbol]
data = data.dropna()

daily_returns = data.pct_change().dropna()
sns.distplot(daily_returns, kde=False)
ymin, ymax = plt.ylim()
plt.vlines(x=mean, ymin=0, ymax=ymax, ls="--")
plt.ylim(0, ymax)
plt.title("average daily rate of return dist. of Nasdaq index")
plt.xlabel("average daily rate of return")
plt.show()
```



Q-Q 플롯

- 정규분포는 여러 연속확률분포 중에서도 가장 널리 사용되는 확률분포다. 따라서 어떤 확률변수의 분포가 정규분포인지 아닌지 확인하는 것은 중요한 통계적 분석 중 하나다.

Q-Q 플롯

- 정규분포는 여러 연속확률분포 중에서도 가장 널리 사용되는 확률분포다. 따라서 어떤 확률변수의 분포가 정규분포인지 아닌지 확인하는 것은 중요한 통계적 분석 중 하나다.
- Q-Q (Quantile-Quantile) 플롯은 분석할 표본 데이터의 분포와 정규분포의 분포 형태를 비교하여 표본 데이터가 정규분포를 따르는지 검사하는 간단한 시각적 도구다.

Q-Q 플롯

- 정규분포는 여러 연속확률분포 중에서도 가장 널리 사용되는 확률분포다. 따라서 어떤 확률변수의 분포가 정규분포인지 아닌지 확인하는 것은 중요한 통계적 분석 중 하나다.
- Q-Q(Quantile-Quantile) 플롯은 분석할 표본 데이터의 분포와 정규분포의 분포 형태를 비교하여 표본 데이터가 정규분포를 따르는지 검사하는 간단한 시각적 도구다.
- Q-Q 플롯은 동일 분위수에 해당하는 정상 분포의 값과 주어진 데이터값을 한 쌍으로 만들어 그린 스캐터 플롯(scatter plot)이다.

Q-Q 플롯

- 정규분포는 여러 연속확률분포 중에서도 가장 널리 사용되는 확률분포다. 따라서 어떤 확률변수의 분포가 정규분포인지 아닌지 확인하는 것은 중요한 통계적 분석 중 하나다.
- Q-Q(Quantile-Quantile) 플롯은 분석할 표본 데이터의 분포와 정규분포의 분포 형태를 비교하여 표본 데이터가 정규분포를 따르는지 검사하는 간단한 시각적 도구다.
- Q-Q 플롯은 동일 분위수에 해당하는 정상 분포의 값과 주어진 데이터값을 한 쌍으로 만들어 그린 스캐터 플롯(scatter plot)이다.
- 정규분포를 따르는 데이터 표본을 Q-Q 플롯으로 그리면 다음과 같이 직선의 형태로 나타난다.

Q-Q 플롯

- 정규분포는 여러 연속확률분포 중에서도 가장 널리 사용되는 확률분포다. 따라서 어떤 확률변수의 분포가 정규분포인지 아닌지 확인하는 것은 중요한 통계적 분석 중 하나다.
- Q-Q(Quantile-Quantile) 플롯은 분석할 표본 데이터의 분포와 정규분포의 분포 형태를 비교하여 표본 데이터가 정규분포를 따르는지 검사하는 간단한 시각적 도구다.
- Q-Q 플롯은 동일 분위수에 해당하는 정상 분포의 값과 주어진 데이터값을 한 쌍으로 만들어 그린 스캐터 플롯(scatter plot)이다.
- 정규분포를 따르는 데이터 표본을 Q-Q 플롯으로 그리면 다음과 같이 직선의 형태로 나타난다.
- (파이썬 코드)

```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt


mu = 0
std = 1
rv = sp.stats.norm(mu, std)

np.random.seed(0)
x = rv.rvs(20)
x_sorted = np.sort(x)
# x_sorted

from scipy.stats.morestats import _calc_uniform_order_statistic_medians
position = _calc_uniform_order_statistic_medians(len(x))
# position

qf = rv.ppf(position)
# qf

plt.scatter(qf, x_sorted)
plt.title("Q-Q plot")
plt.xlabel("theoretical quantiles")
plt.ylabel("sorted sample data")
plt.axis("equal")
plt.show()
```



Q-Q 플롯

- 사이파이 패키지의 `stats` 서브패키지는 Q-Q 플롯을 계산하고 그리기 위한 `probplot()` 명령을 제공한다.

Q-Q 플롯

- 사이파이 패키지의 `stats` 서브패키지는 Q-Q 플롯을 계산하고 그리기 위한 `probplot()` 명령을 제공한다.
- `probplot()`은 기본적으로 인수로 보낸 데이터 표본에 대한 Q-Q 플롯 정보만을 반환하고 실제 차트는 그리지 않는다.

Q-Q 플롯

- 사이파이 패키지의 `stats` 서브패키지는 Q-Q 플롯을 계산하고 그리기 위한 `probplot()` 명령을 제공한다.
- `probplot()`은 기본적으로 인수로 보낸 데이터 표본에 대한 Q-Q 플롯 정보만을 반환하고 실제 차트는 그리지 않는다.
- 만약 차트를 그리고 싶다면 `plot` 인수에 `matplotlib.pyplot` 모듈 객체 혹은 `Axes` 클래스 객체를 넘겨주어야 한다.

Q-Q 플롯

- 사이파이 패키지의 `stats` 서브패키지는 Q-Q 플롯을 계산하고 그리기 위한 `probplot()` 명령을 제공한다.
- `probplot()`은 기본적으로 인수로 보낸 데이터 표본에 대한 Q-Q 플롯 정보만을 반환하고 실제 차트는 그리지 않는다.
- 만약 차트를 그리고 싶다면 `plot` 인수에 `matplotlib.pyplot` 모듈 객체 혹은 `Axes` 클래스 객체를 넘겨주어야 한다.
- (파이썬 코드)

```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt


mu = 0
std = 1
rv = sp.stats.norm(mu, std)

np.random.seed(0)
x = rv.rvs(20)
x_sorted = np.sort(x)
# x_sorted

from scipy.stats.morestats import _calc_uniform_order_statistic_medians
position = _calc_uniform_order_statistic_medians(len(x))
# position

qf = rv.ppf(position)
# qf

np.random.seed(0)
plt.figure(figsize=(7, 7))
sp.stats.probplot(x, plot=plt)
plt.axis("equal")
plt.show()
```



Q-Q 플롯

- 정규분포를 따르지 않는 데이터 표본을 Q-Q 플롯으로 그리면 다음과 같이 직선이 아닌 휘어진 형태로 나타난다.

Q-Q 플롯


- 정규분포를 따르지 않는 데이터 표본을 Q-Q 플롯으로 그리면 다음과 같이 직선이 아닌 휘어진 형태로 나타난다.
- 이 코드에서는 균일분포 데이터를 사용하였다. 이 균일분포 데이터는 0 이상 1 이하의 값만 가질 수 있기 때문에 세로축의 값이 이 구간내에 존재하게된다. 따라서 위아래로 제한된 형태의 휘어진 Q-Q 플롯이 나온다.

Q-Q 플롯

- 정규분포를 따르지 않는 데이터 표본을 Q-Q 플롯으로 그리면 다음과 같이 직선이 아닌 휘어진 형태로 나타난다.
- 이 코드에서는 균일분포 데이터를 사용하였다. 이 균일분포 데이터는 0 이상 1 이하의 값만 가질 수 있기 때문에 세로축의 값이 이 구간내에 존재하게된다. 따라서 위아래로 제한된 형태의 휘어진 Q-Q 플롯이 나온다.
- (파이썬 코드)

```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(0)
x = np.random.rand(100)
plt.figure(figsize=(7, 7))
sp.stats.probplot(x, plot=plt)
plt.ylim(-0.5, 1.5)
plt.show()
```



중심극한정리

- 실세계에서 발생하는 현상 중 많은 것들이 정규분포로 모형화 가능하다. 그 이유 중의 하나는 **중심극한정리**(Central Limit Theorem)다.

중심극한정리

- 실세계에서 발생하는 현상 중 많은 것들이 정규분포로 모형화 가능하다. 그 이유 중의 하나는 **중심극한정리**(Central Limit Theorem)다.
- 중심극한정리는 여러 확률변수의 합이 정규분포와 비슷한 분포를 이루는 현상을 말한다. 중심극한정리를 수학적 용어로 쓰면 다음과 같다.

중심극한정리

- 실세계에서 발생하는 현상 중 많은 것들이 정규분포로 모형화 가능하다. 그 이유 중의 하나는 **중심극한정리**(Central Limit Theorem)다.
- 중심극한정리는 여러 확률변수의 합이 정규분포와 비슷한 분포를 이루는 현상을 말한다. 중심극한정리를 수학적인 용어로 쓰면 다음과 같다.
- $X_1, X_2, \dots, X_N$ 이 기댓값이 μ 이고 분산이 σ^2 으로 동일한 분포(기댓값과 분산의 값이 동일할 뿐이며 분포의 모양은 달라도 된다)이며 서로 독립인 확률변수들이라고 하자. 분포가 어떤 분포인지는 상관없다.

중심극한정리

- 실세계에서 발생하는 현상 중 많은 것들이 정규분포로 모형화 가능하다. 그 이유 중의 하나는 **중심극한정리**(Central Limit Theorem)다.
- 중심극한정리는 여러 확률변수의 합이 정규분포와 비슷한 분포를 이루는 현상을 말한다. 중심극한정리를 수학적 용어로 쓰면 다음과 같다.
- $X_1, X_2, \dots, X_N$ 이 기댓값이 μ 이고 분산이 σ^2 으로 동일한 분포(기댓값과 분산의 값이 동일할 뿐이며 분포의 모양은 달라도 된다)이며 서로 독립인 확률변수들이라고 하자. 분포가 어떤 분포인지는 상관없다.
- $X_1, X_2, \dots, X_N$ 에서 뽑은 각각의 표본 데이터 $x_1, x_2, \dots, x_N$ 의 표본 평균

$$\bar{x}_N = \frac{1}{N}(x_1 + x_2 + \dots + x_N)$$

도 마찬가지로 예측할 수 없는 확률변수다. 이 확률변수를 $\bar{X}_N$ 이라고 하자.

중심극한정리

- 실세계에서 발생하는 현상 중 많은 것들이 정규분포로 모형화 가능하다. 그 이유 중의 하나는 **중심극한정리**(Central Limit Theorem)다.
- 중심극한정리는 여러 확률변수의 합이 정규분포와 비슷한 분포를 이루는 현상을 말한다. 중심극한정리를 수학적인 용어로 쓰면 다음과 같다.
- $X_1, X_2, \dots, X_N$ 이 기댓값이 μ 이고 분산이 σ^2 으로 동일한 분포(기댓값과 분산의 값이 동일할 뿐이며 분포의 모양은 달라도 된다)이며 서로 독립인 확률변수들이라고 하자. 분포가 어떤 분포인지는 상관없다.
- $X_1, X_2, \dots, X_N$ 에서 뽑은 각각의 표본 데이터 $x_1, x_2, \dots, x_N$ 의 표본 평균

$$\bar{x}_N = \frac{1}{N}(x_1 + x_2 + \dots + x_N)$$

도 마찬가지로 예측할 수 없는 확률변수다. 이 확률변수를 $\bar{X}_N$ 이라고 하자.

- 중심극한정리는 다음과 같다.

N 개의 임의의 분포로부터 얻은 표본의 평균은 N 이 증가할수록 기댓값이 μ , 분산이 $\frac{\sigma^2}{N}$ 인 정규분포로 수렴한다.

$$\bar{X}_N \rightarrow \mathcal{N}(x; \mu, \frac{\sigma^2}{N})$$

중심극한정리 - 계속

- 이 표본 평균의 평균이 0, 분산이 1이 되도록 다음처럼 정규화를 하면 다음과 같이 쓸 수도 있다.

N 개의 임의의 분포로부터 얻은 표본의 평균을 정규화하면 N 이 증가할 수록 표준정규분포로 수렴한다.

$$\frac{\bar{X}_N - \mu}{\frac{\sigma}{\sqrt{N}}} \rightarrow \mathcal{N}(x; 0, 1)$$

중심극한정리 - 계속

- 시뮬레이션을 사용하여 중심극한정리가 성립하는지 살펴보도록 하자.

중심극한정리 - 계속

- 시뮬레이션을 사용하여 중심극한정리가 성립하는지 살펴보도록 하자.
- 다음 시뮬레이션에서는 0부터 1까지의 균일 분포(uniform distribution)의 표본을 각각 1번, 2번, 10번 생성하여 그 합의 분포를 보았다. 여기에서는 0부터 1까지의 균일 분포의 기댓값이 $1/2$, 분산이 $1/12$ 라는 사실을 이용했다.

중심극한정리 - 계속

- 시뮬레이션을 사용하여 중심극한정리가 성립하는지 살펴보도록 하자.
- 다음 시뮬레이션에서는 0부터 1까지의 균일 분포(uniform distribution)의 표본을 각각 1번, 2번, 10번 생성하여 그 합의 분포를 보았다. 여기에서는 0부터 1까지의 균일 분포의 기댓값이 $1/2$, 분산이 $1/12$ 라는 사실을 이용했다.
- (파이썬 코드)


```
import scipy as sp
import scipy.stats
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

np.random.seed(0)
xx = np.linspace(-2, 2, 100)
plt.figure(figsize=(6, 9))
for i, N in enumerate([1, 2, 10]):
    X = np.random.rand(5000, N)
    Xbar = (X.mean(axis=1) - 0.5) * np.sqrt(12 * N)
    ax = plt.subplot(3, 2, 2 * i + 1)
    sns.distplot(Xbar, bins=10, kde=False, norm_hist=True)
    plt.xlim(-5, 5)
    plt.yticks([])
    ax.set_title("N = {0}".format(N))
    plt.subplot(3, 2, 2 * i + 2)
    sp.stats.probplot(Xbar, plot=plt)

plt.tight_layout()
plt.show()
```

중심극한정리 - 계속

● (파이썬 코드)



정규분포의 통계량 분포

- 그렇다면 임의의 분포가 아닌 복수의 정규분포로부터 얻은 표본 데이터로 구한 표본평균은 어떤 분포를 가지게 될까?

N 개의 정규분포로부터 얻은 표본의 합은 기댓값이 $N\mu$, 분산이 $N\sigma^2$ 인 정규분포다.

$$x_i \sim \mathcal{N}(\mu, \sigma^2) \quad \rightarrow \quad \sum_{i=1}^N x_i \sim \mathcal{N}(N\mu, N\sigma^2)$$

정규분포의 통계량 분포

- 그렇다면 임의의 분포가 아닌 복수의 정규분포로부터 얻은 표본 데이터로 구한 표본평균은 어떤 분포를 가지게 될까?

N 개의 정규분포로부터 얻은 표본의 합은 기댓값이 $N\mu$, 분산이 $N\sigma^2$ 인 정규분포다.

$$x_i \sim \mathcal{N}(\mu, \sigma^2) \quad \rightarrow \quad \sum_{i=1}^N x_i \sim \mathcal{N}(N\mu, N\sigma^2)$$

- 정규분포의 표본에 상수를 빼거나 곱해도 정규분포다. 이 경우에도 위와 같이 기댓값이 0, 표준편차가 1이 되도록 정규화를 하면 다음과 같이 쓸 수 있다.

$$x_i \sim \mathcal{N}(\mu, \sigma^2) \quad \rightarrow \quad z = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{N}}} \sim \mathcal{N}(z; 0, 1)$$

정규분포의 통계량 분포

- 그렇다면 임의의 분포가 아닌 복수의 정규분포로부터 얻은 표본 데이터로 구한 표본평균은 어떤 분포를 가지게 될까?

N 개의 정규분포로부터 얻은 표본의 합은 기댓값이 $N\mu$, 분산이 $N\sigma^2$ 인 정규분포다.

$$x_i \sim \mathcal{N}(\mu, \sigma^2) \rightarrow \sum_{i=1}^N x_i \sim \mathcal{N}(N\mu, N\sigma^2)$$

- 정규분포의 표본에 상수를 빼거나 곱해도 정규분포다. 이 경우에도 위와 같이 기댓값이 0, 표준편차가 1이 되도록 정규화를 하면 다음과 같이 쓸 수 있다.

$$x_i \sim \mathcal{N}(\mu, \sigma^2) \rightarrow z = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{N}}} \sim \mathcal{N}(z; 0, 1)$$

- 정규분포 표본의 평균을 정규화한 통계량을 z 통계량이라고 한다. 중심극한정리와 다른 점에 주의해야 한다. 중심극한정리에서는 표준정규분포로 점점 다가갈 뿐이고 표본 개수가 무한대가 되기 전에는 정확한 정규분포가 아니지만 z 통계량은 개수 N 에 상관없이 항상 정확하게 표준정규분포이다.

선형회귀모형과 정규분포

- 정규분포는 선형회귀모형에서 잡음(disturbance)을 모형화하는데 사용된다. 선형회귀모형은 입력변수 $x_1, x_2, \dots, x_N$ 이 종속변수 y 에 선형적으로 영향을 미치는 모형이다.

$$\hat{y} = w_1x_1 + \dots + w_Nx_N \approx y$$

선형회귀모형과 정규분포

- 정규분포는 선형회귀모형에서 잡음(disturbance)을 모형화하는데 사용된다. 선형회귀모형은 입력변수 $x_1, x_2, \dots, x_N$ 이 종속변수 y 에 선형적으로 영향을 미치는 모형이다.

$$\hat{y} = w_1x_1 + \dots + w_Nx_N \approx y$$

- 이 모형은 다음과 같이 표현할 수 있다.

$$y = w_1x_1 + \dots + w_Nx_N + \epsilon$$

선형회귀모형과 정규분포

- 정규분포는 선형회귀모형에서 잡음(disturbance)을 모형화하는데 사용된다. 선형회귀모형은 입력변수 $x_1, x_2, \dots, x_N$ 이 종속변수 y 에 선형적으로 영향을 미치는 모형이다.

$$\hat{y} = w_1x_1 + \dots + w_Nx_N \approx y$$

- 이 모형은 다음과 같이 표현할 수 있다.

$$y = w_1x_1 + \dots + w_Nx_N + \epsilon$$

- ϵ 은 잡음이라고 하며 우리가 값을 측정할 수 없는 양을 뜻한다. 예측값과 실제값의 차이를 뜻하는 잔차(residual)와는 다르다.

선형회귀모형과 정규분포

- 정규분포는 선형회귀모형에서 잡음(disturbance)을 모형화하는데 사용된다. 선형회귀모형은 입력변수 $x_1, x_2, \dots, x_N$ 이 종속변수 y 에 선형적으로 영향을 미치는 모형이다.

$$\hat{y} = w_1x_1 + \dots + w_Nx_N \approx y$$

- 이 모형은 다음과 같이 표현할 수 있다.

$$y = w_1x_1 + \dots + w_Nx_N + \epsilon$$

- ϵ 은 잡음이라고 하며 우리가 값을 측정할 수 없는 양을 뜻한다. 예측값과 실제값의 차이를 뜻하는 잔차(residual)와는 다르다.
- 잡음은 선형회귀모형을 만들 때 하나하나의 영향력이 작거나 일일이 측정하기 힘들어서 무시하는 수많은 변수들의 영향을 하나로 합친 것이다. 즉 원래 y 값은 $x_1, x_2, \dots, x_N, \dots$ 의 거의 무한한 개수의 입력변수의 영향을 받는다.

$$y = w_1x_1 + \dots + w_Nx_N + w_{N+1}x_{N+1} + \dots$$

선형회귀모형과 정규분포

- 정규분포는 선형회귀모형에서 잡음(disturbance)을 모형화하는데 사용된다. 선형회귀모형은 입력변수 $x_1, x_2, \dots, x_N$ 이 종속변수 y 에 선형적으로 영향을 미치는 모형이다.

$$\hat{y} = w_1x_1 + \dots + w_Nx_N \approx y$$

- 이 모형은 다음과 같이 표현할 수 있다.

$$y = w_1x_1 + \dots + w_Nx_N + \epsilon$$

- ϵ 은 잡음이라고 하며 우리가 값을 측정할 수 없는 양을 뜻한다. 예측값과 실제값의 차이를 뜻하는 잔차(residual)와는 다르다.
- 잡음은 선형회귀모형을 만들 때 하나하나의 영향력이 작거나 일일이 측정하기 힘들어서 무시하는 수많은 변수들의 영향을 하나로 합친 것이다. 즉 원래 y 값은 $x_1, x_2, \dots, x_N, \dots$ 의 거의 무한한 개수의 입력변수의 영향을 받는다.

$$y = w_1x_1 + \dots + w_Nx_N + w_{N+1}x_{N+1} + \dots$$

- 하지만 이 중에서 입력변수 $x_1, x_2, \dots, x_N$ 만이 영향력이 크거나 측정이 쉽다면 다른 변수의 영향은 하나의 확률변수라고 합쳐서 표현할 수 있다.

$$\epsilon = w_{N+1}x_{N+1} + \dots$$

선형회귀모형과 정규분포

- 중심극한정리에 의해 임의의 확률변수의 합은 정규분포와 비슷한 형태가 된다. 또한 ϵ 의 기댓값이 0이 아니라면 다음처럼 상수항 $w_0 = E[\epsilon]$ 을 추가하는 대신 ϵ 의 기댓값이 0이라고 할 수 있기 때문에

$$y = w_0 + w_1x_1 + \cdots + w_Nx_N + \epsilon$$

선형회귀모형과 정규분포

- 중심극한정리에 의해 임의의 확률변수의 합은 정규분포와 비슷한 형태가 된다. 또한 ϵ 의 기댓값이 0이 아니라면 다음처럼 상수항 $w_0 = E[\epsilon]$ 을 추가하는 대신 ϵ 의 기댓값이 0이라고 할 수 있기 때문에

$$y = w_0 + w_1 x_1 + \cdots + w_N x_N + \epsilon$$

- 잡음 ϵ 이 기댓값이 0인 정규분포라고 가정하는 것은 합리적이다.

$$\epsilon \sim \mathcal{N}(0, \sigma^2)$$

선형회귀모형과 정규분포

- 중심극한정리에 의해 임의의 확률변수의 합은 정규분포와 비슷한 형태가 된다. 또한 ϵ 의 기댓값이 0이 아니라면 다음처럼 상수항 $w_0 = E[\epsilon]$ 을 추가하는 대신 ϵ 의 기댓값이 0이라고 할 수 있기 때문에

$$y = w_0 + w_1x_1 + \cdots + w_Nx_N + \epsilon$$

- 잡음 ϵ 이 기댓값이 0인 정규분포라고 가정하는 것은 합리적이다.

$$\epsilon \sim \mathcal{N}(0, \sigma^2)$$

- (그림. 선형회귀모형과 정규분포)

