

1 4.6 베타분포, 감마분포, 디리클레분포

개요

- 베타분포, 감마분포, 디리클레분포는 모숫값을 조정하여 분포의 모양을 우리가 원하는대로 쉽게 바꿀 수 있다.

베타분포

개요

- 베타분포, 감마분포, 디리클레분포는 모숫값을 조정하여 분포의 모양을 우리가 원하는대로 쉽게 바꿀 수 있다.
- 모숫값은 분포 모양을 조절하는 조절값이라고 생각하면 된다.

베타분포

개요

- 베타분포, 감마분포, 디리클레분포는 모숫값을 조정하여 분포의 모양을 우리가 원하는대로 쉽게 바꿀 수 있다.
- 모숫값은 분포 모양을 조절하는 조절값이라고 생각하면 된다.
- 이러한 특성때문에 이 분포들은 데이터가 이루는 분포를 표현하기보다는 베이지안 확률론의 관점에서 어떤 값에 대해 우리가 가지고 있는 확신 혹은 신뢰의 정도를 표현하는데 주로 사용된다.

베타분포

개요

- 베타분포, 감마분포, 디리클레분포는 모숫값을 조정하여 분포의 모양을 우리가 원하는대로 쉽게 바꿀 수 있다.
- 모숫값은 분포 모양을 조절하는 조절값이라고 생각하면 된다.
- 이러한 특성때문에 이 분포들은 데이터가 이루는 분포를 표현하기보다는 베이저안 확률론의 관점에서 어떤 값에 대해 우리가 가지고 있는 확신 혹은 신뢰의 정도를 표현하는데 주로 사용된다.

베타분포

- **베타분포**(Beta distribution)는 a 와 b ($a, b > 0$)라는 두 모수를 가지며 표본 공간은 0과 1사이의 실수다. 즉 0과 1 사이의 표본값만 가질 수 있다. 베타분포의 확률밀도함수는 다음과 같다.

$$\text{Beat}(x; a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}, \quad 0 \leq x \leq 1$$

이 식에서 $\Gamma(a)$ 는 감마함수(Gamma function)라는 특수함수로 다음처럼 정의된다.


$$\Gamma(a) = \int_0^{\infty} x^{a-1} e^{-x} dx$$

베타분포 - 계속

- 여러 모수 a, b , 값에 대해 베타분포의 모양을 그려보면 다음과 같다.

```
import numpy as np
import scipy as sp
import scipy.stats
import matplotlib.pyplot as plt

xx = np.linspace(0, 1, 1000)
plt.subplot(221)
plt.fill_between(xx, sp.stats.beta(1.0001, 1.0001).pdf(xx))
plt.ylim(0, 6)
plt.title("(A) a=1, b=1")
plt.subplot(222)
plt.fill_between(xx, sp.stats.beta(4, 2).pdf(xx))
plt.ylim(0, 6)
plt.title("(B) a=4, b=2, mode={0}".format((4-1)/(4+2-2)))
plt.subplot(223)
plt.fill_between(xx, sp.stats.beta(8, 4).pdf(xx))
plt.ylim(0, 6)
plt.title("(C) a=8, b=4, mode={0}".format((8-1)/(8+4-2)))
plt.subplot(224)
plt.fill_between(xx, sp.stats.beta(30, 12).pdf(xx))
plt.ylim(0, 6)
plt.title("(D) a=30, b=12, mode={0}".format((30-1)/(30+12-2)))
plt.tight_layout()
plt.show()
```



베타분포 - 계속

- 이 그림으로부터 모수 a, b 가 베타분포의 모양을 결정하는 형상 인자(shape factor)라는 것을 알 수 있다. 베타분포의 기댓값, 최빈값, 분산은 각각 다음과 같다.

- 기댓값: $E[x] = \frac{a}{a+b}$

- 최빈값 - 확률분포가 가장 커지는 위치:

$$mod = \begin{cases} \frac{a-1}{a+b-2}, & \text{if } a, b > 1 \\ (0, 1) \text{에 있는 임의의 값}, & \text{if } a, b = 1 \\ \{0, 1\} \text{ (bimodal)}, & \text{if } a, b < 1 \\ 0, & \text{if } a \leq 1, b > 1 \\ 1, & \text{if } a > 1, b \leq 1. \end{cases}$$

- 분산 - 확률분포의 폭: $Var[x] = \frac{ab}{(a+b)^2(a+b+1)}$

베타분포 - 계속

- 이 그림으로부터 모수 a, b 가 베타분포의 모양을 결정하는 형상 인자(shape factor)라는 것을 알 수 있다. 베타분포의 기댓값, 최빈값, 분산은 각각 다음과 같다.

- 기댓값: $E[x] = \frac{a}{a+b}$

- 최빈값 - 확률분포가 가장 커지는 위치:

$$mod = \begin{cases} \frac{a-1}{a+b-2}, & \text{if } a, b > 1 \\ (0, 1) \text{에 있는 임의의 값}, & \text{if } a, b = 1 \\ \{0, 1\} \text{ (bimodal)}, & \text{if } a, b < 1 \\ 0, & \text{if } a \leq 1, b > 1 \\ 1, & \text{if } a > 1, b \leq 1. \end{cases}$$

- 분산 - 확률분포의 폭: $Var[x] = \frac{ab}{(a+b)^2(a+b+1)}$

- 최빈값 수식을 보면 $a = b$ 일 때 $x = 0.5$ 에서 가장 확률밀도가 커지는 것을 알 수 있다.

베타분포 - 계속

- 이 그림으로부터 모수 a, b 가 베타분포의 모양을 결정하는 형상 인자(shape factor)라는 것을 알 수 있다. 베타분포의 기댓값, 최빈값, 분산은 각각 다음과 같다.

- 기댓값: $E[x] = \frac{a}{a+b}$

- 최빈값 - 확률분포가 가장 커지는 위치:

$$mod = \begin{cases} \frac{a-1}{a+b-2}, & \text{if } a, b > 1 \\ (0, 1) \text{에 있는 임의의 값}, & \text{if } a, b = 1 \\ \{0, 1\} \text{ (bimodal)}, & \text{if } a, b < 1 \\ 0, & \text{if } a \leq 1, b > 1 \\ 1, & \text{if } a > 1, b \leq 1. \end{cases}$$

- 분산 - 확률분포의 폭: $Var[x] = \frac{ab}{(a+b)^2(a+b+1)}$

- 최빈값 수식을 보면 $a = b$ 일 때 $x = 0.5$ 에서 가장 확률밀도가 커지는 것을 알 수 있다.
- 또한 분산 수식에서 분모가 3차식, 분자가 2차식이기 때문에 a, b 의 값이 커질수록 분산 즉, 확률분포의 폭이 작아진다.

베타분포와 베이지안 추정

- 베타분포는 0부터 1까지의 값을 가질 수 있는 베르누이분포의 모수 μ 의 값을 베이지안 추정한 결과를 표현한 것이다.

베타분포와 베이지안 추정

- 베타분포는 0부터 1까지의 값을 가질 수 있는 베르누이분포의 모수 μ 의 값을 베이지안 추정한 결과를 표현한 것이다.
- 베이지안 추정은 모수가 가질 수 있는 모든 값에 대해 가능성을 확률분포로 나타낸 것을 말한다.

베타분포와 베이지안 추정

- 베타분포는 0부터 1까지의 값을 가질 수 있는 베르누이분포의 모수 μ 의 값을 베이지안 추정한 결과를 표현한 것이다.
- 베이지안 추정은 모수가 가질 수 있는 모든 값에 대해 가능성을 확률분포로 나타낸 것을 말한다.
- 실제로 베르누이분포의 모수를 베이지안 추정하는 것은 나중에 다루게 된다. 여기에서는 결과만 보인다.

베타분포와 베이지안 추정

- 베타분포는 0부터 1까지의 값을 가질 수 있는 베르누이분포의 모수 μ 의 값을 베이지안 추정한 결과를 표현한 것이다.
- 베이지안 추정은 모수가 가질 수 있는 모든 값에 대해 가능성을 확률분포로 나타낸 것을 말한다.
- 실제로 베르누이분포의 모수를 베이지안 추정하는 것은 나중에 다루게 된다. 여기에서는 결과만 보인다.
- 위 그림이 베이지안 추정 결과라면 각각은 베르누이분포의 모수 μ 에 대해 다음과 같이 추정한 것과 같다.

베타분포와 베이지안 추정

- 베타분포는 0부터 1까지의 값을 가질 수 있는 베르누이분포의 모수 μ 의 값을 베이지안 추정한 결과를 표현한 것이다.
- 베이지안 추정은 모수가 가질 수 있는 모든 값에 대해 가능성을 확률분포로 나타낸 것을 말한다.
- 실제로 베르누이분포의 모수를 베이지안 추정하는 것은 나중에 다루게 된다. 여기에서는 결과만 보인다.
- 위 그림이 베이지안 추정 결과라면 각각은 베르누이분포의 모수 μ 에 대해 다음과 같이 추정한 것과 같다.

(A): 베르누이분포의 모수 μ 를 추정할 수 없다. (정보가 없음)

베타분포와 베이지안 추정

- 베타분포는 0부터 1까지의 값을 가질 수 있는 베르누이분포의 모수 μ 의 값을 베이지안 추정한 결과를 표현한 것이다.
- 베이지안 추정은 모수가 가질 수 있는 모든 값에 대해 가능성을 확률분포로 나타낸 것을 말한다.
- 실제로 베르누이분포의 모수를 베이지안 추정하는 것은 나중에 다루게 된다. 여기에서는 결과만 보인다.
- 위 그림이 베이지안 추정 결과라면 각각은 베르누이분포의 모수 μ 에 대해 다음과 같이 추정한 것과 같다.
 - (A): 베르누이분포의 모수 μ 를 추정할 수 없다. (정보가 없음)
 - (B): 베르누이분포의 모수 μ 값이 0.75일 가능성이 가장 크다. (정확도 낮음)

베타분포와 베이지안 추정

- 베타분포는 0부터 1까지의 값을 가질 수 있는 베르누이분포의 모수 μ 의 값을 베이지안 추정한 결과를 표현한 것이다.
- 베이지안 추정은 모수가 가질 수 있는 모든 값에 대해 가능성을 확률분포로 나타낸 것을 말한다.
- 실제로 베르누이분포의 모수를 베이지안 추정하는 것은 나중에 다루게 된다. 여기에서는 결과만 보인다.
- 위 그림이 베이지안 추정 결과라면 각각은 베르누이분포의 모수 μ 에 대해 다음과 같이 추정한 것과 같다.
 - (A): 베르누이분포의 모수 μ 를 추정할 수 없다. (정보가 없음)
 - (B): 베르누이분포의 모수 μ 값이 0.75일 가능성이 가장 크다. (정확도 낮음)
 - (C): 베르누이분포의 모수 μ 값이 0.70일 가능성이 가장 크다. (정확도 중간)

베타분포와 베이지안 추정

- 베타분포는 0부터 1까지의 값을 가질 수 있는 베르누이분포의 모수 μ 의 값을 베이지안 추정한 결과를 표현한 것이다.
- 베이지안 추정은 모수가 가질 수 있는 모든 값에 대해 가능성을 확률분포로 나타낸 것을 말한다.
- 실제로 베르누이분포의 모수를 베이지안 추정하는 것은 나중에 다루게 된다. 여기에서는 결과만 보인다.
- 위 그림이 베이지안 추정 결과라면 각각은 베르누이분포의 모수 μ 에 대해 다음과 같이 추정한 것과 같다.
 - (A): 베르누이분포의 모수 μ 를 추정할 수 없다. (정보가 없음)
 - (B): 베르누이분포의 모수 μ 값이 0.75일 가능성이 가장 크다. (정확도 낮음)
 - (C): 베르누이분포의 모수 μ 값이 0.70일 가능성이 가장 크다. (정확도 중간)
 - (D): 베르누이분포의 모수 μ 이 0.725일 가능성이 가장 크다. (정확도 높음)

감마분포

- 감마분포(Gamma distribution)도 베타분포처럼 모수의 베이지안 추정에 사용된다.

감마분포

- 감마분포(Gamma distribution)도 베타분포처럼 모수의 베이지안 추정에 사용된다.
- 다만 베타분포가 0부터 1 사이값을 가지는 모수를 베이지안 방법으로 추정하는데 사용되는 것과 달리 감마분포는 0부터 무한대의 값을 가지는 양수 값을 추정하는 데 사용된다.

감마분포

- **감마분포**(Gamma distribution)도 베타분포처럼 모수의 베이지안 추정에 사용된다.
- 다만 베타분포가 0부터 1 사이값을 가지는 모수를 베이지안 방법으로 추정하는데 사용되는 것과 달리 감마분포는 0부터 무한대의 값을 가지는 양수 값을 추정하는 데 사용된다.
- 감마분포의 확률 밀도 함수는 a 와 b 라는 두 모수를 가지며 수학적으로 다음과 같이 정의된다.

$$\text{Gam}(x; a, b) = \frac{1}{\Gamma(a)} b^a x^{a-1} e^{-bx}$$

감마분포 - 계속


- 감마분포의 확률 밀도 함수는 모수 a, b 의 값에 따라 다음과 같은 형상을 가진다.

감마분포 - 계속

- 감마분포의 확률 밀도 함수는 모수 a, b 의 값에 따라 다음과 같은 형상을 가진다.
- 사이파이의 stats 서브패키지에서 제공하는 gamma 클래스는 모수 $b = 1$ 로 고정되어 a 값만 설정할 수 있다. b 를 바꾸려면 x 값 스케일과 계수를 수동으로 설정하여야 한다.

```
import numpy as np
import scipy as sp
import scipy.stats
import matplotlib.pyplot as plt

xx = np.linspace(0, 16, 100)
plt.subplot(221)
plt.fill_between(xx, sp.stats.gamma(8).pdf(xx))
plt.ylim(0, 0.4)
plt.title("(A) a=9, b=1, mode=7")
plt.subplot(222)
plt.fill_between(xx, sp.stats.gamma(6).pdf(xx))
plt.ylim(0, 0.4)
plt.title("(B) a=6, b=1, mode=5")
plt.subplot(223)
plt.fill_between(xx, sp.stats.gamma(3).pdf(xx))
plt.ylim(0, 0.4)
plt.title("(C) a=3, b=1, mode=2")
plt.subplot(224)
plt.fill_between(xx, sp.stats.gamma(2).pdf(xx))
plt.ylim(0, 0.4)
plt.title("(D) a=2, b=1, mode=1")
plt.tight_layout()
plt.show()
```



감마분포와 베이지안 추정

- 위 그림이 베이지안 추정 결과라면 각각은 모수에 대해 다음과 같이 추정한 것과 같다.

감마분포와 베이지안 추정

- 위 그림이 베이지안 추정 결과라면 각각은 모수에 대해 다음과 같이 추정한 것과 같다.
(A): 추정하고자 하는 모숫값이 8일 가능성이 가장 크다. (정확도 아주 낮음)

감마분포와 베이지안 추정

- 위 그림이 베이지안 추정 결과라면 각각은 모수에 대해 다음과 같이 추정한 것과 같다.
 - (A): 추정하고자 하는 모숫값이 8일 가능성이 가장 크다. (정확도 아주 낮음)
 - (B): 추정하고자 하는 모숫값이 5일 가능성이 가장 크다. (정확도 낮음)

감마분포와 베이지안 추정

- 위 그림이 베이지안 추정 결과라면 각각은 모수에 대해 다음과 같이 추정한 것과 같다.
 - (A): 추정하고자 하는 모숫값이 8일 가능성이 가장 크다. (정확도 아주 낮음)
 - (B): 추정하고자 하는 모숫값이 5일 가능성이 가장 크다. (정확도 낮음)
 - (C): 추정하고자 하는 모숫값이 2일 가능성이 가장 크다. (정확도 높음)

감마분포와 베이지안 추정

- 위 그림이 베이지안 추정 결과라면 각각은 모수에 대해 다음과 같이 추정한 것과 같다.
 - (A): 추정하고자 하는 모숫값이 8일 가능성이 가장 크다. (정확도 아주 낮음)
 - (B): 추정하고자 하는 모숫값이 5일 가능성이 가장 크다. (정확도 낮음)
 - (C): 추정하고자 하는 모숫값이 2일 가능성이 가장 크다. (정확도 높음)
 - (D): 추정하고자 하는 모숫값이 1일 가능성이 가장 크다. (정확도 아주 높음)

감마분포와 베이지안 추정

- 위 그림이 베이지안 추정 결과라면 각각은 모수에 대해 다음과 같이 추정한 것과 같다.
 - (A): 추정하고자 하는 모숫값이 8일 가능성이 가장 크다. (정확도 아주 낮음)
 - (B): 추정하고자 하는 모숫값이 5일 가능성이 가장 크다. (정확도 낮음)
 - (C): 추정하고자 하는 모숫값이 2일 가능성이 가장 크다. (정확도 높음)
 - (D): 추정하고자 하는 모숫값이 1일 가능성이 가장 크다. (정확도 아주 높음)
- 감마분포의 기댓값, 최빈값, 분산은 각각 다음과 같다.
 - 기댓값: $E[x] = \frac{a}{b}$
 - 최빈값 - 확률분포가 가장 커지는 위치: $mod = \frac{a-1}{b}$
 - 분산 - 확률분포의 폭: $Var[x] = \frac{a}{b^2}$

디리클레분포

- 디리클레분포(Dirichlet distribution)는 베타분포의 확장판이라고 할 수 있다. 베타분포는 0과 1사이의 값을 가지는 단일(univariate) 확률변수의 베이지안 모형에 사용되고 디리클레분포는 0과 1사이의 사이의 값을 가지는 다변수(multivariate) 확률 변수의 베이지안 모형에 사용된다.

디리클레분포

- 디리클레분포(Dirichlet distribution)는 베타분포의 확장판이라고 할 수 있다. 베타분포는 0과 1사이의 값을 가지는 단일(univariate) 확률변수의 베이지안 모형에 사용되고 디리클레분포는 0과 1사이의 사이의 값을 가지는 다변수(multivariate) 확률 변수의 베이지안 모형에 사용된다.
- 예를 들어 $K = 3$ 인 디리클레분포를 따르는 확률변수는 다음과 같은 값들을 표본으로 가질 수 있다.

$$(0.2, 0.3, 0.5), \quad (0.5, 0.5, 0), \quad (1, 0, 0)$$

디리클레분포

- 디리클레분포(Dirichlet distribution)는 베타분포의 확장판이라고 할 수 있다. 베타분포는 0과 1사이의 값을 가지는 단일(univariate) 확률변수의 베이지안 모형에 사용되고 디리클레분포는 0과 1사이의 사이의 값을 가지는 다변수(multivariate) 확률 변수의 베이지안 모형에 사용된다.
- 예를 들어 $K = 3$ 인 디리클레분포를 따르는 확률변수는 다음과 같은 값들을 표본으로 가질 수 있다.

$$(0.2, 0.3, 0.5), \quad (0.5, 0.5, 0), \quad (1, 0, 0)$$

- 디리클레분포의 확률밀도함수는 다음과 같다. ($0 \leq x_i \leq 1$, $\sum_{i=1}^K x_i = 1$)

$$\begin{aligned} \text{Dir}(x; \alpha) &= \text{Dir}(x_1, \dots, x_K; \alpha_1, \dots, \alpha_K) \\ &= \frac{1}{B(\alpha_1, \dots, \alpha_K)} \prod_{i=1}^K x_i^{\alpha_i - 1} \end{aligned}$$

이 식에서 $x = (x_1, \dots, x_K)$ 는 디리클레분포의 표본값 벡터이고 $\alpha = (\alpha_1, \dots, \alpha_K)$ 는 모수 벡터다. $B(\alpha_1, \dots, \alpha_K)$ 는 베타함수라는 특수함수로 다음처럼 정의한다.

$$B(\alpha_1, \dots, \alpha_K) = \frac{\prod_{i=1}^K \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^K \alpha_i)}$$

베타분포와 디리클레분포의 관계

- 베타분포는 $K = 2$ 인 디리클레분포라고 볼 수 있다.

베타분포와 디리클레분포의 관계

- 베타분포는 $K = 2$ 인 디리클레분포라고 볼 수 있다.
- 즉 $x_1 = x, x_2 = 1 - x, \alpha_1 = a, \alpha_2 = b$ 로 하면

$$\begin{aligned}
 \text{Beta}(x; a, b) &= \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} \\
 &= \frac{\Gamma(\alpha_1 + \alpha_2)}{\Gamma(\alpha_1)\Gamma(\alpha_2)} x^{\alpha_1-1} (1-x)^{\alpha_2-1} \\
 &= \frac{1}{B(\alpha_1, \alpha_2)} \prod_{i=1}^2 x_i^{\alpha_i-1}
 \end{aligned}$$

디리클레분포의 모멘트

- 디리클레분포의 기댓값, 최빈값, 분산은 다음과 같다.

- 기댓값: $E[x_k] = \frac{\alpha_k}{\sum \alpha}$

- 최빈값 - 확률분포가 가장 커지는 위치: $mod = \frac{\alpha_k - 1}{\sum \alpha - K}$

- 분산 - 확률분포의 폭: $Var[x_k] = \frac{\alpha_k(\sum \alpha - \alpha_k)}{(\sum \alpha)^2(\sum \alpha + 1)}$

디리클레분포의 모멘트

- 디리클레분포의 기댓값, 최빈값, 분산은 다음과 같다.
 - 기댓값: $E[x_k] = \frac{\alpha_k}{\sum \alpha}$
 - 최빈값 - 확률분포가 가장 커지는 위치: $mod = \frac{\alpha_k - 1}{\sum \alpha - K}$
 - 분산 - 확률분포의 폭: $Var[x_k] = \frac{\alpha_k(\sum \alpha - \alpha_k)}{(\sum \alpha)^2(\sum \alpha + 1)}$
- 기댓값 공식을 보면 모수인 $(\alpha_1, \dots, \alpha_K)$ 는 $(x_1, \dots, x_K)$ 중 어느 수가 더 크게 나올 가능성이 높은지를 결정하는 형상인자(shape factor)임을 알 수 있다. 모든 α_i 값이 동일하면 모든 x_i 의 분포가 같아진다.

디리클레분포의 모멘트

- 디리클레분포의 기댓값, 최빈값, 분산은 다음과 같다.
 - 기댓값: $E[x_k] = \frac{\alpha_k}{\sum \alpha}$
 - 최빈값 - 확률분포가 가장 커지는 위치: $mod = \frac{\alpha_k - 1}{\sum \alpha - K}$
 - 분산 - 확률분포의 폭: $Var[x_k] = \frac{\alpha_k(\sum \alpha - \alpha_k)}{(\sum \alpha)^2(\sum \alpha + 1)}$
- 기댓값 공식을 보면 모수인 $(\alpha_1, \dots, \alpha_K)$ 는 $(x_1, \dots, x_K)$ 중 어느 수가 더 크게 나올 가능성이 높은지를 결정하는 형상인자(shape factor)임을 알 수 있다. 모든 α_i 값이 동일하면 모든 x_i 의 분포가 같아진다.
- 또한 분산 공식을 보면 $(\alpha_1, \dots, \alpha_K)$ 의 절대값이 클수록 분산이 작아진다. 즉, 디리클리 분포의 표본값 x 가 어떤 특정한 값 주변이 나올 가능성이 높아진다.

디리클레분포의 시뮬레이션

```
import numpy as np
from scipy.stats import dirichlet

#디리클레 랜덤 변수 생성
quantiles = np.array([0.2, 0.2, 0.6]) # 확률 변수값 지정(예)
alpha = np.array([0.4, 5, 15]) # 농도 매개변수 (concentration parameters) 지정(예)
print(dirichlet.pdf(quantiles, alpha)) # 확률 변수값과 농도 매개변수에 대한 확률
print(dirichlet.logpdf(quantiles, alpha)) # 동일한 PDF이지만 로그 스케일을 따르는 경우

# 디리클레 분포를 지정하면 관심 수량을 계산할 수 있음.
print(dirichlet.mean(alpha)) # 분포의 평균
print(dirichlet.var(alpha)) # 분포의 분산

# 분포에서 무작위 샘플을 반환할 수도 있음.
print(dirichlet.rvs(alpha, size=1, random_state=1))
print(dirichlet.rvs(alpha, size=2, random_state=2))
```