

# 1 5장 추정과 검정

## 개요

- 이 장은 데이터 분석에서 가장 중요한 내용인 추정과 검정을 다룬다.

## 5.1 확률분포의 추정

## 개요

- 이 장은 데이터 분석에서 가장 중요한 내용인 추정과 검정을 다룬다.
- 추정은 데이터로부터 확률분포를 찾아내는 역설계 과정이다. 추정을 통해 데이터는 확률변수로 거듭나게 된다.

### 5.1 확률분포의 추정

## 개요

- 이 장은 데이터 분석에서 가장 중요한 내용인 추정과 검정을 다룬다.
- 추정은 데이터로부터 확률분포를 찾아내는 역설계 과정이다. 추정을 통해 데이터는 확률변수로 거듭나게 된다.
- 검정은 이러한 추정이 어느 정도의 신뢰성을 가졌는지 알아보는 과정이다. 검정을 통해 추정 결과가 믿을만한지 아니면 믿을만한 추정을 위해 데이터가 더 필요한지를 알 수 있다.

### 5.1 확률분포의 추정

## 개요

- 이 장은 데이터 분석에서 가장 중요한 내용인 추정과 검정을 다룬다.
- 추정은 데이터로부터 확률분포를 찾아내는 역설계 과정이다. 추정을 통해 데이터는 확률변수로 거듭나게 된다.
- 검정은 이러한 추정이 어느 정도의 신뢰성을 가졌는지 알아보는 과정이다. 검정을 통해 추정 결과가 믿을만한지 아니면 믿을만한 추정을 위해 데이터가 더 필요한지를 알 수 있다.

### 5.1 확률분포의 추정

- '분석하고자 하는 데이터가 어떤 확률변수로부터 실현된 표본이다'는 데이터 분석의 첫 번째 가정이다. 이 말은 우리가 정말 관심이 있는 것이 지금 손에 가지고 있는 데이터 즉, 하나의 실현체에 불과한 표본이 아니라 그 뒤에서 이 데이터를 만들어내는 확률변수의 분포라는 뜻이다.

## 개요

- 이 장은 데이터 분석에서 가장 중요한 내용인 추정과 검정을 다룬다.
- 추정은 데이터로부터 확률분포를 찾아내는 역설계 과정이다. 추정을 통해 데이터는 확률변수로 거듭나게 된다.
- 검정은 이러한 추정이 어느 정도의 신뢰성을 가졌는지 알아보는 과정이다. 검정을 통해 추정 결과가 믿을만한지 아니면 믿을만한 추정을 위해 데이터가 더 필요한지를 알 수 있다.

### 5.1 확률분포의 추정

- '분석하고자 하는 데이터가 어떤 확률변수로부터 실현된 표본이다'는 데이터 분석의 첫 번째 가정이다. 이 말은 우리가 정말 관심이 있는 것이 지금 손에 가지고 있는 데이터 즉, 하나의 실현체에 불과한 표본이 아니라 그 뒤에서 이 데이터를 만들어내는 확률변수의 분포라는 뜻이다.
- 확률론적인 관점에서 볼 때 데이터는 이 확률변수의 분포를 알아내기 위한 일련의 참고 자료일 뿐이다. 따라서 우리는 데이터 즉 표본으로부터 확률변수의 분포를 알아내야 한다.

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.



## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.
  2. 데이터로부터 해당 확률분포의 모수의 값을 구한다.

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.
  2. 데이터로부터 해당 확률분포의 모수의 값을 구한다.
- 첫 번째 작업 즉, 확률변수가 어떤 확률분포를 따르는가는 데이터가 생성되는 원리를 알거나 데이터의 특성을 알면 추측할 수 있다. 히스토그램을 그려서 확률분포의 모양을 살펴보고 힌트를 얻을 수도 있다.

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.
  2. 데이터로부터 해당 확률분포의 모수의 값을 구한다.
- 첫 번째 작업 즉, 확률변수가 어떤 확률분포를 따르는가는 데이터가 생성되는 원리를 알거나 데이터의 특성을 알면 추측할 수 있다. 히스토그램을 그려서 확률분포의 모양을 살펴보고 힌트를 얻을 수도 있다.
  - 데이터는 0 또는 1 뿐이다. → 베르누이분포

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.
  2. 데이터로부터 해당 확률분포의 모수의 값을 구한다.
- 첫 번째 작업 즉, 확률변수가 어떤 확률분포를 따르는가는 데이터가 생성되는 원리를 알거나 데이터의 특성을 알면 추측할 수 있다. 히스토그램을 그려서 확률분포의 모양을 살펴보고 힌트를 얻을 수도 있다.
  - 데이터는 0 또는 1 뿐이다. → 베르누이분포
  - 데이터는 카테고리 값이어야 한다. → 카테고리분포

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.
  2. 데이터로부터 해당 확률분포의 모수의 값을 구한다.
- 첫 번째 작업 즉, 확률변수가 어떤 확률분포를 따르는가는 데이터가 생성되는 원리를 알거나 데이터의 특성을 알면 추측할 수 있다. 히스토그램을 그려서 확률분포의 모양을 살펴보고 힌트를 얻을 수도 있다.
  - 데이터는 0 또는 1 뿐이다. → 베르누이분포
  - 데이터는 카테고리 값이어야 한다. → 카테고리분포
  - 데이터는 0과 1 사이의 실수 값이어야 한다. → 베타분포

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.
  2. 데이터로부터 해당 확률분포의 모수의 값을 구한다.
- 첫 번째 작업 즉, 확률변수가 어떤 확률분포를 따르는가는 데이터가 생성되는 원리를 알거나 데이터의 특성을 알면 추측할 수 있다. 히스토그램을 그려서 확률분포의 모양을 살펴보고 힌트를 얻을 수도 있다.
  - 데이터는 0 또는 1 뿐이다. → 베르누이분포
  - 데이터는 카테고리 값이어야 한다. → 카테고리분포
  - 데이터는 0과 1 사이의 실수 값이어야 한다. → 베타분포
  - 데이터는 항상 0 또는 양수이어야 한다. → 로그정규분포, 감마분포, F분포, 카이제곱분포, 지수분포, 하프코시분포 등

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.
  2. 데이터로부터 해당 확률분포의 모수의 값을 구한다.
- 첫 번째 작업 즉, 확률변수가 어떤 확률분포를 따르는가는 데이터가 생성되는 원리를 알거나 데이터의 특성을 알면 추측할 수 있다. 히스토그램을 그려서 확률분포의 모양을 살펴보고 힌트를 얻을 수도 있다.
  - 데이터는 0 또는 1 뿐이다. → 베르누이분포
  - 데이터는 카테고리 값이어야 한다. → 카테고리분포
  - 데이터는 0과 1 사이의 실수 값이어야 한다. → 베타분포
  - 데이터는 항상 0 또는 양수이어야 한다. → 로그정규분포, 감마분포, F분포, 카이제곱분포, 지수분포, 하프코시분포 등
  - 데이터가 크기 제한이 없는 실수다. → 정규분포 또는 스튜던트 t 분포, 코시분포, 라플라스분포 등

## 확률분포의 결정

- 확률분포를 알아내는 일은 다음처럼 두 작업으로 나뉜다.
  1. 확률변수가 우리가 배운 베르누이분포, 이항분포, 정규분포 등의 기본 분포 중 어떤 확률분포를 따르는지 알아낸다.
  2. 데이터로부터 해당 확률분포의 모수의 값을 구한다.
- 첫 번째 작업 즉, 확률변수가 어떤 확률분포를 따르는가는 데이터가 생성되는 원리를 알거나 데이터의 특성을 알면 추측할 수 있다. 히스토그램을 그려서 확률분포의 모양을 살펴보고 힌트를 얻을 수도 있다.
  - 데이터는 0 또는 1 뿐이다. → 베르누이분포
  - 데이터는 카테고리 값이어야 한다. → 카테고리분포
  - 데이터는 0과 1 사이의 실수 값이어야 한다. → 베타분포
  - 데이터는 항상 0 또는 양수이어야 한다. → 로그정규분포, 감마분포, F분포, 카이제곱분포, 지수분포, 하프코시분포 등
  - 데이터가 크기 제한이 없는 실수다. → 정규분포 또는 스튜던트 t 분포, 코시분포, 라플라스분포 등
- 이 규칙에는 예외가 있을 수 있다. 예를 들어 항상 양수인 데이터인 경우에도 정규분포로 모형화가 가능하다면 정규분포를 사용할 수 있다. 정규분포와 스튜던트 t분포와 같이 둘 중 어느 것인지 구분하기 힘든 경우에는 뒤에서 설명할 정규성 검정이나 KS검정을 사용한다.



## 모수 추정 방법론

- 두번째 작업 즉, 모수의 값으로 가장 가능성이 높은 하나의 숫자를 찾아내는 작업을 모수 추정(parameter estimation)이라고 한다.

## 모멘트 방법

## 모수 추정 방법론

- 두번째 작업 즉, 모수의 값으로 가장 가능성이 높은 하나의 숫자를 찾아내는 작업을 모수 추정(parameter estimation)이라고 한다.
- 모수 추정 방법에는 다음과 같은 방법들이 있다.

## 모멘트 방법

## 모수 추정 방법론

- 두번째 작업 즉, 모수의 값으로 가장 가능성이 높은 하나의 숫자를 찾아내는 작업을 모수 추정(parameter estimation)이라고 한다.
- 모수 추정 방법에는 다음과 같은 방법들이 있다.
  - 모멘트 방법 (이 절)

## 모멘트 방법

## 모수 추정 방법론

- 두번째 작업 즉, 모수의 값으로 가장 가능성이 높은 하나의 숫자를 찾아내는 작업을 모수 추정(parameter estimation)이라고 한다.
- 모수 추정 방법에는 다음과 같은 방법들이 있다.
  - 모멘트 방법 (이 절)
  - 최대가능도 추정법 (다음 절)

## 모멘트 방법

## 모수 추정 방법론

- 두번째 작업 즉, 모수의 값으로 가장 가능성이 높은 하나의 숫자를 찾아내는 작업을 모수 추정(parameter estimation)이라고 한다.
- 모수 추정 방법에는 다음과 같은 방법들이 있다.
  - 모멘트 방법 (이 절)
  - 최대가능도 추정법 (다음 절)
  - 베이즈 추정법 (다음 절)

## 모멘트 방법

## 모수 추정 방법론

- 두번째 작업 즉, 모수의 값으로 가장 가능성이 높은 하나의 숫자를 찾아내는 작업을 모수 추정(parameter estimation)이라고 한다.
- 모수 추정 방법에는 다음과 같은 방법들이 있다.
  - 모멘트 방법 (이 절)
  - 최대가능도 추정법 (다음 절)
  - 베이즈 추정법 (다음 절)

## 모멘트 방법

- 모멘트 방법(method of moment)은 표본자료에 대한 표본모멘트가 확률분포의 이론적 모멘트와 같다고 가정하여 모수를 구한다.

$$\mu = E[X] \triangleq \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

위 식에서  $N$ 은 데이터의 개수,  $x_i$ 는 표본 데이터 이다.

## 모수 추정 방법론

- 두번째 작업 즉, 모수의 값으로 가장 가능성이 높은 하나의 숫자를 찾아내는 작업을 모수 추정(parameter estimation)이라고 한다.
- 모수 추정 방법에는 다음과 같은 방법들이 있다.
  - 모멘트 방법 (이 절)
  - 최대가능도 추정법 (다음 절)
  - 베이즈 추정법 (다음 절)

## 모멘트 방법

- 모멘트 방법(method of moment)은 표본자료에 대한 표본모멘트가 확률분포의 이론적 모멘트와 같다고 가정하여 모수를 구한다.

$$\mu = E[X] \triangleq \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

위 식에서  $N$ 은 데이터의 개수,  $x_i$ 는 표본 데이터 이다.

- 2차 모멘트(분산)의 경우에는 다음과 같다.

$$\sigma^2 = E[(X - \mu)^2] \triangleq \bar{s}^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

## 예제 1. 베르누이분포의 모수 추정

- 모멘트 방법으로 베르누이 확률변수의 모수  $\mu$ 를 구하면 다음과 같다. 이 식에서  $N_1$ 은 1의 개수이다.

$$\mu = E[X] \triangleq \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{N_1}{N}$$

## 예제 2. 정규분포의 모수 추정



## 예제 1. 베르누이분포의 모수 추정

- 모멘트 방법으로 베르누이 확률변수의 모수  $\mu$ 를 구하면 다음과 같다. 이 식에서  $N_1$ 은 1의 개수이다.

$$\mu = E[X] \triangleq \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{N_1}{N}$$

## 예제 2. 정규분포의 모수 추정

- 모멘트 방법으로 정규분포의 모수  $\mu, \sigma^2$ 을 구하면 다음과 같다.

$$\mu = E[X] \triangleq \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\sigma^2 = E[(X - \mu)^2] \triangleq s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

## 예제 1. 베르누이분포의 모수 추정

- 모멘트 방법으로 베르누이 확률변수의 모수  $\mu$ 를 구하면 다음과 같다. 이 식에서  $N_1$ 은 1의 개수이다.

$$\mu = E[X] \triangleq \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{N_1}{N}$$

## 예제 2. 정규분포의 모수 추정

- 모멘트 방법으로 정규분포의 모수  $\mu, \sigma^2$ 을 구하면 다음과 같다.

$$\mu = E[X] \triangleq \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\sigma^2 = E[(X - \mu)^2] \triangleq s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

- 정규분포는 모수가 아예 모멘트로 정의되어 있기 때문에 모멘트 방법을 사용하면 아주 쉽게 모수를 추정할 수 있다.

## 예제 3. 베타 분포의 모수 추정

- 모멘트 방법으로 베타 분포의 모수  $a, b$ 를 구하면 다음과 같다. 이 경우에는 모수와 모멘트 간의 관계를 이용하여 비선형 연립 방정식을 풀어야 한다.

$$E[X] = \frac{a}{a+b} \triangleq \bar{x}$$

$$E[(X - \mu)^2] = \frac{ab}{(a+b)^2(a+b+1)} \triangleq s^2$$

## 예제 3. 베타 분포의 모수 추정

- 모멘트 방법으로 베타 분포의 모수  $a, b$ 를 구하면 다음과 같다. 이 경우에는 모수와 모멘트 간의 관계를 이용하여 비선형 연립 방정식을 풀어야 한다.

$$E[X] = \frac{a}{a+b} \triangleq \bar{x}$$

$$E[(X - \mu)^2] = \frac{ab}{(a+b)^2(a+b+1)} \triangleq s^2$$

- 이 비선형 연립방정식을 풀어 해를 구하면 다음과 같다.

$$a = \bar{x} \left( \frac{\bar{x}(1 - \bar{x})}{s^2} - 1 \right)$$

$$b = (1 - \bar{x}) \left( \frac{\bar{x}(1 - \bar{x})}{s^2} - 1 \right)$$


## 예제 3. 베타 분포의 모수 추정 - 계속

- 예를 들어 다음과 같은 데이터 10000개가 있다고 하자. 값이 항상 0과 1사이에 있으므로 베타분포를 따른다고 가정하자. 사실 이 데이터는  $a = 15, b = 12$ 인 베타분포에서 생성한 것이다.

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import scipy as sp
import scipy.stats

np.random.seed(0)
x = sp.stats.beta(15, 12).rvs(10000)

sns.distplot(x, kde=False, norm_hist=True)
plt.title("Histogram of sample with beta distribution")
plt.show()
```



## 예제 3. 베타 분포의 모수 추정 - 계속

- 모멘트 방법으로 모수를 계산하면 원래의 모수와 비슷한 값을 구할 수 있다.


```
def estimate_beta(x):
    x_bar = x.mean()
    s2 = x.var()
    a = x_bar * (x_bar * (1 - x_bar) / s2 - 1)
    b = (1 - x_bar) * (x_bar * (1 - x_bar) / s2 - 1)
    return a, b

params = estimate_beta(x)
print(params)
#Out (15.346682046700685, 12.2121537049535)
```

## 예제 3. 베타 분포의 모수 추정 - 계속

- 추정된 모수값으로 확률밀도분포를 그리면 히스토그램과 일치하는 것을 볼 수 있다.


```
xx = np.linspace(0, 1, 1000)
sns.distplot(x, kde=False, norm_hist=True)
plt.plot(xx, sp.stats.beta(params[0], params[1]).pdf(xx))
plt.xlim(0, 1)
plt.title("Histogram of sample with beta dist. and estimated pdf")
plt.show()
```



## 예제 3. 베타 분포의 모수 추정 - 계속

- 연속확률분포의 히스토그램을 그릴 수 있는 시본의 `distplot()` 함수에는 사실 모수 추정기능이 포함되어 있다. `fit`인수로 사이파이의 확률변수 명령을 넣으면 이 명령을 사용하여 모수를 추정한 뒤에 해당 확률밀도함수 그래프를 히스토그램과 함께 보여준다.

```
sns.distplot(x, kde=False, norm_hist=True, fit=sp.stats.beta)
plt.xlim(0, 1)
plt.title("Histogram of sample with beta dist. and estimated pdf")
plt.show()
```





## 5.2 최대가능도 추정법

- 모멘트 방법으로 추정한 모수는 그 숫자가 가장 가능성 높은 값이라는 이론적 보장이 없다.

## 5.2 최대가능도 추정법

- 모멘트 방법으로 추정한 모수는 그 숫자가 가장 가능성 높은 값이라는 이론적 보장이 없다.
- 이 절에서는 이론적으로 가장 가능성이 높은 모수를 찾는 방법인 최대가능도 추정법에 대해 알아본다.

## 5.2 최대가능도 추정법

- 모멘트 방법으로 추정한 모수는 그 숫자가 가장 가능성 높은 값이라는 이론적 보장이 없다.
- 이 절에서는 이론적으로 가장 가능성이 높은 모수를 찾는 방법인 최대가능도 추정법에 대해 알아본다.
- 최대가능도 추정법은 모든 추정방법 중 가장 널리 사용되는 방법이다. 먼저 가능도함수에 대해 알아보고 베르누이분포, 카테고리분포, 정규분포, 다변수정규분포 등 여러 기본분포의 모수를 최대가능도 추정법으로 추정하는 방법을 공부한다.

## 가능도 함수

- 이제부터는 여러가지 확률분포  $X$ 에 대한 확률밀도함수 또는 확률질량함수를 다음과 같이 대표하여 쓰기로 한다.

$$p(x; \theta)$$

이 식에서  $x$ 는 확률분포가 가질 수 있는 실숫값이다.  $x$ 는 스칼라값일 수도 있고 벡터값일 수도 있다.  $\theta$ 는 확률밀도함수의 모수를 표시하는 대표기호다.  $x$ 와 마찬가지로  $\theta$ 도 스칼라일 수도 있고 벡터일 수도 있다.

## 가능도 함수

- 이제부터는 여러가지 확률분포  $X$ 에 대한 확률밀도함수 또는 확률질량함수를 다음과 같이 대표하여 쓰기로 한다.

$$p(x; \theta)$$

이 식에서  $x$ 는 확률분포가 가질 수 있는 실숫값이다.  $x$ 는 스칼라값일 수도 있고 벡터값일 수도 있다.  $\theta$ 는 확률밀도함수의 모수를 표시하는 대표기호다.  $x$ 와 마찬가지로  $\theta$ 도 스칼라일 수도 있고 벡터일 수도 있다.

- (Example)  $\theta = \begin{cases} \mu, & \text{if 확률분포가 베르누이 확률분포} \\ (N, \mu), & \text{if 확률분포가 이항분포} \\ (\mu, \sigma^2), & \text{if 확률분포가 정규분포.} \end{cases}$

## 가능도 함수

- 이제부터는 여러가지 확률분포  $X$ 에 대한 확률밀도함수 또는 확률질량함수를 다음과 같이 대표하여 쓰기로 한다.

$$p(x; \theta)$$

이 식에서  $x$ 는 확률분포가 가질 수 있는 실숫값이다.  $x$ 는 스칼라값일 수도 있고 벡터값일 수도 있다.  $\theta$ 는 확률밀도함수의 모수를 표시하는 대표기호다.  $x$ 와 마찬가지로  $\theta$ 도 스칼라일 수도 있고 벡터일 수도 있다.

- (Example)  $\theta = \begin{cases} \mu, & \text{if 확률분포가 베르누이 확률분포} \\ (N, \mu), & \text{if 확률분포가 이항분포} \\ (\mu, \sigma^2), & \text{if 확률분포가 정규분포.} \end{cases}$
- 확률밀도함수에서는 모수  $\theta$ 가 이미 알고 있는 상수계수고  $x$ 가 변수다. 하지만 모수 추정 문제에서는  $x$  즉, 이미 실현된 표본값은 알고 있지만 모수  $\theta$ 를 모르고 있다. 이때는 반대로  $x$ 를 이미 알고있는 상수계수로 놓고  $\theta$ 를 변수로 생각한다. 물론 함수의 값 자체는 변함없이 주어진  $x$ 가 나올 수 있는 확률밀도다. 이렇게 확률밀도함수에서 모수를 변수로 보는 경우에 이 함수를 가능도함수(likelihood function)라고 한다. 같은 함수를 확률밀도함수로 보면  $p(x; \theta)$ 로 표기하지만 가능도함수로 보면  $L(\theta; x)$  기호로 표기한다.

## 예제 1

- 정규분포의 확률밀도함수는 다음과 같은 단변수 함수다.

$$p(x; \mu_0, \sigma_0^2) = \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(x - \mu_0)^2}{2\sigma_0^2}\right)$$

모수가 상수라는 것을 강조하기 위해 아래첨자를 붙였다.

## 예제 1

- 정규분포의 확률밀도함수는 다음과 같은 단변수 함수다.

$$p(x; \mu_0, \sigma_0^2) = \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(x - \mu_0)^2}{2\sigma_0^2}\right)$$

모수가 상수라는 것을 강조하기 위해 아래첨자를 붙였다.

- 이때 가능도함수는 다음과 같이 입력변수가 2개인 다변수 함수가 된다.

$$L(\mu, \sigma^2; x_0) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_0 - \mu)^2}{2\sigma^2}\right)$$

수식은 같지만 함수의 변수가 다르다는 점에 주의하라.



## 예제 1 - 계속

- 예를 들어 정규분포에서 기댓값 모수와 분산 모수를 입력 변수로 가지는 가능도함수를 그리면 각각 다음과 같다. 기댓값 모수를 입력 변수로 가지는 가능도함수의 모양이 확률밀도함수와 같은 모양인 것은 ( $x$ 와  $\mu$ 를 바꾸어도 식이 같아지는) 정규분포의 확률밀도함수가 가지는 특별한 성질 때문이며 아주 우연히 이렇게 된 것뿐이다.

```
def likelihood_mu(mu):
    return sp.stats.norm(loc=mu).pdf(0)

mus = np.linspace(-5, 5, 1000)
likelihood_mu = [likelihood_mu(m) for m in mus]
plt.subplot(211)



plt.plot(mus, likelihood_mu)
plt.title("Likelihood function $L(\mu, \sigma^2=1; x=0)$")
plt.xlabel("$\mu$")
plt.show()

def likelihood_sigma2(sigma2):
    return sp.stats.norm(scale=np.sqrt(sigma2)).pdf(0)

sigma2s = np.linspace(0.1, 10, 1000)
likelihood_sigma2 = [likelihood_sigma2(s) for s in sigma2s]

plt.subplot(212)
plt.plot(sigma2s, likelihood_sigma2)
plt.title("Likelihood function $L(\mu=0, \sigma; x=0)$")
plt.xlabel("$\sigma^2$")
plt.show()
```

## 예제 1 - 계속




## 예제 1 - 계속

- $L(\mu, \sigma^2)$ 은 이차원 함수이므로 입체로 그리면 다음과 같다.

```
MU, SIGMA2 = np.meshgrid(mus, sigma2s)
L = np.exp(-MU ** 2 / (2 * SIGMA2)) / np.sqrt(2 * np.pi * SIGMA2)

fig = plt.figure()
ax = fig.add_subplot(projection='3d')
ax.plot_surface(MU, SIGMA2, L, linewidth=0.1)
plt.xlabel('\mu')
plt.ylabel('\sigma^2')
plt.title('Likelihood function $L(\mu, \sigma^2)$')
plt.show()
```



## 예제 2

- 베르누이분포의 확률질량함수는 다음과 같은 함수다. 이때 입력  $x$ 는 0과 1이라는 두 가지 값만 받을 수 있다.

$$p(x; \mu_0) = \mu_0^x (1 - \mu_0)^{1-x}$$

## 예제 2

- 베르누이분포의 확률질량함수는 다음과 같은 함수다. 이때 입력  $x$ 는 0과 1이라는 두 가지 값만 받을 수 있다.

$$p(x; \mu_0) = \mu_0^x (1 - \mu_0)^{1-x}$$

- 하지만 가능도함수는 다음과 0부터 1까지의 연속적인 실숫값을 입력으로 받는 함수가 된다.

$$L(\mu; x_0) = \mu^{x_0} (1 - \mu)^{1-x_0}$$

수식은 같지만 함수의 변수가 다르다는 점에 주의하라.

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음
  - $\theta$ 는 상수,  $x$ 는 변수



## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음
  - $\theta$ 는 상수,  $x$ 는 변수
  - $\theta$ 가 이미 정해져 있는 상황에서의  $x$  값의 상대적 확률

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음
  - $\theta$ 는 상수,  $x$ 는 변수
  - $\theta$ 가 이미 정해져 있는 상황에서의  $x$  값의 상대적 확률
  - 적분하면 전체 면적은 항상 1

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음
  - $\theta$ 는 상수,  $x$ 는 변수
  - $\theta$ 가 이미 정해져 있는 상황에서의  $x$  값의 상대적 확률
  - 적분하면 전체 면적은 항상 1
- 가능도 함수  $L(\theta) = p(x; \theta)$

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음
  - $\theta$ 는 상수,  $x$ 는 변수
  - $\theta$ 가 이미 정해져 있는 상황에서의  $x$  값의 상대적 확률
  - 적분하면 전체 면적은 항상 1
- 가능도 함수  $L(\theta) = p(x; \theta)$ 
  - $x$ 가 이미 발생, 값을 이미 알고 있음

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음
  - $\theta$ 는 상수,  $x$ 는 변수
  - $\theta$ 가 이미 정해져 있는 상황에서의  $x$  값의 상대적 확률
  - 적분하면 전체 면적은 항상 1
- 가능도 함수  $L(\theta) = p(x; \theta)$ 
  - $x$ 가 이미 발생, 값을 이미 알고 있음
  - $x$ 는 상수,  $\theta$ 는 변수

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음
  - $\theta$ 는 상수,  $x$ 는 변수
  - $\theta$ 가 이미 정해져 있는 상황에서의  $x$  값의 상대적 확률
  - 적분하면 전체 면적은 항상 1
- 가능도 함수  $L(\theta) = p(x; \theta)$ 
  - $x$ 가 이미 발생, 값을 이미 알고 있음
  - $x$ 는 상수,  $\theta$ 는 변수
  - $x$ 가 이미 정해져 있는 상황에서의  $\theta$  값의 상대적 확률

## 가능도 함수와 확률밀도 함수 요약

- 확률밀도 함수  $f(x; \theta)$ 
  - $\theta$  값을 이미 알고 있음
  - $\theta$ 는 상수,  $x$ 는 변수
  - $\theta$ 가 이미 정해져 있는 상황에서의  $x$  값의 상대적 확률
  - 적분하면 전체 면적은 항상 1
- 가능도 함수  $L(\theta) = p(x; \theta)$ 
  - $x$ 가 이미 발생, 값을 이미 알고 있음
  - $x$ 는 상수,  $\theta$ 는 변수
  - $x$ 가 이미 정해져 있는 상황에서의  $\theta$  값의 상대적 확률
  - 적분하면 전체 면적이 1이 아닐 수 있다.

## 최대가능도 추정법

- 최대가능도 추정법(Maximum Likelihood Estimation, MLE)은 주어진 표본에 대해 가능도를 가장 크게 하는 모수  $\theta$ 를 찾는 방법이다. 이 방법으로 찾은 모수는 기호로  $\hat{\theta}_{MLE}$ 와 같이 표시한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; x)$$

## 예제



## 최대가능도 추정법

- 최대가능도 추정법(Maximum Likelihood Estimation, MLE)은 주어진 표본에 대해 가능도를 가장 크게 하는 모수  $\theta$ 를 찾는 방법이다. 이 방법으로 찾은 모수는 기호로  $\hat{\theta}_{MLE}$ 와 같이 표시한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; x)$$

## 예제

- 정규분포를 가지는 확률변수의 분산  $\sigma^2 = 1$ 은 알고 있으나 평균  $\mu$ 를 모르고 있어 이를 추정해야 하는 문제를 생각해보자.

## 최대가능도 추정법

- 최대가능도 추정법(Maximum Likelihood Estimation, MLE)은 주어진 표본에 대해 가능도를 가장 크게 하는 모수  $\theta$ 를 찾는 방법이다. 이 방법으로 찾은 모수는 기호로  $\hat{\theta}_{MLE}$ 와 같이 표시한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; x)$$

## 예제

- 정규분포를 가지는 확률변수의 분산  $\sigma^2 = 1$ 은 알고 있으나 평균  $\mu$ 를 모르고 있어 이를 추정해야 하는 문제를 생각해보자.
- 확률변수의 표본은 하나  $x_1 = 1$ 을 가지고 있다고 하자. 이 경우 어떤  $\mu$  값이 가장 가능성(가능도)이 커 보이는가?

## 최대가능도 추정법

- 최대가능도 추정법(Maximum Likelihood Estimation, MLE)은 주어진 표본에 대해 가능도를 가장 크게 하는 모수  $\theta$ 를 찾는 방법이다. 이 방법으로 찾은 모수는 기호로  $\hat{\theta}_{MLE}$ 와 같이 표시한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; x)$$

## 예제

- 정규분포를 가지는 확률변수의 분산  $\sigma^2 = 1$ 은 알고 있으나 평균  $\mu$ 를 모르고 있어 이를 추정해야 하는 문제를 생각해보자.
- 확률변수의 표본은 하나  $x_1 = 1$ 을 가지고 있다고 하자. 이 경우 어떤  $\mu$  값이 가장 가능성(가능도)이 커 보이는가?
- 다음 그림에는  $\mu = -1, \mu = 0, \mu = 1$  세 가지 후보를 제시한다. 이 세 가지  $\mu$  값에 대해 1이 나올 확률밀도의 값이 바로 가능도다.

## 예제 - 계속

```

x = np.linspace(-5, 5, 100)


p1 = sp.stats.norm(loc=-1).pdf(1)
p2 = sp.stats.norm(loc=0).pdf(1)
p3 = sp.stats.norm(loc=1).pdf(1)

plt.scatter(1, p1, s=100, c='r', marker='v',
            label=r"$N(x_1; \mu=-1) \mathcal{P} = \{:.2f\}$".format(np.round(p1, 2)))
plt.scatter(1, p2, s=100, c='b', marker='^',
            label=r"$N(x_1; \mu=0) \mathcal{P} = \{:.2f\}$".format(np.round(p2, 2)))
plt.scatter(1, p3, s=100, c='g', marker='s',
            label=r"$N(x_1; \mu=1) \mathcal{P} = \{:.2f\}$".format(np.round(p3, 2)))

plt.plot(x, sp.stats.norm(loc=-1).pdf(x), ls="--")
plt.plot(x, sp.stats.norm(loc=0).pdf(x), ls="--")
plt.plot(x, sp.stats.norm(loc=1).pdf(x), ls="--")
plt.scatter(1, 0, s=100, c='k')
plt.vlines(1, -0.09, 0.45, linestyle=":")
plt.text(1-0.3, -0.15, "$x_1=1$")
plt.xlabel("x")
plt.ylabel("probability density")
plt.legend()
plt.title("Principle of the MLE")
plt.show()

```


## 예제 - 계속



- $N(x; \mu = -1)$ 이라는 확률분포에서  $x = 1$ 이 나올 가능도(확률밀도)는 0.05이다.

어떤 확률분포를 고르는 것이 합리적인가? 당연히 가장 큰 가능도를 가진 확률분포를 선택해야 한다. 그림에서 볼 수 있듯이  $\mu = 1$ 일 경우의 가능도가 가장 크다. 따라서 최대가능도 추정법에 의한 추정값은  $\hat{\mu}_{MLE} = 1$ 이다.


## 예제 - 계속



- $N(x; \mu = -1)$ 이라는 확률분포에서  $x = 1$ 이 나올 가능도(확률밀도)는 0.05이다.
- $N(x; \mu = 0)$ 이라는 확률분포에서  $x = 1$ 이 나올 가능도(확률밀도)는 0.24이다.

어떤 확률분포를 고르는 것이 합리적인가? 당연히 가장 큰 가능도를 가진 확률분포를 선택해야 한다. 그림에서 볼 수 있듯이  $\mu = 1$ 일 경우의 가능도가 가장 크다. 따라서 최대가능도 추정법에 의한 추정값은  $\hat{\mu}_{MLE} = 1$ 이다.

## 예제 - 계속



- $N(x; \mu = -1)$ 이라는 확률분포에서  $x = 1$ 이 나올 가능도(확률밀도)는 0.05이다.
- $N(x; \mu = 0)$ 이라는 확률분포에서  $x = 1$ 이 나올 가능도(확률밀도)는 0.24이다.
- $N(x; \mu = 1)$ 이라는 확률분포에서  $x = 1$ 이 나올 가능도(확률밀도)는 0.40이다.

어떤 확률분포를 고르는 것이 합리적인가? 당연히 가장 큰 가능도를 가진 확률분포를 선택해야 한다. 그림에서 볼 수 있듯이  $\mu = 1$ 일 경우의 가능도가 가장 크다. 따라서 최대가능도 추정법에 의한 추정값은  $\hat{\mu}_{MLE} = 1$ 이다.

## 복수의 표본 데이터가 있는 경우의 가능도 함수

- 일반적으로는 추정을 위해 확보하고 있는 확률변수 표본의 수가 하나가 아니라 복수 개  $\{x_1, x_2, \dots, x_N\}$ 이므로 가능도함수도 복수 표본값에 대한 결합확률밀도  $p\{X_1, X_2, \dots, X_N\}(x_1, x_2, \dots, x_N; \theta)$ 가 된다. 표본 데이터  $x_1, x_2, \dots, x_N$ 는 같은 확률분포에서 나온 독립적인 값들이므로 결합 확률밀도함수는 다음처럼 곱으로 표현된다.

$$L(\theta; x_1, x_2, \dots, x_N) = p(x_1, x_2, \dots, x_N; \theta) = \prod_{i=1}^N p(x_i; \theta)$$



## 예제 1

- 정규분포로부터 다음 세 개의 표본 데이터  $\{1, 0, -3\}$ 를 얻었다.

## 예제 1

- 정규분포로부터 다음 세 개의 표본 데이터  $\{1, 0, -3\}$ 를 얻었다.
- 이 경우의 가능도 함수는 다음과 같다.

$$\begin{aligned}
 L(\theta; x_1 = 1, x_2 = 0, x_3 = -3) &= \mathcal{N}(x_1, x_2, x_3; \theta) \\
 &= \mathcal{N}(x_1; \theta) \cdot \mathcal{N}(x_2; \theta) \cdot \mathcal{N}(x_3; \theta) \\
 &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(1-\mu)^2}{2\sigma^2}\right) \cdot \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(0-\mu)^2}{2\sigma^2}\right) \\
 &\quad \cdot \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(-3-\mu)^2}{2\sigma^2}\right) \\
 &= \frac{1}{(2\pi\sigma^2)^{\frac{3}{2}}} \exp\left(-\frac{3(\mu + \frac{2}{3})^2 + \frac{26}{3}}{2\sigma^2}\right)
 \end{aligned}$$

## 예제 1

- 정규분포로부터 다음 세 개의 표본 데이터  $\{1, 0, -3\}$ 를 얻었다.
- 이 경우의 가능도 함수는 다음과 같다.

$$\begin{aligned}
 L(\theta; x_1 = 1, x_2 = 0, x_3 = -3) &= \mathcal{N}(x_1, x_2, x_3; \theta) \\
 &= \mathcal{N}(x_1; \theta) \cdot \mathcal{N}(x_2; \theta) \cdot \mathcal{N}(x_3; \theta) \\
 &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(1-\mu)^2}{2\sigma^2}\right) \cdot \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(0-\mu)^2}{2\sigma^2}\right) \\
 &\quad \cdot \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(-3-\mu)^2}{2\sigma^2}\right) \\
 &= \frac{1}{(2\pi\sigma^2)^{\frac{3}{2}}} \exp\left(-\frac{3(\mu + \frac{2}{3})^2 + \frac{26}{3}}{2\sigma^2}\right)
 \end{aligned}$$

- 이 가능도함수는 2차함수이므로 미분을 하지 않아도 최대값 위치를 구할 수 있다. 가장 가능도를 높게하는 모수  $\mu$ 의 값은  $\hat{\mu}_{MLE} = -\frac{2}{3}$ 이다.

## 예제 1 - 계속

## ● 파이썬 코드와 그래프

```


mu = np.linspace(-3, 3, 1000)
sigma2 = 1

def likelihood(mu):
    return (2 * np.pi * sigma2) ** (3 / 2) * np.exp(-(3 *
mu ** 2 + 4 * mu + 10) / (2 * sigma2))

li = likelihood(mu)

plt.plot(mu, li)
plt.vlines(-2/3, 0, 0.25, linestyle=":")
plt.xlabel(r"parameter $\mu$")
plt.title("likelihood ft of normal dist. at {1, 0, -3}")
plt.show()

```



## 예제 2

- 베르누이분포로부터 다음 표본 데이터  $\{1, 0, 1\}$ 을 얻었다고 하자.

## 예제 2

- 베르누이분포로부터 다음 표본 데이터  $\{1, 0, 1\}$ 을 얻었다고 하자.
- 이때 가능도함수는 다음과 같다.

$$\begin{aligned}
 L(\mu; x_1 = 1, x_2 = 0, x_3 = 1) &= p(x_1 = 1, x_2 = 0, x_3 = 1; \mu) \\
 &= p(x_1 = 1; \mu) \cdot p(x_2 = 0; \mu) \cdot p(x_3 = 1; \mu) \\
 &= \mu^1(1 - \mu)^{1-1} \cdot \mu^0(1 - \mu)^{1-0} \cdot \mu^1(1 - \mu)^{1-1} \\
 &= -\mu^3 + \mu^2
 \end{aligned}$$

## 예제 2

- 베르누이분포로부터 다음 표본 데이터  $\{1, 0, 1\}$ 을 얻었다고 하자.
- 이때 가능도함수는 다음과 같다.

$$\begin{aligned}
 L(\mu; x_1 = 1, x_2 = 0, x_3 = 1) &= p(x_1 = 1, x_2 = 0, x_3 = 1; \mu) \\
 &= p(x_1 = 1; \mu) \cdot p(x_2 = 0; \mu) \cdot p(x_3 = 1; \mu) \\
 &= \mu^1(1 - \mu)^{1-1} \cdot \mu^0(1 - \mu)^{1-0} \cdot \mu^1(1 - \mu)^{1-1} \\
 &= -\mu^3 + \mu^2
 \end{aligned}$$

- 이 가능도함수를 최대화하는 모수의 값을 찾기 위해 미분한 도함수가 0이 되는 위치를 찾는다.

$$\frac{dL}{d\mu} = -3\mu^2 + 2\mu = -3\mu\left(\mu - \frac{2}{3}\right) = 0$$

## 예제 2

- 베르누이분포로부터 다음 표본 데이터  $\{1, 0, 1\}$ 을 얻었다고 하자.
- 이때 가능도함수는 다음과 같다.

$$\begin{aligned}
 L(\mu; x_1 = 1, x_2 = 0, x_3 = 1) &= p(x_1 = 1, x_2 = 0, x_3 = 1; \mu) \\
 &= p(x_1 = 1; \mu) \cdot p(x_2 = 0; \mu) \cdot p(x_3 = 1; \mu) \\
 &= \mu^1(1 - \mu)^{1-1} \cdot \mu^0(1 - \mu)^{1-0} \cdot \mu^1(1 - \mu)^{1-1} \\
 &= -\mu^3 + \mu^2
 \end{aligned}$$

- 이 가능도함수를 최대화하는 모수의 값을 찾기 위해 미분한 도함수가 0이 되는 위치를 찾는다.

$$\frac{dL}{d\mu} = -3\mu^2 + 2\mu = -3\mu\left(\mu - \frac{2}{3}\right) = 0$$

- 모수의 값이 0이면 표본값으로 1이 나올 수 없으므로 가능도함수를 최대화하는 모수는  $\hat{\mu}_{MLE} = \frac{2}{3}$ 이다.



## 로그 가능도 함수

- 일반적으로 최대가능도 추정법을 사용하여 가능도가 최대가 되는  $\theta$ 를 계산하려면 수치적 최적화(numerical optimization)를 해야 한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; \{x_i\})$$

## 로그 가능도 함수

- 일반적으로 최대가능도 추정법을 사용하여 가능도가 최대가 되는  $\theta$ 를 계산하려면 수치적 최적화(numerical optimization)를 해야 한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; \{x_i\})$$

- 그런데 보통은 가능도를 직접 사용하는 것이 아니라 로그 변환한 로그 가능도 함수  $LL = \log L$ 를 사용하는 경우가 많다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \log L(\theta; \{x_i\})$$

## 로그 가능도 함수

- 일반적으로 최대가능도 추정법을 사용하여 가능도가 최대가 되는  $\theta$ 를 계산하려면 수치적 최적화(numerical optimization)를 해야 한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; \{x_i\})$$

- 그런데 보통은 가능도를 직접 사용하는 것이 아니라 로그 변환한 로그 가능도 함수  $LL = \log L$ 를 사용하는 경우가 많다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \log L(\theta; \{x_i\})$$

- 이유는 다음과 같다.

## 로그 가능도 함수

- 일반적으로 최대가능도 추정법을 사용하여 가능도가 최대가 되는  $\theta$ 를 계산하려면 수치적 최적화(numerical optimization)를 해야 한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; \{x_i\})$$

- 그런데 보통은 가능도를 직접 사용하는 것이 아니라 로그 변환한 로그 가능도 함수  $LL = \log L$ 를 사용하는 경우가 많다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \log L(\theta; \{x_i\})$$

- 이유는 다음과 같다.

1. 로그 변환에 의해서는 최대값의 위치가 변치 않는다.

## 로그 가능도 함수

- 일반적으로 최대가능도 추정법을 사용하여 가능도가 최대가 되는  $\theta$ 를 계산하려면 수치적 최적화(numerical optimization)를 해야 한다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta; \{x_i\})$$

- 그런데 보통은 가능도를 직접 사용하는 것이 아니라 로그 변환한 로그 가능도 함수  $LL = \log L$ 를 사용하는 경우가 많다.

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \log L(\theta; \{x_i\})$$

- 이유는 다음과 같다.
  1. 로그 변환에 의해서는 최대값의 위치가 변치 않는다.
  2. 반복시행으로 인한 복수 표본 데이터인 경우 결합 확률밀도함수가 동일한 함수의 곱으로 나타나는 경우가 많은데 이때 로그 변환에 의해 곱셈이 덧셈이 되어 계산이 단순해진다.

## 예제

- 위 예와 같이 정규분포로 부터 얻은 표본값이  $\{1, 0, -3\}$ 인 경우 로그 변환을 하면 최대값의 위치가  $2/3$ 라는 것을 쉽게 구할 수 있다.

$$\begin{aligned}
 \log L(\theta; x_1, x_2, x_3) &= \log\left(\frac{1}{(2\pi\sigma^2)^{\frac{3}{2}}} \exp\left(-\frac{3\mu^2 + 4\mu + 10}{2\sigma^2}\right)\right) \\
 &= \log\left(\frac{1}{(2\pi\sigma^2)^{\frac{3}{2}}}\right) - \frac{3\mu^2 + 4\mu + 10}{2\sigma^2} \\
 &= \log\left(\frac{1}{(2\pi\sigma^2)^{\frac{3}{2}}}\right) - \frac{3(\mu + \frac{2}{3})^2 + \frac{26}{3}}{2\sigma^2}
 \end{aligned}$$

## 베르누이분포의 최대가능도 모수 추정

- 모수가  $\mu$ 인 베르누이분포의 확률질량함수는 다음과 같다.

$$p(x; \mu) = \text{Bern}(x; \mu) = \mu^x (1 - \mu)^{1-x}$$

## 베르누이분포의 최대가능도 모수 추정

- 모수가  $\mu$ 인 베르누이분포의 확률질량함수는 다음과 같다.

$$p(x; \mu) = \text{Bern}(x; \mu) = \mu^x (1 - \mu)^{1-x}$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률질량함수는 각각의 확률질량 함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i}$$



## 베르누이분포의 최대가능도 모수 추정

- 모수가  $\mu$ 인 베르누이분포의 확률질량함수는 다음과 같다.

$$p(x; \mu) = \text{Bern}(x; \mu) = \mu^x (1 - \mu)^{1-x}$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률질량함수는 각각의 확률질량 함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i}$$

- 미분을 쉽게 하기 위해 로그 변환을 하여 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu) = \sum_{i=1}^N x_i \log \mu + (N - \sum_{i=1}^N x_i) \log(1 - \mu)$$

## 베르누이분포의 최대가능도 모수 추정

- 모수가  $\mu$ 인 베르누이분포의 확률질량함수는 다음과 같다.

$$p(x; \mu) = \text{Bern}(x; \mu) = \mu^x (1 - \mu)^{1-x}$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률질량함수는 각각의 확률질량 함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i}$$

- 미분을 쉽게 하기 위해 로그 변환을 하여 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu) = \sum_{i=1}^N x_i \log \mu + (N - \sum_{i=1}^N x_i) \log(1 - \mu)$$

- $x = 1$ (성공) 또는  $x = 0$ (실패) 이므로 성공 횟수와 실패 횟수를 다음과 같이  $N_1, N_0$ 라고 표기하도록 하자.

$$N_1 = \sum_{i=1}^N x_i, \quad N_0 = N - \sum_{i=1}^N x_i$$

## 베르누이분포의 최대가능도 모수 추정

- 모수가  $\mu$ 인 베르누이분포의 확률질량함수는 다음과 같다.

$$p(x; \mu) = \text{Bern}(x; \mu) = \mu^x (1 - \mu)^{1-x}$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률질량함수는 각각의 확률질량 함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i}$$

- 미분을 쉽게 하기 위해 로그 변환을 하여 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu) = \sum_{i=1}^N x_i \log \mu + (N - \sum_{i=1}^N x_i) \log(1 - \mu)$$

- $x = 1$ (성공) 또는  $x = 0$ (실패) 이므로 성공 횟수와 실패 횟수를 다음과 같이  $N_1, N_0$ 라고 표기하도록 하자.

$$N_1 = \sum_{i=1}^N x_i, \quad N_0 = N - \sum_{i=1}^N x_i$$

- 로그가능도 함수는  $\log L = N_1 \log \mu + N_0 \log(1 - \mu)$ 와 같아진다.

## 베르누이분포의 최대가능도 모수 추정

- 모수가  $\mu$ 인 베르누이분포의 확률질량함수는 다음과 같다.

$$p(x; \mu) = \text{Bern}(x; \mu) = \mu^x (1 - \mu)^{1-x}$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률질량함수는 각각의 확률질량 함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i}$$

- 미분을 쉽게 하기 위해 로그 변환을 하여 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu) = \sum_{i=1}^N x_i \log \mu + (N - \sum_{i=1}^N x_i) \log(1 - \mu)$$

- $x = 1$ (성공) 또는  $x = 0$ (실패) 이므로 성공 횟수와 실패 횟수를 다음과 같이  $N_1, N_0$ 라고 표기하도록 하자.

$$N_1 = \sum_{i=1}^N x_i, \quad N_0 = N - \sum_{i=1}^N x_i$$

- 로그가능도 함수는  $\log L = N_1 \log \mu + N_0 \log(1 - \mu)$ 와 같아진다.
- 이 목적함수를 모수로 미분한 값이 0이 되게 하는 모숫값을 구하면  $\mu = \frac{N_1}{N}$ 이다.

## 베르누이분포의 최대가능도 모수 추정

- 모수가  $\mu$ 인 베르누이분포의 확률질량함수는 다음과 같다.

$$p(x; \mu) = \text{Bern}(x; \mu) = \mu^x (1 - \mu)^{1-x}$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률질량함수는 각각의 확률질량 함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i}$$

- 미분을 쉽게 하기 위해 로그 변환을 하여 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu) = \sum_{i=1}^N x_i \log \mu + (N - \sum_{i=1}^N x_i) \log(1 - \mu)$$

- $x = 1$ (성공) 또는  $x = 0$ (실패) 이므로 성공 횟수와 실패 횟수를 다음과 같이  $N_1, N_0$ 라고 표기하도록 하자.

$$N_1 = \sum_{i=1}^N x_i, \quad N_0 = N - \sum_{i=1}^N x_i$$

- 로그가능도 함수는  $\log L = N_1 \log \mu + N_0 \log(1 - \mu)$ 와 같아진다.
- 이 목적함수를 모수로 미분한 값이 0이 되게 하는 모숫값을 구하면  $\mu = \frac{N_1}{N}$ 이다.
- (결론) 최대가능도 추정법에 의한 베르누이분포의 모수는 1이 나온 횟수와 전체 시행횟수의 비율이다.

## 카테고리분포의 최대가능도 모수 추정

- 모수가  $\mu = (\mu_1, \dots, \mu_K)$ 인 카테고리분포의 확률질량함수는 다음과 같다.

$$p(x; \mu_1, \dots, \mu_K) = \text{Cat}(x; \mu_1, \dots, \mu_K) = \prod_{i=1}^N \mu_i^{x_i}, \quad \sum_{i=1}^K \mu_i = 1$$

## 카테고리분포의 최대가능도 모수 추정

- 모수가  $\mu = (\mu_1, \dots, \mu_K)$ 인 카테고리분포의 확률질량함수는 다음과 같다.

$$p(x; \mu_1, \dots, \mu_K) = \text{Cat}(x; \mu_1, \dots, \mu_K) = \prod_{i=1}^N \mu_i^{x_i}, \quad \sum_{i=1}^K \mu_i = 1$$

- 이 식에서  $x$ 는 모두  $K$ 개의 원소를 가지는 원핫인코딩(one-hot-encoding)벡터다. 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu_1, \dots, \mu_K; x_1, \dots, x_N) = \prod_{i=1}^N \prod_{j=1}^K \mu_j^{x_{i,j}}$$

위 식에서  $x_{i,j}$ 는  $i$ 번째 시행 결과인  $x_i$ 의  $j$ 번째 원소를 뜻한다.

## 카테고리분포의 최대가능도 모수 추정

- 모수가  $\mu = (\mu_1, \dots, \mu_K)$ 인 카테고리분포의 확률질량함수는 다음과 같다.

$$p(x; \mu_1, \dots, \mu_K) = \text{Cat}(x; \mu_1, \dots, \mu_K) = \prod_{i=1}^N \mu_i^{x_i}, \quad \sum_{i=1}^K \mu_i = 1$$

- 이 식에서  $x$ 는 모두  $K$ 개의 원소를 가지는 원핫인코딩(one-hot-encoding)벡터다. 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu_1, \dots, \mu_K; x_1, \dots, x_N) = \prod_{i=1}^N \prod_{j=1}^K \mu_j^{x_{i,j}}$$

위 식에서  $x_{i,j}$ 는  $i$ 번째 시행 결과인  $x_i$ 의  $j$ 번째 원소를 뜻한다.

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu_1, \dots, \mu_K) = \sum_{j=1}^K (\log \mu_j (\sum_{i=1}^N x_{i,j}))$$



## 카테고리분포의 최대가능도 모수 추정

- 모수가  $\mu = (\mu_1, \dots, \mu_K)$ 인 카테고리분포의 확률질량함수는 다음과 같다.

$$p(x; \mu_1, \dots, \mu_K) = \text{Cat}(x; \mu_1, \dots, \mu_K) = \prod_{i=1}^N \mu_i^{x_i}, \quad \sum_{i=1}^K \mu_i = 1$$

- 이 식에서  $x$ 는 모두  $K$ 개의 원소를 가지는 원핫인코딩(one-hot-encoding)벡터다. 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu_1, \dots, \mu_K; x_1, \dots, x_N) = \prod_{i=1}^N \prod_{j=1}^K \mu_j^{x_{i,j}}$$

위 식에서  $x_{i,j}$ 는  $i$ 번째 시행 결과인  $x_i$ 의  $j$ 번째 원소를 뜻한다.

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu_1, \dots, \mu_K) = \sum_{j=1}^K (\log \mu_j (\sum_{i=1}^N x_{i,j}))$$

- $j$ 번째 원소가 나온 횟수를  $N_j := \sum_{i=1}^N x_{i,j}$ 라고 표기하자.

## 카테고리분포의 최대가능도 모수 추정

- 모수가  $\mu = (\mu_1, \dots, \mu_K)$ 인 카테고리분포의 확률질량함수는 다음과 같다.

$$p(x; \mu_1, \dots, \mu_K) = \text{Cat}(x; \mu_1, \dots, \mu_K) = \prod_{i=1}^N \mu_i^{x_i}, \quad \sum_{i=1}^K \mu_i = 1$$

- 이 식에서  $x$ 는 모두  $K$ 개의 원소를 가지는 원핫인코딩(one-hot-encoding)벡터다. 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu_1, \dots, \mu_K; x_1, \dots, x_N) = \prod_{i=1}^N \prod_{j=1}^K \mu_j^{x_{i,j}}$$

위 식에서  $x_{i,j}$ 는  $i$ 번째 시행 결과인  $x_i$ 의  $j$ 번째 원소를 뜻한다.

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu_1, \dots, \mu_K) = \sum_{j=1}^K (\log \mu_j (\sum_{i=1}^N x_{i,j}))$$

- $j$ 번째 원소가 나온 횟수를  $N_j := \sum_{i=1}^N x_{i,j}$ 라고 표기하자.
- 로그가능도 함수는  $\log L = \sum_{j=1}^K (\log \mu_j \cdot N_j)$ 와 같아진다. 그런데 모수는 제한조건  $\sum_{j=1}^K \mu_j = 1$ 을 만족해야만 한다.

## 카테고리분포의 최대가능도 모수 추정

- 모수가  $\mu = (\mu_1, \dots, \mu_K)$ 인 카테고리분포의 확률질량함수는 다음과 같다.

$$p(x; \mu_1, \dots, \mu_K) = \text{Cat}(x; \mu_1, \dots, \mu_K) = \prod_{i=1}^N \mu_i^{x_i}, \quad \sum_{i=1}^K \mu_i = 1$$

- 이 식에서  $x$ 는 모두  $K$ 개의 원소를 가지는 원핫인코딩(one-hot-encoding)벡터다. 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu_1, \dots, \mu_K; x_1, \dots, x_N) = \prod_{i=1}^N \prod_{j=1}^K \mu_j^{x_{i,j}}$$

위 식에서  $x_{i,j}$ 는  $i$ 번째 시행 결과인  $x_i$ 의  $j$ 번째 원소를 뜻한다.

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu_1, \dots, \mu_K) = \sum_{j=1}^K (\log \mu_j (\sum_{i=1}^N x_{i,j}))$$

- $j$ 번째 원소가 나온 횟수를  $N_j := \sum_{i=1}^N x_{i,j}$ 라고 표기하자.
- 로그가능도 함수는  $\log L = \sum_{j=1}^K (\log \mu_j \cdot N_j)$ 와 같아진다. 그런데 모수는 제한조건  $\sum_{j=1}^K \mu_j = 1$ 을 만족해야만 한다.
- 이 목적함수를 모수로 미분한 값이 0이 되게 하는 모숫값을 구하면  $\mu_j = \frac{N_j}{N}$ 이다.

## 카테고리분포의 최대가능도 모수 추정

- 모수가  $\mu = (\mu_1, \dots, \mu_K)$ 인 카테고리분포의 확률질량함수는 다음과 같다.

$$p(x; \mu_1, \dots, \mu_K) = \text{Cat}(x; \mu_1, \dots, \mu_K) = \prod_{i=1}^N \mu_i^{x_i}, \quad \sum_{i=1}^K \mu_i = 1$$

- 이 식에서  $x$ 는 모두  $K$ 개의 원소를 가지는 원핫인코딩(one-hot-encoding)벡터다. 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu_1, \dots, \mu_K; x_1, \dots, x_N) = \prod_{i=1}^N \prod_{j=1}^K \mu_j^{x_{i,j}}$$

위 식에서  $x_{i,j}$ 는  $i$ 번째 시행 결과인  $x_i$ 의  $j$ 번째 원소를 뜻한다.

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구하면 다음과 같다.

$$\log L = \log p(x_1, \dots, x_N; \mu_1, \dots, \mu_K) = \sum_{j=1}^K (\log \mu_j (\sum_{i=1}^N x_{i,j}))$$

- $j$ 번째 원소가 나온 횟수를  $N_j := \sum_{i=1}^N x_{i,j}$ 라고 표기하자.
- 로그가능도 함수는  $\log L = \sum_{j=1}^K (\log \mu_j \cdot N_j)$ 와 같아진다. 그런데 모수는 제한조건  $\sum_{j=1}^K \mu_j = 1$ 을 만족해야만 한다.
- 이 목적함수를 모수로 미분한 값이 0이 되게 하는 모숫값을 구하면  $\mu_j = \frac{N_j}{N}$ 이다.
- (결론) 최대가능도 추정법에 의한 카테고리분포의 모수는 각 범주값이 나온 횟수와 전체 시행횟수의 비율이다.

## 정규분포의 최대가능도 모수 추정

- 정규분포의 확률밀도함수는 다음과 같다. 여기에서  $x$ 는 스칼라 값이다.

$$p(x; \theta) = \mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

## 정규분포의 최대가능도 모수 추정

- 정규분포의 확률밀도함수는 다음과 같다. 여기에서  $x$ 는 스칼라 값이다.

$$p(x; \theta) = \mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$$

## 정규분포의 최대가능도 모수 추정

- 정규분포의 확률밀도함수는 다음과 같다. 여기에서  $x$ 는 스칼라 값이다.

$$p(x; \theta) = \mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$$

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구한다.

## 정규분포의 최대가능도 모수 추정

- 정규분포의 확률밀도함수는 다음과 같다. 여기에서  $x$ 는 스칼라 값이다.

$$p(x; \theta) = \mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$$

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구한다.
- 이 확률밀도함수가 최대가 되는 모수값을 찾기 위해서는 각각의 모수  $\mu, \sigma^2$ 으로 미분한 값이 0이 되어야 한다.



## 정규분포의 최대가능도 모수 추정

- 정규분포의 확률밀도함수는 다음과 같다. 여기에서  $x$ 는 스칼라 값이다.

$$p(x; \theta) = \mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$$

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구한다.
- 이 확률밀도함수가 최대가 되는 모수값을 찾기 위해서는 각각의 모수  $\mu, \sigma^2$ 으로 미분한 값이 0이 되어야 한다.
- 두 식을 풀면 주어진 데이터 표본에 대해 모수의 가능도 함수를 가장 크게 하는 모수의 값을 구할 수 있다.

## 정규분포의 최대가능도 모수 추정

- 정규분포의 확률밀도함수는 다음과 같다. 여기에서  $x$ 는 스칼라 값이다.

$$p(x; \theta) = \mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$$

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구한다.
- 이 확률밀도함수가 최대가 되는 모수값을 찾기 위해서는 각각의 모수  $\mu, \sigma^2$ 으로 미분한 값이 0이 되어야 한다.
- 두 식을 풀면 주어진 데이터 표본에 대해 모수의 가능도 함수를 가장 크게 하는 모수의 값을 구할 수 있다.
- 이 목적함수를 모수로 미분한 값이 0이 되게 하는 모수값을 구하면  $\mu = \bar{x}, \sigma^2 = s^2$ 이다.

## 정규분포의 최대가능도 모수 추정

- 정규분포의 확률밀도함수는 다음과 같다. 여기에서  $x$ 는 스칼라 값이다.

$$p(x; \theta) = \mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 그런데  $N$  번의 반복 시행으로 표본 데이터가  $x_1, \dots, x_N$ 이 있는 경우에는 모두 독립이므로 전체 확률밀도함수는 각각의 확률질량함수의 곱과 같다.

$$L(\mu; x_1, \dots, x_N) = p(x_1, \dots, x_N; \mu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$$

- 미분을 쉽게 하기 위해 로그 변환을 한 로그가능도 함수를 구한다.
- 이 확률밀도함수가 최대가 되는 모수값을 찾기 위해서는 각각의 모수  $\mu, \sigma^2$ 으로 미분한 값이 0이 되어야 한다.
- 두 식을 풀면 주어진 데이터 표본에 대해 모수의 가능도 함수를 가장 크게 하는 모수의 값을 구할 수 있다.
- 이 목적함수를 모수로 미분한 값이 0이 되게 하는 모수값을 구하면  $\mu = \bar{x}, \sigma^2 = s^2$ 이다.
- (결론) 최대가능도 추정법에 의한 정규분포의 기댓값은 표본평균과 같고 분산은 (편향)표본분산과 같다.