

1 5장 추정과 검정[계속]

5.3 베이지 추정법

- 베이지 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.

5.3 베이지 추정법

- 베이지 추정법(Bayesian estimation)은 모수값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이지 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.

5.3 베이지 추정법

- 베이지 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이지 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.
- 베이지 추정법을 사용하는 이유는 추정된 모숫값 숫자 하나만으로는 추정의 신뢰도와 신뢰구간을 구할 수 없기 때문이다.

5.3 베이지 추정법

- 베이지 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이지 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.
- 베이지 추정법을 사용하는 이유는 추정된 모숫값 숫자 하나만으로는 추정의 신뢰도와 신뢰구간을 구할 수 없기 때문이다.
- 예) 인터넷 쇼핑몰에 있는 두 개의 경쟁상품에 사용자 의견이 다음과 같이 붙어 있다고 하자.

5.3 베이즈 추정법

- 베이즈 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이즈 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.
- 베이즈 추정법을 사용하는 이유는 추정된 모숫값 숫자 하나만으로는 추정의 신뢰도와 신뢰구간을 구할 수 없기 때문이다.
- 예) 인터넷 쇼핑몰에 있는 두 개의 경쟁상품에 사용자 의견이 다음과 같이 붙어 있다고 하자.
 - 상품 A: 전체 평가의견 3개, 좋아요 2개, 싫어요 1개

5.3 베이지 추정법

- 베이지 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이지 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.
- 베이지 추정법을 사용하는 이유는 추정된 모숫값 숫자 하나만으로는 추정의 신뢰도와 신뢰구간을 구할 수 없기 때문이다.
- 예) 인터넷 쇼핑몰에 있는 두 개의 경쟁상품에 사용자 의견이 다음과 같이 붙어 있다고 하자.
 - 상품 A: 전체 평가의견 3개, 좋아요 2개, 싫어요 1개
 - 상품 B: 전체 평가의견 100개, 좋아요 60개, 싫어요 40개

5.3 베이지 추정법

- 베이지 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이지 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.
- 베이지 추정법을 사용하는 이유는 추정된 모숫값 숫자 하나만으로는 추정의 신뢰도와 신뢰구간을 구할 수 없기 때문이다.
- 예) 인터넷 쇼핑몰에 있는 두 개의 경쟁상품에 사용자 의견이 다음과 같이 붙어 있다고 하자.
 - 상품 A: 전체 평가의견 3개, 좋아요 2개, 싫어요 1개
 - 상품 B: 전체 평가의견 100개, 좋아요 60개, 싫어요 40개
- 내가 이 상품을 사용했을 때 평가의견이 '좋아요'가 나올지 '싫어요'가 나올지는 베르누이분포 확률변수로 모형화할 수 있다. 최대가능도 추정법에 따르면 상품 A와 상품 B에서 '좋아요'가 나온 비율을 사용하여 베르누이 모수를 구하면 다음과 같이 상품 A의 모수가 높다.

5.3 베이지 추정법

- 베이지 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이지 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.
- 베이지 추정법을 사용하는 이유는 추정된 모숫값 숫자 하나만으로는 추정의 신뢰도와 신뢰구간을 구할 수 없기 때문이다.
- 예) 인터넷 쇼핑몰에 있는 두 개의 경쟁상품에 사용자 의견이 다음과 같이 붙어 있다고 하자.
 - 상품 A: 전체 평가의견 3개, 좋아요 2개, 싫어요 1개
 - 상품 B: 전체 평가의견 100개, 좋아요 60개, 싫어요 40개
- 내가 이 상품을 사용했을 때 평가의견이 '좋아요'가 나올지 '싫어요'가 나올지는 베르누이분포 확률변수로 모형화할 수 있다. 최대가능도 추정법에 따르면 상품 A와 상품 B에서 '좋아요'가 나온 비율을 사용하여 베르누이 모수를 구하면 다음과 같이 상품 A의 모수가 높다.
 - 상품 A의 모수: $\frac{2}{3} = 0.67$

5.3 베이즈 추정법

- 베이즈 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이즈 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.
- 베이즈 추정법을 사용하는 이유는 추정된 모숫값 숫자 하나만으로는 추정의 신뢰도와 신뢰구간을 구할 수 없기 때문이다.
- 예) 인터넷 쇼핑몰에 있는 두 개의 경쟁상품에 사용자 의견이 다음과 같이 붙어 있다고 하자.
 - 상품 A: 전체 평가의견 3개, 좋아요 2개, 싫어요 1개
 - 상품 B: 전체 평가의견 100개, 좋아요 60개, 싫어요 40개
- 내가 이 상품을 사용했을 때 평가의견이 '좋아요'가 나올지 '싫어요'가 나올지는 베르누이분포 확률변수로 모형화할 수 있다. 최대가능도 추정법에 따르면 상품 A와 상품 B에서 '좋아요'가 나온 비율을 사용하여 베르누이 모수를 구하면 다음과 같이 상품 A의 모수가 높다.
 - 상품 A의 모수: $\frac{2}{3} = 0.67$
 - 상품 B의 모수: $\frac{60}{100} = 0.60$

5.3 베이즈 추정법

- 베이즈 추정법(Bayesian estimation)은 모숫값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.
- 어떤 확률분포함수의 모수를 μ 라고 하자. 최대가능도 추정법에서는 모수를 미지의 상수로 보았지만 베이즈 추정법에서는 모수를 확률변수로 본다. 확률변수는 확률밀도함수를 가진다. 즉, 어떤 값이 가능성이 높고 어떤 값이 가능성이 낮은지를 살펴보겠다는 뜻이다.
- 베이즈 추정법을 사용하는 이유는 추정된 모숫값 숫자 하나만으로는 추정의 신뢰도와 신뢰구간을 구할 수 없기 때문이다.
- 예) 인터넷 쇼핑몰에 있는 두 개의 경쟁상품에 사용자 의견이 다음과 같이 붙어 있다고 하자.
 - 상품 A: 전체 평가의견 3개, 좋아요 2개, 싫어요 1개
 - 상품 B: 전체 평가의견 100개, 좋아요 60개, 싫어요 40개
- 내가 이 상품을 사용했을 때 평가의견이 '좋아요'가 나올지 '싫어요'가 나올지는 베르누이분포 확률변수로 모형화할 수 있다. 최대가능도 추정법에 따르면 상품 A와 상품 B에서 '좋아요'가 나온 비율을 사용하여 베르누이 모수를 구하면 다음과 같이 상품 A의 모수가 높다.
 - 상품 A의 모수: $\frac{2}{3} = 0.67$
 - 상품 B의 모수: $\frac{60}{100} = 0.60$
- 상품 B의 평가의견은 100개고 상품 A의 평가의견은 3개밖에 되지 않는데 상품 A의 모수가 더 높다고 더 높은 상품이라고 확신할 수 있는가? 베이즈 추정법에서는 단순히 모수의 값을 하나의 숫자로 구하는 것이 아니므로 이러한 잘못된 결론을 내리지 않도록 도와준다.

베이즈 추정법의 기본 원리

- 수학적으로 베이즈 추정법은 주어진 데이터 $\{x_1, \dots, x_N\}$ 를 기반으로 모수 μ 의 조건부 확률분포 $p(\mu \mid x_1, \dots, x_N)$ 를 계산하는 작업이다. 조건부 확률분포를 구하므로 베이즈 정리를 사용한다.

$$p(\mu \mid x_1, \dots, x_N) = \frac{p(x_1, \dots, x_N \mid \mu) \cdot p(\mu)}{p(x_1, \dots, x_N)} \propto p(x_1, \dots, x_N \mid \mu) \cdot p(\mu)$$

베이즈 추정법의 기본 원리

- 수학적으로 베이즈 추정법은 주어진 데이터 $\{x_1, \dots, x_N\}$ 를 기반으로 모수 μ 의 조건부 확률분포 $p(\mu \mid x_1, \dots, x_N)$ 를 계산하는 작업이다. 조건부 확률분포를 구하므로 베이즈 정리를 사용한다.

$$p(\mu \mid x_1, \dots, x_N) = \frac{p(x_1, \dots, x_N \mid \mu) \cdot p(\mu)}{p(x_1, \dots, x_N)} \propto p(x_1, \dots, x_N \mid \mu) \cdot p(\mu)$$

- $p(\mu)$ 는 **모수의 사전(Prior)분포**다. 사전 분포는 베이지안 추정 작업을 하기 전에 이미 알고 있던 모수 μ 의 분포를 뜻한다. 모수의 분포에 대해 아무런 지식이 없는 경우에는 균일(uniform) 분포 Beta(1, 1)나 0을 중심으로 가지는 정규분포 $\mathcal{N}(0, \sigma_0^2)$ 등의 **무정보분포(non-informative distribution)**를 사용할 수 있다. 무정보 분포에 대해서는 다음 장에서 공부한다.

베이즈 추정법의 기본 원리

- 수학적으로 베이즈 추정법은 주어진 데이터 $\{x_1, \dots, x_N\}$ 를 기반으로 모수 μ 의 조건부 확률분포 $p(\mu | x_1, \dots, x_N)$ 를 계산하는 작업이다. 조건부 확률분포를 구하므로 베이즈 정리를 사용한다.

$$p(\mu | x_1, \dots, x_N) = \frac{p(x_1, \dots, x_N | \mu) \cdot p(\mu)}{p(x_1, \dots, x_N)} \propto p(x_1, \dots, x_N | \mu) \cdot p(\mu)$$

- $p(\mu)$ 는 **모수의 사전(Prior)분포**다. 사전 분포는 베이지안 추정 작업을 하기 전에 이미 알고 있던 모수 μ 의 분포를 뜻한다. 모수의 분포에 대해 아무런 지식이 없는 경우에는 균일(uniform) 분포 Beta(1, 1)나 0을 중심으로 가지는 정규분포 $\mathcal{N}(0, \sigma_0^2)$ 등의 **무정보분포(non-informative distribution)**를 사용할 수 있다. 무정보 분포에 대해서는 다음 장에서 공부한다.
- $p(\mu | x_1, \dots, x_N)$ 는 **모수의 사후(Posterior)분포**다. 수학적으로는 데이터 $x_1, \dots, x_N$ 가 주어진 상태에서의 μ 에 대한 조건부 확률 분포다. 우리가 베이즈 추정법 작업을 통해 구하고자 하는 것이 바로 이 사후 분포다.

베이즈 추정법의 기본 원리

- 수학적으로 베이즈 추정법은 주어진 데이터 $\{x_1, \dots, x_N\}$ 를 기반으로 모수 μ 의 조건부 확률분포 $p(\mu \mid x_1, \dots, x_N)$ 를 계산하는 작업이다. 조건부 확률분포를 구하므로 베이즈 정리를 사용한다.

$$p(\mu \mid x_1, \dots, x_N) = \frac{p(x_1, \dots, x_N \mid \mu) \cdot p(\mu)}{p(x_1, \dots, x_N)} \propto p(x_1, \dots, x_N \mid \mu) \cdot p(\mu)$$

- $p(\mu)$ 는 **모수의 사전(Prior)분포**다. 사전 분포는 베이지안 추정 작업을 하기 전에 이미 알고 있던 모수 μ 의 분포를 뜻한다. 모수의 분포에 대해 아무런 지식이 없는 경우에는 균일(uniform) 분포 Beta(1, 1)나 0을 중심으로 가지는 정규분포 $\mathcal{N}(0, \sigma_0^2)$ 등의 **무정보분포(non-informative distribution)**를 사용할 수 있다. 무정보 분포에 대해서는 다음 장에서 공부한다.
- $p(\mu \mid x_1, \dots, x_N)$ 는 **모수의 사후(Posterior)분포**다. 수학적으로는 데이터 $x_1, \dots, x_N$ 가 주어진 상태에서의 μ 에 대한 조건부 확률 분포다. 우리가 베이즈 추정법 작업을 통해 구하고자 하는 것이 바로 이 사후 분포다.
- $p(x_1, \dots, x_N \mid \mu)$ 는 **가능도(likelihood)분포**다. 모수 μ 가 특정한 값으로 주어졌을 때 주어진 데이터 $x_1, \dots, x_N$ 이 나올 수 있는 확률값을 나타낸다.

베이지스 추정법의 기본 원리 - 계속

- 이때 계산된 모수의 분포는 두 가지 방법으로 표현한다.

베이즈 추정법의 기본 원리 - 계속

- 이때 계산된 모수의 분포는 두 가지 방법으로 표현한다.
 - (1) **모수적(parametric) 방법**: 다른 확률분포를 사용하여 추정된 모수의 분포를 나타낸다. 모수 분포를 표현하는 확률분포함수의 모수를 **하이퍼모수(hyper-parameter)**라고 부른다. 모수적 방법을 사용한 베이즈 추정법은 결국 하이퍼모숫값을 계산하는 작업이다.

베이즈 추정법의 기본 원리 - 계속

- 이때 계산된 모수의 분포는 두 가지 방법으로 표현한다.
 - (1) **모수적(parametric) 방법**: 다른 확률분포를 사용하여 추정된 모수의 분포를 나타낸다. 모수 분포를 표현하는 확률분포함수의 모수를 하이퍼모수 (hyper-parameter)라고 부른다. 모수적 방법을 사용한 베이즈 추정법은 결국 하이퍼모숫값을 계산하는 작업이다.
 - (2) **비모수적(non-parametric) 방법**: 모수의 분포와 동일한 분포를 가지는 실제 표본 집합을 생성하여 히스토그램이나 최빈값 등으로 분포를 표현한다. MCMC(Markov chain Monte Carlo)와 같은 몬테카를로(Monte Carlo) 방법이 비모수적 방법이다.

베이즈 추정법의 기본 원리 - 계속

- 이때 계산된 모수의 분포는 두 가지 방법으로 표현한다.
 - (1) **모수적(parametric) 방법**: 다른 확률분포를 사용하여 추정된 모수의 분포를 나타낸다. 모수 분포를 표현하는 확률분포함수의 모수를 **하이퍼모수 (hyper-parameter)**라고 부른다. 모수적 방법을 사용한 베이즈 추정법은 결국 하이퍼모숫값을 계산하는 작업이다.
 - (2) **비모수적(non-parametric) 방법**: 모수의 분포와 동일한 분포를 가지는 실제 표본 집합을 생성하여 히스토그램이나 최빈값 등으로 분포를 표현한다. **MCMC(Markov chain Monte Carlo)**와 같은 **몬테카를로(Monte Carlo)** 방법이 비모수적 방법이다.
- 여기에서는 모수적 방법의 몇 가지 간단한 예를 보인다.

베르누이분포의 모수 추정

- 가장 단순한 이산확률변수인 베르누이분포의 모수 μ 를 베이즈 추정법으로 추정해보자.

베르누이분포의 모수 추정

- 가장 단순한 이산확률변수인 베르누이분포의 모수 μ 를 베이지 추정법으로 추정해보자.
- 베르누이 분포의 모수는 0부터 1사이의 값을 가지므로 사전 분포는 하이퍼모수 $a = b = 1$ 인 베타분포라고 가정하자.

$$p(\mu) \propto \mu^{a-1}(1 - \mu)^{b-1} \quad (a = 1, b = 1)$$

베르누이분포의 모수 추정

- 가장 단순한 이산확률변수인 베르누이분포의 모수 μ 를 베이지 추정법으로 추정해보자.
- 베르누이 분포의 모수는 0부터 1사이의 값을 가지므로 사전 분포는 하이퍼모수 $a = b = 1$ 인 베타분포라고 가정하자.

$$p(\mu) \propto \mu^{a-1}(1-\mu)^{b-1} \quad (a=1, b=1)$$

- 데이터는 모두 독립적인 베르누이 분포의 곱이므로 가능도 함수는 다음과 같다.

$$p(x_1, \dots, x_N \mid \mu) = \prod_{i=1}^N \mu^{x_i} (1-\mu)^{1-x_i}$$

베르누이분포의 모수 추정 - 계속

- 베이즈 정리를 사용하면 사후분포가 다음처럼 갱신된 하이퍼모수 a', b' 를 가지는 또다른 베타분포가 된다.

$$\begin{aligned}
 p(\mu \mid x_1, \dots, x_N) &\propto p(x_1, \dots, x_N \mid \mu) p(\mu) \\
 &= \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i} \cdot \mu^{a-1} (1 - \mu)^{b-1} \\
 &= \mu^{\sum_{i=1}^N x_i + a - 1} (1 - \mu)^{\sum_{i=1}^N (1-x_i) + b - 1} \\
 &= \mu^{N_1 + a - 1} (1 - \mu)^{N_0 + b - 1} \\
 &= \mu^{a' - 1} (1 - \mu)^{b' - 1}
 \end{aligned}$$

베르누이분포의 모수 추정 - 계속

- 베이즈 정리를 사용하면 사후분포가 다음처럼 갱신된 하이퍼모수 a', b' 를 가지는 또다른 베타분포가 된다.

$$\begin{aligned}
 p(\mu \mid x_1, \dots, x_N) &\propto p(x_1, \dots, x_N \mid \mu) p(\mu) \\
 &= \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i} \cdot \mu^{a-1} (1 - \mu)^{b-1} \\
 &= \mu^{\sum_{i=1}^N x_i + a - 1} (1 - \mu)^{\sum_{i=1}^N (1-x_i) + b - 1} \\
 &= \mu^{N_1 + a - 1} (1 - \mu)^{N_0 + b - 1} \\
 &= \mu^{a' - 1} (1 - \mu)^{b' - 1}
 \end{aligned}$$

- 이렇게 사전분포와 사후분포가 모숫값만 다르고 함수 형태가 같은 확률밀도함수로 표현될 수 있도록 해주는 사전분포를 **켈레 사전확률분포 (conjugate prior)**라고 한다.

베르누이분포의 모수 추정 - 계속

- 베이즈 정리를 사용하면 사후분포가 다음처럼 갱신된 하이퍼모수 a', b' 를 가지는 또다른 베타분포가 된다.

$$\begin{aligned}
 p(\mu \mid x_1, \dots, x_N) &\propto p(x_1, \dots, x_N \mid \mu) p(\mu) \\
 &= \prod_{i=1}^N \mu^{x_i} (1 - \mu)^{1-x_i} \cdot \mu^{a-1} (1 - \mu)^{b-1} \\
 &= \mu^{\sum_{i=1}^N x_i + a - 1} (1 - \mu)^{\sum_{i=1}^N (1-x_i) + b - 1} \\
 &= \mu^{N_1 + a - 1} (1 - \mu)^{N_0 + b - 1} \\
 &= \mu^{a' - 1} (1 - \mu)^{b' - 1}
 \end{aligned}$$

- 이렇게 사전분포와 사후분포가 모습값만 다르고 함수 형태가 같은 확률밀도함수로 표현될 수 있도록 해주는 사전분포를 **켈레 사전확률분포 (conjugate prior)**라고 한다.
- 갱신된 하이퍼모수값은 다음과 같다.

$$\begin{aligned}
 a' &= N_1 + a \\
 b' &= N_0 + b
 \end{aligned}$$

베르누이분포의 모수 추정 - 예제

- 동전을 10번 던져서 앞면이 6번 나왔다. 이 때 사전분포가 하이퍼모수 $a = b = 1$ 인 베타분포라면 사후분포는 다음과 같은 하이퍼모수를 가지는 베타분포가 된다.

$$a' = 6 + 1 = 7$$

$$b' = 4 + 1 = 5$$

베르누이분포의 모수 추정 - 예제

- 동전을 10번 던져서 앞면이 6번 나왔다. 이 때 사전분포가 하이퍼모수 $a = b = 1$ 인 베타분포라면 사후분포는 다음과 같은 하이퍼모수를 가지는 베타분포가 된다.

$$a' = 6 + 1 = 7$$

$$b' = 4 + 1 = 5$$

- 참고로 최대가능도 추정법으로 구한 베르누이 모수의 값은 0.6이다.

베르누이분포의 모수 추정 - 예제


```

import numpy as np
import scipy as sp
import scipy.stats
import matplotlib.pyplot as plt

xx = np.linspace(0, 1, 1000)
a0, b0 = 1, 1
plt.plot(xx, sp.stats.beta(a0, b0).pdf(xx), c="r", ls="--", label="Prior distribution")
a1, b1 = 6 + 1, 4 + 1
plt.plot(xx, sp.stats.beta(a1, b1).pdf(xx), c="g", ls="-", label="Posterior distribution")
plt.legend()
plt.title("dist. of Bernoulli dist. parameter calculated by Bayesian estimation method")
plt.show()

```

dist. of Bernoulli dist. parameter calculated by Bayesian estimation method



베르누이분포의 모수 추정 - 계속

- 베이즈 추정법의 장점은 순차적(sequential) 계산이 가능하다는 점이다.

베르누이분포의 모수 추정 - 계속

- 베이지스 추정법의 장점은 순차적(sequential) 계산이 가능하다는 점이다.
- 예를 들어 매 50개의 데이터를 수집하는 경우를 생각하자. 베이지스 추정법을 사용하면 첫날 50개의 데이터로 모수를 추정한 뒤 다음날에는 추가적인 데이터 50개를 사용하여 모숫값을 더 정확하게 추정할 수 있다. 이 과정에서 계산량은 증가하지 않는다. 그다음 날도 마찬가지다.

베르누이분포의 모수 추정 - 계속

- 베이지스 추정법의 장점은 순차적(sequential) 계산이 가능하다는 점이다.
- 예를 들어 매 50개의 데이터를 수집하는 경우를 생각하자. 베이지스 추정법을 사용하면 첫날 50개의 데이터로 모수를 추정한 뒤 다음날에는 추가적인 데이터 50개를 사용하여 모숫값을 더 정확하게 추정할 수 있다. 이 과정에서 계산량은 증가하지 않는다. 그다음 날도 마찬가지다.
- 하지만 최대가능도 추정법을 사용하면 첫날에는 데이터 50개를 이용하여 모수를 추정하지만 둘째 날에는 100개의 데이터를 사용하여 모수를 추정해야 한다. 그다음 날에는 150개의 데이터를 사용하여 계산을 해야 한다. 데이터가 더 수집되면 점점 추정에 사용되는 데이터의 수가 증가하고 그에 따라 계산량도 증가한다.

베르누이분포의 모수 추정 - 계속

- 베イズ 추정법의 장점은 순차적(sequential) 계산이 가능하다는 점이다.
- 예를 들어 매 50개의 데이터를 수집하는 경우를 생각하자. 베イズ 추정법을 사용하면 첫날 50개의 데이터로 모수를 추정한 뒤 다음날에는 추가적인 데이터 50개를 사용하여 모숫값을 더 정확하게 추정할 수 있다. 이 과정에서 계산량은 증가하지 않는다. 그다음 날도 마찬가지다.
- 하지만 최대가능도 추정법을 사용하면 첫날에는 데이터 50개를 이용하여 모수를 추정하지만 둘째 날에는 100개의 데이터를 사용하여 모수를 추정해야 한다. 그다음 날에는 150개의 데이터를 사용하여 계산을 해야 한다. 데이터가 더 수집되면 점점 추정에 사용되는 데이터의 수가 증가하고 그에 따라 계산량도 증가한다.
- 다음 그림에서는 실제 모숫값이 0.65인 베르누이분포에 대해 베イズ 추정법을 한 결과를 보이고 있다. 처음에는 데이터 50개로 모수를 추정했으며 다음에는 데이터 50개를 추가했다. 이러한 방식으로 데이터 개수가 200개까지 증가할 때 추정 결과가 어떻게 달라지는지를 보인다.

베르누이분포의 모수 추정 - 계속

```

mu0 = 0.65
a, b = 1, 1
print("Initial estimate: mode = not known")

xx = np.linspace(0, 1, 1000)
plt.plot(xx, sp.stats.beta(a, b).pdf(xx), ls=":", label="Initial estimate")

np.random.seed(0)

for i in range(3):
    x = sp.stats.bernoulli(mu0).rvs(50)
    N0, N1 = np.bincount(x, minlength=2)
    a, b = a + N1, b + N0
    plt.plot(xx, sp.stats.beta(a, b).pdf(xx), ls="-.", label="{0}th estimate".format(i))
    print("{0}th estimate: mode = {:.4f}".format(i, (a - 1)/(a + b - 2)))

plt.vlines(x=0.65, ymin=0, ymax=12)
plt.ylim(0, 12)
plt.legend()
plt.title("Result of estimating the parameter of the Bernoulli dist. using Bayesian estimation")
plt.show()


```

```

Initial estimate: mode = not known
0th estimate: mode = 0.64
1th estimate: mode = 0.69
2th estimate: mode = 0.65

```

Result of estimating the parameter of the Bernoulli dist. using Bayesian estimation



카테고리분포의 모수 추정

- 클래스 개수가 K 인 카테고리분포의 모수 벡터 μ 를 베이지 추정법으로 추정해보자.

카테고리분포의 모수 추정

- 클래스 개수가 K 인 카테고리분포의 모수 벡터 μ 를 베이지 추정법으로 추정해보자.
- 카테고리분포의 모수의 각 원소는 모두 0부터 1사이의 값을 가지므로 사전 분포는 하이퍼모수 $\alpha_k = 1$ 인 디리클리 분포라고 가정한다.

$$p(\mu) \propto \prod_{k=1}^K \mu_k^{\alpha_k - 1} \quad (\alpha_k = 1, k = 1, \dots, K)$$

카테고리분포의 모수 추정

- 클래스 개수가 K 인 카테고리분포의 모수 벡터 μ 를 베이지 추정법으로 추정해보자.
- 카테고리분포의 모수의 각 원소는 모두 0부터 1사이의 값을 가지므로 사전 분포는 하이퍼모수 $\alpha_k = 1$ 인 디리클리 분포라고 가정한다.

$$p(\mu) \propto \prod_{k=1}^K \mu_k^{\alpha_k - 1} \quad (\alpha_k = 1, k = 1, \dots, K)$$

- 데이터는 모두 독립적인 카테고리 분포의 곱이므로 가능도 함수는 다음처럼 다항 분포다.

$$p(x_1, \dots, x_N \mid \mu) = \prod_{i=1}^N \prod_{k=1}^K \mu_k^{x_{i,k}}$$

카테고리분포의 모수 추정

- 베이즈 정리로 사후 분포를 구하면 다음과 같이 갱신된 하이퍼모수 α'_i 를 가지는 디리클리 분포가 된다.

$$\begin{aligned}
 p(\mu \mid x_1, \dots, x_N) &\propto p(x_1, \dots, x_N \mid \mu) p(\mu) \\
 &= \prod_{i=1}^N \prod_{k=1}^K \mu_k^{x_{i,k}} \cdot \prod_{k=1}^K \mu_k^{\alpha_k - 1} \\
 &= \prod_{k=1}^K \mu_k^{\sum_{i=1}^N x_{i,k} + \alpha_k - 1} \\
 &= \prod_{k=1}^K \mu_k^{N_k + \alpha_k - 1} \\
 &= \prod_{k=1}^K \mu_k^{\alpha'_k - 1}
 \end{aligned}$$

카테고리분포의 모수 추정

- 베이즈 정리로 사후 분포를 구하면 다음과 같이 갱신된 하이퍼모수 α'_i 를 가지는 디리클리 분포가 된다.

$$\begin{aligned}
 p(\mu \mid x_1, \dots, x_N) &\propto p(x_1, \dots, x_N \mid \mu) p(\mu) \\
 &= \prod_{i=1}^N \prod_{k=1}^K \mu_k^{x_{i,k}} \cdot \prod_{k=1}^K \mu_k^{\alpha_k - 1} \\
 &= \prod_{k=1}^K \mu_k^{\sum_{i=1}^N x_{i,k} + \alpha_k - 1} \\
 &= \prod_{k=1}^K \mu_k^{N_k + \alpha_k - 1} \\
 &= \prod_{k=1}^K \mu_k^{\alpha'_k - 1}
 \end{aligned}$$

- 이 경우에도 마찬가지로 디리클리분포는 켄레 분포임을 알 수 있다. 갱신된 하이퍼 모숫값은 다음과 같다.

$$\alpha'_k = N_k + \alpha_k$$

카테고리분포의 모수 추정

- 베이즈 정리를 사용하여 카테고리 분포의 모수를 추정하는 것은 사전 분포(prior distribution)를 설정한 후, 관측된 데이터를 통해 사후 분포(posterior distribution)를 업데이트하는 과정이다. 이러한 방식은 사전에 어느 정도 정보를 가지고 있을 때 특히 유용하다.

카테고리분포의 모수 추정

- 베이즈 정리를 사용하여 카테고리 분포의 모수를 추정하는 것은 사전 분포(prior distribution)를 설정한 후, 관측된 데이터를 통해 사후 분포(posterior distribution)를 업데이트하는 과정이다. 이러한 방식은 사전에 어느 정도 정보를 가지고 있을 때 특히 유용하다.
- 카테고리 분포에서 베이즈 추정을 적용하려면, 종종 베타 분포나 디리클레 분포를 사전 분포로 사용한다. 다항 분포의 경우에는 디리클레 분포가 자연스러운 연계를 보인다.

카테고리분포의 모수 추정

- 베이즈 정리를 사용하여 카테고리 분포의 모수를 추정하는 것은 사전 분포(prior distribution)를 설정한 후, 관측된 데이터를 통해 사후 분포(posterior distribution)를 업데이트하는 과정이다. 이러한 방식은 사전에 어느 정도 정보를 가지고 있을 때 특히 유용하다.
- 카테고리 분포에서 베이즈 추정을 적용하려면, 종종 베타 분포나 디리클레 분포를 사전 분포로 사용한다. 다항 분포의 경우에는 디리클레 분포가 자연스러운 연계를 보인다.
- 아래 예제에서는 디리클레 사전 분포를 가정하고, 간단한 데이터를 바탕으로 파이썬을 사용하여 베이즈 업데이트를 수행하는 방법을 보여준다.

카테고리분포의 모수 추정 - 예제

```
import numpy as np
from scipy.stats import dirichlet

# 사전 분포(디리클레)의 파라미터 설정 (모든 카테고리에 대해 같은 값을 설정)
alpha_prior = np.array([1, 1, 1]) # 각 카테고리에 대한 사전 지식 (사전 카운트)

# 관측된 데이터
data = ['red', 'blue', 'green', 'blue', 'blue', 'red', 'green', 'green', 'blue', 'red']
categories, counts = np.unique(data, return_counts=True)

# 데이터를 기반으로 사후 파라미터 업데이트
alpha_posterior = alpha_prior + counts

# 디리클레 사후 분포로부터 기대치 계산
expected_probabilities = dirichlet.mean(alpha_posterior)

# 결과 출력
for category, probability in zip(categories, expected_probabilities):
    print(f"Category '{category}' has updated estimated probability: {probability:.3f}")
```

```
Category 'blue' has updated estimated probability: 0.385
Category 'green' has updated estimated probability: 0.308
Category 'red' has updated estimated probability: 0.308
```

카테고리분포의 모수 추정 - 예제

```

import numpy as np
from scipy.stats import dirichlet

# 사전 분포(디리클레)의 파라미터 설정 (모든 카테고리에 대해 같은 값을 설정)
alpha_prior = np.array([1, 1, 1]) # 각 카테고리에 대한 사전 지식 (사전 카운트)

# 관측된 데이터
data = ['red', 'blue', 'green', 'blue', 'blue', 'red', 'green', 'green', 'blue', 'red']
categories, counts = np.unique(data, return_counts=True)

# 데이터를 기반으로 사후 파라미터 업데이트
alpha_posterior = alpha_prior + counts

# 디리클레 사후 분포로부터 기대치 계산
expected_probabilities = dirichlet.mean(alpha_posterior)

# 결과 출력
for category, probability in zip(categories, expected_probabilities):
    print(f"Category '{category}' has updated estimated probability: {probability:.3f}")

Category 'blue' has updated estimated probability: 0.385
Category 'green' has updated estimated probability: 0.308
Category 'red' has updated estimated probability: 0.308

```

- 이 코드는 각 카테고리의 사전 확률에 데이터의 영향을 추가하여 사후 확률을 업데이트하고, 최종적으로 각 카테고리의 확률을 출력한다. `dirichlet.mean` 함수는 주어진 파라미터에 대한 디리클레 분포의 기대치를 계산한다. 이 방법을 통해 데이터와 사전 지식을 함께 활용하여 각 카테고리의 확률을 더 정확하게 추정할 수 있다.

정규분포의 기댓값 모수 추정

- 정규분포의 기댓값 모수를 베이지안 방법으로 추정한다. 분산 모수 σ^2 은 알고 있다고 가정한다.

정규분포의 기댓값 모수 추정

- 정규분포의 기댓값 모수를 베이지안 방법으로 추정한다. 분산 모수 σ^2 은 알고 있다고 가정한다.
- 기댓값은 $-\infty$ 부터 ∞ 까지의 모든 수가 가능하기 때문에 모수의 사전 분포로는 정규분포를 사용한다.

$$p(\mu) = \mathcal{N}(\mu_0, \sigma_0^2) = \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(\mu - \mu_0)^2}{2\sigma_0^2}\right)$$

정규분포의 기댓값 모수 추정

- 정규분포의 기댓값 모수를 베이지안 방법으로 추정한다. 분산 모수 σ^2 은 알고 있다고 가정한다.
- 기댓값은 $-\infty$ 부터 ∞ 까지의 모든 수가 가능하기 때문에 모수의 사전 분포로는 정규분포를 사용한다.

$$p(\mu) = \mathcal{N}(\mu_0, \sigma_0^2) = \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(\mu - \mu_0)^2}{2\sigma_0^2}\right)$$

- 데이터는 모두 독립적인 정규분포의 곱이므로 가능도 함수는 다음과 같다.

$$p(x_1, \dots, x_N \mid \mu) = \prod_{i=1}^N \mathcal{N}(x_i \mid \mu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

$$\begin{aligned} p(\mu \mid x_1, \dots, x_N) &\propto p(x_1, \dots, x_N \mid \mu)p(\mu) \\ &\propto \exp\left(-\frac{(\mu - \mu'_0)^2}{2\sigma'^2_0}\right) \end{aligned}$$

정규분포의 기댓값 모수 추정

- 베이즈 정리를 이용하여 사후 분포를 구하면 다음과 같이 갱신된 하이퍼모수를 가지는 정규분포가 된다.

$$\begin{aligned}\mu'_0 &= \frac{\sigma^2}{N\sigma^2 + \sigma^2}\mu_0 + \frac{N\sigma^2}{N\sigma^2 + \sigma^2} \frac{\sum x_i}{N} \\ \frac{1}{\sigma'^2_0} &= \frac{1}{\sigma^2_0} + \frac{N}{\sigma^2}\end{aligned}$$

정규분포의 기댓값 모수 추정 - 예제

다음은 실제 기댓값이 2, 분산이 4인 정규분포에서 나온 데이터를 이용하여 기댓값 모수를 순차적 베이즈 추정한 결과다. 각 차수별로 100개의 데이터를 사용하였다. 초기 추정값 즉, 사전확률분포로는 기댓값이 0, 분산이 1인 정규분포를 사용하였다.

```
mu, sigma2 = 2, 4
mu0, sigma20 = 0, 1
xx = np.linspace(1.8, 2.2, 1000)
np.random.seed(1)
N = 100
ls = [":", "-.", "--", "-"]
for i in range(4):
    x = sp.stats.norm(mu).rvs(N)
    mu0 = sigma2/(N*sigma20 + sigma2) * mu0 + \
        (N*sigma20)/(N*sigma20 + sigma2)*x.mean()
    sigma20 = 1/(1/sigma20 + N/sigma2)
    plt.plot(xx, sp.stats.norm(mu0, sigma20).pdf(xx), ls=ls[i], label="{0}th estimate".format(i))
    print("{0}th estimate: {1:4.2f}".format(i, mu0))
plt.legend()
plt.title("Resultsof estimating the expected value of the normal dist. by Bayesian estimation")
plt.show()
```

```
0th estimate: 1.98
1th estimate: 2.07
2th estimate: 2.05
3th estimate: 2.03
```

정규분포의 기댓값 모수 추정 - 예제

Resultsof estimating the expected value of the normal dist. by Bayesian estimation

